# Crear Software en la Era de los Pesos Abiertos

Hardware, modelos y el ciclo de desarrollo completo.

01

**Fernando**

Software Crafter · AI Survivor

Software Crafters Barcelona

XIII EDITION #SCBCN26

# SPONSORS SCBCN26

## UNIXCORN

540

## PEGASO

next digital

## PONIA

seQura

manfred

sirviendo código;

CODESAI

codely

basetis

CAMBIO DE PARADIGMA

# El Fin del Bufé Libre

La fase de adquisición masiva subvencionada por capital riesgo ha terminado. Creada la dependencia en el flujo diario de los desarrolladores, llega el despertar de la factura real.

2022 – 2024

🎁

## La Era Dorada

**10 $** / mes (o gratis)

✨ **Acceso Ilimitado**
Modelos punteros sin límites de tokens para crear el hábito.

💸 **Cómputo a Pérdidas**
Los fondos de inversión absorben miles de millones en GPUs.

**Fidelización Total**
El autocomplete y el chat se vuelven indispensables en el IDE.

`Objetivo: Enganche de Mercado`

2025 – 2026

⚠️

## El Despertar

**200 $ - 275 €** / mes + Credits

⚡ **Cambio de Condiciones**
Límites arbitrarios y multiplicadores a mitad de contrato.

🔒 **Razonamiento Encarcelado**
Modelos de razonamiento profundo fuera del plan estándar.

📈 **"Es el Mercado, Amigo"**
Monetización forzada sabiendo que no puedes dar marcha atrás.

`Realidad: Sostenibilidad Forzada`

PRENSA Y ANÁLISIS

# El choque de precios en los medios

NYT / TECHCRUNCH 27 Sep 2024

FILTRACIÓN

## «La hoja de ruta de OpenAI para subir ChatGPT hasta 44 $ al mes»

Planes internos filtrados detallan la duplicación progresiva del precio de la suscripción Plus para compensar la factura masiva de servidores.

techcrunch.com/openai-pricing-roadmap ↗

XATAKA ANDROID 4 Nov 2025

MERCADO PRO

## «La batalla de los 200 € al mes: ChatGPT Pro vs. Gemini Ultra»

Fragmentación del mercado: las funciones potentes de razonamiento profundo y agentes autónomos se desplazan a tramos de 229 € a 275 € mensuales.

xatakandroid.com/batalla-precios-ia-espana ↗

XATAKA 12 Jun 2026

ECONOMÍA IA

## «Las suscripciones de IA son un chollo insostenible: el fin del bufé libre»

200 dólares al mes dan acceso a 14.000 $ en tokens reales. La llegada de agentes autónomos obliga a cerrar el grifo de las tarifas planas ilimitadas.

xataka.com/suscripciones-ia-chollo-insostenible ↗

MINDSTUDIO 15 Jun 2026

CAPITAL RIESGO

## «Por qué la era de los 20 $/mes se acaba y llega el pricing shock»

La fase de adquisición subvencionada por fondos de inversión ha terminado; las plataformas recortan el plan básico y cobran recargos por cada tarea pesada.

mindstudio.ai/ai-pricing-shock ↗

CASO DE ESTUDIO • REBELIÓN DEV

# Especial GitHub Copilot: La crisis de los Refunds

GITHUB BLOG OFICIAL 20 Abr 2026

COMUNICADO

## «Changes to Copilot Individual Plans and Refund Clarifications»

La dirección de GitHub se ve obligada a publicar aclaraciones oficiales sobre los límites por créditos y a habilitar el reembolso prorrateado para calmar las bajas.

🔗 github.blog/copilot-individual-plans ↗

REDDIT (R/GITHUBCOPILOT) 28 Abr 2026

CHARGEBACKS

## «Massive Backlash: Model Downgrades and Refund Disputes»

Hilos con miles de votos organizando disputas en PayPal y tarjetas por *bait-and-switch* tras la degradación automática a modelos básicos en 2–3 días.

🔗 reddit.com/r/GithubCopilot/…/1sy2ka1 ↗

TECH ANALYSIS / MEDIUM 3 Jun 2026

IMPACTO GLOBAL

## «GitHub Copilot Just Betrayed 4.7 Million Devs: The End of Flat Rate»

Crónica del colapso del modelo económico de suscripción fija tras la llegada de agentes autónomos y la frustración masiva en la comunidad de software.

🔗 medium.com/@shahadilh18/github-copilot-just-betrayed ↗

GITHUB COMMUNITY FORUM 5 Jun 2026

QUEJA FORMAL

## «Formal Complaint: Copilot Pricing Changes and Breach of Contract»

Suscriptores anuales denuncian la introducción de AI Credits con multiplicadores abusivos que reducen el valor útil a menos de un tercio a mitad de contrato.

🔗 github.com/orgs/community/discussions/198080 ↗

INFERENCIA POR API

# Modelos Cloud: Occidentales vs. Asiáticos

PROPIETARIO CLOUD

$2.00 - $5.00 / 1M

## APIs norteamericanas

OpenAI (GPT-5.6 / o3) • Anthropic (Claude 5) • Google

PROS & VENTAJAS

- ✓ Integración inmediata sin infraestructura propia
- ✓ Modelos frontera con razonamiento profundo puntero
- ✓ Ecosistema de SDKs y herramientas consolidado

CONTRAS & RIESGOS

- ✗ Subidas arbitrarias de cuotas y multiplicadores de créditos
- ✗ Telemetría externa y procesamiento fuera de tu control
- ✗ Riesgo total de encierro (Vendor Lock-in)

Seguridad: Privacidad de tercero

Modelo: Coste Variable Flotante

OPEN-WEIGHTS CLOUD

$0.08 - $0.55 / 1M

## APIs chinas

DeepSeek (V4 / R1) • Alibaba Qwen (3.8 Max / 72B)

PROS & VENTAJAS

- ✓ Reducción drástica de factura (hasta 20× más barato)
- ✓ Calidad y benchmarks equiparables a modelos frontera
- ✓ API REST 100% compatible con estándar OpenAI

CONTRAS & RIESGOS

- ✗ Inferencia en servidores de terceros fuera de la UE
- ✗ Dependencia de disponibilidad de API del proveedor
- ✗ Latencias variables bajo alta demanda global

Seguridad: Servidor externo

Modelo: Alta Eficiencia ($/1M)

PRENSA Y ANÁLISIS · PRIVACIDAD

# El espionaje de modelos: destilación y rutas ocultas

ANTHROPIC · THREAT REPORT Sep 2026

INVESTIGACIÓN

## «7 laboratorios chinos destilaron Claude a escala industrial»

Campañas con 24.000+ cuentas fraudulentas y 151M de interacciones (Alibaba) para clonar razonamiento, código y cadenas de pensamiento.

anthropic.com/detecting-countering-misuse-of-ai ↗

ANTHROPIC · INFORME AMPLIADO Sep 2026

RUTEO OCULTO

## «Moonshot AI desviaba los prompts de sus usuarios a Claude… y revendía la respuesta»

En tiempo real, las consultas de sus propios clientes iban a los servidores de Claude y volvían al usuario presentadas como producción de su propia IA.

anthropic.com/detecting-countering-misuse-of-ai ↗

CYBERSPACE ADMIN. OF CHINA Oct 2026

INSPECCIÓN

## «China interroga a DeepSeek y Moonshot: sus usuarios hablaban con EE.UU.»

Al desviar prompts locales hacia servidores americanos, información sensible corporativa y gubernamental quedó expuesta ; la CAC abre inspecciones por seguridad nacional.

thehackernews.com · cobertura CAC ↗

NSA · CISA · FBI Sep 2026

ALERTA CONJUNTA

## «EE.UU. confirma el ataque sistemático a los modelos frontera occidentales»

Alerta de inteligencia conjunta: DeepSeek y Alibaba atacan sistemáticamente los modelos frontera mediante destilación no autorizada.

cisa.gov · alerta conjunta ↗

ESCENA REAL · FILTRACIÓN DE DATOS

# Conversación con el CEO: APIs chinas 🇨🇳

*«Bro, sospecho que nuestro prompt se ha **filtrado por medio planeta**.»*

PRENSA Y ANÁLISIS · VARIABILIDAD

# El nerfeo: tu modelo cambia bajo tus pies

ANTHROPIC ENGINEERING 23 Abr 2026 — POST-MORTEM

## «Anthropic reconoce la caída de calidad: 3 experimentos degradaron Claude Code»

Razonamiento High→Medium, amnesia de caché de sesión y concisión forzada en el system prompt. Revertidos entre el 7 y el 20 de abril tras las quejas masivas.

anthropic.com/engineering/claude-code-quality ↗

OPENAI COMMUNITY 9 Oct 2026 — SILENT ROUTING

## «Downgrades encubiertos: el flagship se reenruta sin avisar»

Con proxies locales, los desarrolladores cazaron rutas hacia variantes degradadas (gpt-5.6-luna) cuando el clúster devolvía "selected model is at capacity".

community.openai.com/…/1404987 ↗

REDDIT · R/CHATGPT 6 Ago 2026 — NERFEO

## «GPT 5.6 Sol High feels severely nerfed since 08/06»

Más de 100 votos denunciando la caída repentina del razonamiento complejo, con quejas por el enrutador Auto ineludible: no puedes fijar el modelo.

reddit.com/r/ChatGPT/…/1vl1anl ↗

REDDIT · R/CLAUDEAI 18 Ago 2026 — DEGRADACIÓN

## «Discussion Hub: degraded performance for multiple models»

Hilos masivos de seguimiento con picos documentados en agosto y septiembre: la comunidad mide el rendimiento del modelo día a día porque ya no se fía.

reddit.com/r/ClaudeAI/…/1vrtyin ↗

ESCENA REAL · VARIABILIDAD

# Conversación con el CEO: APIs norteamericanas 🇺🇸

*«Bro, me han nerfeado el modelo. Esto antes molaba…»*

INFRAESTRUCTURA DEDICADA

# Tu Infraestructura: Alquilar o Poseer

GPU CLOUD IAAS

3,22 € - 33 € / h

## Alquiler de GPUs Cloud

RunPod • Lambda • 1× a 8× NVIDIA H200 (141GB - 1.128GB)

PROS & VENTAJAS

✓ Inferencia masiva de MoE gigantes (230B-405B) en FP8/FP16

✓ Flexibilidad total: encender, escalar o apagar sin permanencia

✓ Alta concurrencia para servir a un equipo entero de devs

CONTRAS & RIESGOS

✗ Facturación continua mientras la máquina esté activa

✗ Requiere sysadmin y configuración de vLLM / Ollama

✗ Los pesos del modelo residen en la nube de un tercero

Seguridad: Instancia Cloud Privada

Modelo: Coste Fijo Horario

100% SOBERANO

0,00 € / token

## Hardware Propio Local

Apple Silicon (Mac Studio M-series) • Workstations RTX/NPU

PROS & VENTAJAS

✓ Privacidad absoluta: zero data leaks y 100% offline (air-gapped)

✓ Coste marginal por token exactamente de 0,00 €

✓ Control artesanal total, soberanía de datos y latencia fija

CONTRAS & RIESGOS

✗ Inversión inicial en compra de hardware propio

✗ Tamaño de modelo limitado por la VRAM física del equipo

Seguridad: 100% Local / Air-Gapped

Modelo: Coste Marginal Nulo

INFRAESTRUCTURA DEDICADA

# Tu Infraestructura: Alquilar o Poseer

GPU CLOUD IAAS

3,22 € - 33 € / h

## Alquiler de GPUs Cloud

RunPod • Lambda • 1× a 8× NVIDIA H200 (141GB - 1.128GB)

PROS & VENTAJAS

✓ Inferencia masiva de MoE gigantes (230B-405B) en FP8/FP16

✓ Flexibilidad total: encender, escalar o apagar sin permanencia

✓ Alta concurrencia para servir a un equipo entero de devs

CONTRAS & RIESGOS

✗ Facturación continua mientras la máquina esté activa

✗ Requiere sysadmin y configuración de vLLM / Ollama

✗ Los pesos del modelo residen en la nube de un tercero

Seguridad: Instancia Cloud Privada

Modelo: Coste Fijo Horario

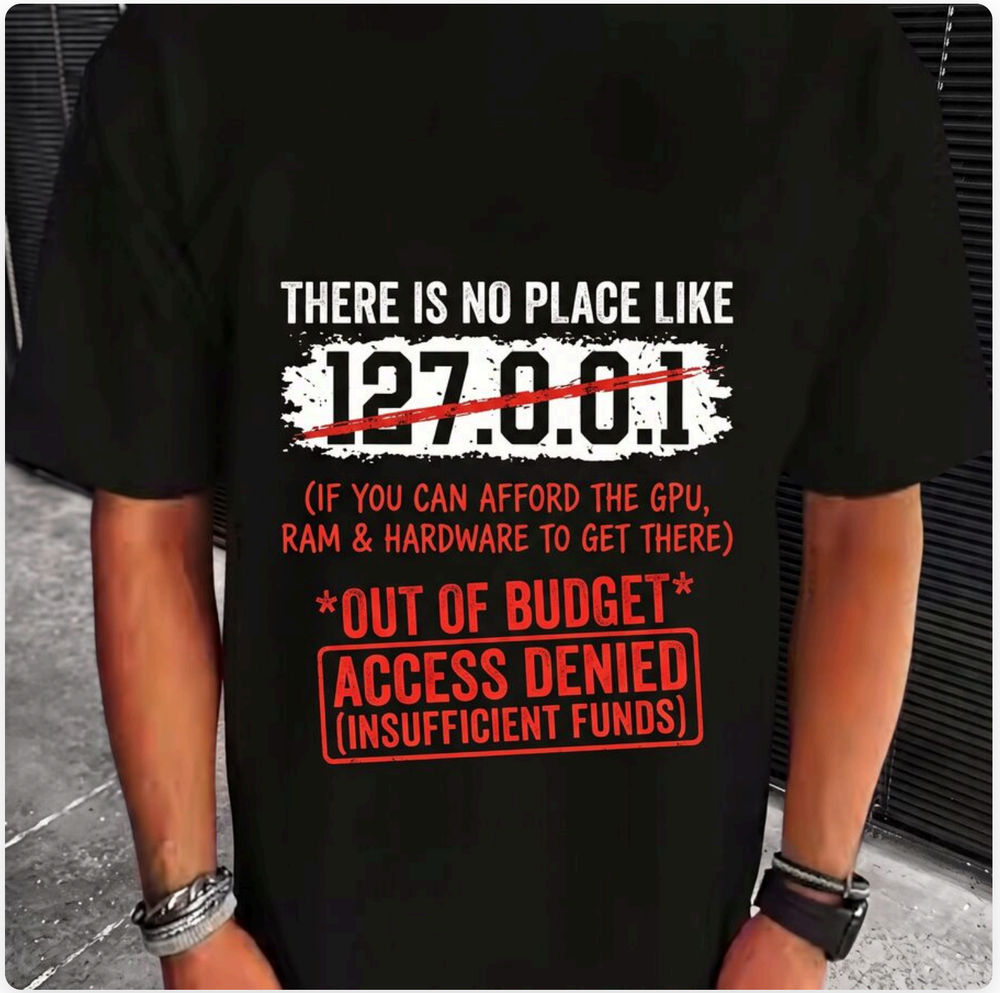


💸 **...hasta la factura del silicio:** $25/GB y la caja agotada

PRENSA Y ANÁLISIS

# El choque de precios II: la caja se disparó

| EQUIPO | CONFIGURACIÓN | EVOLUCIÓN DE PRECIO | Δ | ESTADO (OCT 2026) |
|---|---|---|---|---|
| Framework Desktop | **128 GB unificada** | $1.999 → $2.459 → $3.449 | +72% | 🔴 Agotado en tienda |
| **NVIDIA DGX Spark** | **GB10 · 128 GB** | **$3.999 → $4.699 → $6.950** | **+74%** | 🔴 **Agotado en canal** |
| NVIDIA DGX Spark | **GB10 · 64 GB (recorte)** | anuncio: $4.999 | +25% vs. 128 GB orig. | 🟡 Anunciado 23 Oct |
| Bosgame M5 / MS-S1 Max | **Strix Halo · 128 GB** | $2.899 → $3.099 – $3.799 | +7 – 31% | 🟡 Stock fugaz |
| GMKtec EVO-X2 | **Strix Halo · 128 GB** | – | – | 🔴 Agotado (todas) |
| Apple Mac Studio | **M5 Max · 128 GB** | $5.099 | +$1.600 por 64 GB ($25/GB) | 🟢 Disponible |
| Apple Mac Studio | **M5 Ultra · 256 GB** | $9.499 | – | 🟢 Disponible |
| Gorgon Halo | **AI Max+ Pro 495 · 192 GB** | $6.799 | – | 🟢 Escalón de entrada 192 GB |

La promesa de amortizar una caja de **$2.000** se convirtió en un ticket de entrada de **$5.000–7.000**, con roturas de stock sistemáticas y 25 $ por cada GB de memoria. **La IA local dejó de ser la puerta de entrada para todo el mundo.**

EL PIVOTE DE 2026

Tarifas H200 verificadas el 19 sep 2026 · DeepInfra · Vast.ai · Latitude.sh

# La salida honesta: alquilar GPUs para pesos abiertos

NIVEL 1

## 1× H200

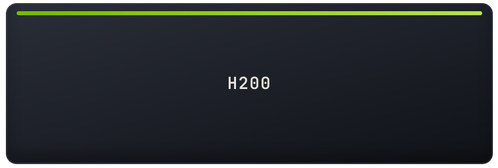


141 GB VRAM

4,8 TB/s por GPU

3,22 – 4,22 €/h

Caben: **Qwen 3.8 Flash Next** · **DeepSeek V4 Flash** en NVFP4, sin repartir

NIVEL 2

## 2× H200

282 GB VRAM

NVLink une las 2 GPUs

6,44 – 8,45 €/h

Caben: **DeepSeek V3** · **Qwen 3.8** en FP8, repartido entre las 2

NIVEL 3

## 4× H200

564 GB VRAM

NVLink: 4 GPUs fusionadas

12,88 – 16,89 €/h

Caben: modelos frontera **230B–405B** con tensor paralelismo

NIVEL 4

## 8× H200

1.128 GB VRAM

NVSwitch conecta las 8

25,76 – 33,12 €/h

Caben: **DeepSeek V3/V4** a precisión nativa, sin comprometer

VIVENCIA PERSONAL • LA DECISIÓN

# La Decisión: Haciendo «calculasiones»

⏳ ANTES DE QUE EL MERCADO EXPLOTARA

1 **Cálculo de Inferencia Cloud vs Local**

Las APIs de frontera ($1.25 – $4.00 / 1M tok) en un flujo de desarrollo diario intensivo escalan a cientos de euros al mes.

2 **La Ecuación de la VRAM (128 GB)**

INT4 / NVFP4 permite encajar modelos MoE de 122B y 35B con 256K de contexto nativo sin recurrir a terceros.

3 **La Conclusión Inevitable**

Amortización en meses, latencia cero, soberanía total de código y experimentación sin mirar el taxímetro de tokens.

VIVENCIA PERSONAL • CASO DE ESTUDIO

# ¡Llegó el Aparato! (llegué a tiempo)

📦 1. Hardware (GB10 • 128 GB)

+

vLLM PAGED

llama.cpp GGUF

SGLang RADIX

🔩 2. Motores de Inferencia

+

Qwen 3.5 122B A10B MoE INT4

Qwen 3.6 35B A3B MoE FP8

🧠 3. Modelos Open-Weights

VIVENCIA PERSONAL • CASO DE ESTUDIO

# ¡Llegó el Aparato! (llegué a tiempo)

📦 1. Hardware (GB10 • 128 GB)

+

vLLM PAGED

llama.cpp GGUF

SGLang RADIX

🔩 2. Motores de Inferencia

+

¡OBSOLETO!

Qwen 3.5 122B A10B MoE INT4

Qwen 3.6 35B A3B MoE FP8

🧠 3. Modelos Open-Weights

VIVENCIA PERSONAL • CASO DE ESTUDIO

# ¡Llegó el Aparato! (llegué a tiempo)

📦 1. Hardware (GB10 • 128 GB)

+

vLLM PAGED

llama.cpp GGUF

SGLang RADIX

🔩 2. Motores de Inferencia

+

Qwen 3.8 FlashNext MoE NUEVO

Qwen 3.6 35B A3B MoE NVFP4

🧠 3. Modelos Open-Weights

VIVENCIA PERSONAL • CASO DE ESTUDIO

# ¡Llegó el Aparato! (llegué a tiempo)

📦 1. Hardware (GB10 • 128 GB)

+

vLLM PAGED

llama.cpp GGUF

SGLang RADIX

🔩 2. Motores de Inferencia

+

Qwen 3.8 FlashNext MoE NUEVO

Qwen 3.6 35B A3B MoE NVFP4

🧠 3. Modelos Open-Weights

=

⚗️ 4. «Alquimia de la buena»

FOROS & COMUNIDAD • EARLY ADOPTERS

# El Drama de Blackwell GB10: La odisea en los foros

NVIDIA DEV FORUMS 14 Mar 2026

POWER THROTTLE

## «DGX Spark & ASUS GX10 stuck at 611MHz / 13W throttle state»

Bugs en el controlador USB-C PD bloquean la GPU en modo seguro inutilizable. El soporte oficial confirma que el único fix temporal es el "cold drain" : desconectar físicamente de la corriente y esperar a vaciar condensadores.

GITHUB ISSUES (VLLM) 8 Abr 2026

SM 12.1A MISMATCH

## «Fatal CUDA error: Datacenter sm_100 containers fail on GB10»

La arquitectura de consumo SM 12.1a no es compatible con binarios oficiales. Los kernels de Tensor Core tcgen05 para FP4 vienen deshabilitados o sin compilar , provocando fallos inmediatos.

REDDIT (R/LOCALLLAMA) 19 May 2026

ROADMAP TRAP

## «NVFP4 on GB10 performs WORSE than INT4 on Ada: Where are the kernels?»

Compradores de estaciones de 128GB descubren que NVIDIA no liberará soporte maduro de NVFP4 hasta finales de 2026 , dejando el hardware puntero a un tercio de su velocidad teórica.

COMMUNITY RELEASE 2 Jun 2026

OPEN SOURCE FIX

## «avarok/vllm-nvfp4-gb10 & spark-vllm-docker: Unlocking 128GB Unified Memory»

Desarrolladores independientes publican imágenes Docker con kernels CUTLASS recompilados a mano , permitiendo correr Nemotron y Qwen 72B a máxima velocidad sin esperar a los drivers oficiales.

FOROS & COMUNIDAD • LA PROMESA NVFP4

# El Drama de Blackwell GB10: La odisea en los foros

COMUNIDAD & DESARROLLADORES La Promesa Blackwell

«¡Me dijiste que podría ejecutar NVFP4!»

NVIDIA & DRIVERS OFICIALES Roadmap Oficial

«Pero no dije cuándo...» (A finales de 2026)

ARTESANÍA DE SOFTWARE & OPEN SOURCE • HACKERS DE SILICIO

# Hackeando el Hierro: La Comunidad al Rescate

## Eugr

Independent Hacker & ML Engineer

`eugr/spark-vllm-docker`

`@eugr`

### ✓ Contenedores Docker para DGX Spark

Creó las primeras imágenes y *build recipes* de vLLM optimizadas para Asus Ascent GX10 / DGX Spark, permitiendo levantar el stack de inferencia.

### ✓ Soporte MTP & Aceleración Especulativa

Integró recetas de Multi-Token Prediction directamente en vLLM para multiplicar la velocidad de inferencia sin VRAM adicional.

### ✓ 128 GB Unificados al Máximo

Habilitó la ejecución de modelos MoE y densos masivos (Qwen, Nemotron) sorteando las trabas iniciales de software del vendor.

## Thomas Braun

Founder of Avarok & Kernel Hacker

`avarok/vllm-nvfp4-gb10`

`@tbraun96 • Avarok`

### ✓ Recompilación de Kernels CUTLASS

Parcheó y recompiló a mano los kernels para la microarquitectura `sm_121a` de Blackwell GB10 saltándose los binarios oficiales.

### ✓ NVFP4 Nativo Meses Antes del Roadmap

Desbloqueó la aceleración FP4 en Tensor Cores en mayo/junio 2026, mientras NVIDIA posponía el soporte oficial a finales de año.

### ✓ Rendimiento Teórico Recuperado

Multiplicó por 3× la velocidad de Nemotron y Qwen 72B frente a los lentos fallbacks por software estándar.

🛠️ **El Ecosistema vLLM & SGLang al Rescate:** La comunidad y los mantenedores integran continuamente parches de kernels CUTLASS/PTX y PRs upstream para que el hardware funcione a máxima potencia sin esperar a los drivers oficiales.

`COMUNIDAD OPEN SOURCE`

MARCO MENTAL • LAS 3 VARIABLES CLAVE

# El Trilema de la IA Local: Memoria, Calidad y Velocidad

1. **Memoria · El límite físico**
2. **Calidad · La lógica intacta**
3. **Velocidad · La fluidez interactiva**

ANATOMÍA DE LA MEMORIA • VRAM & HARDWARE

# ¿En qué se gasta la Memoria? Pesos vs. KV Cache

🎮 Tanque de 24 GB (Qwen 3.6 27B INT4)

24 GB VRAM

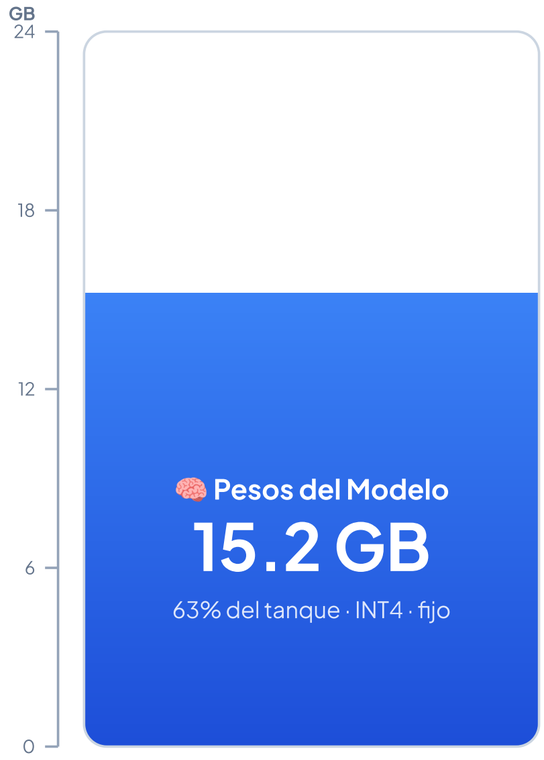


## 🧠 Pesos del Modelo

MEMORIA ESTÁTICA

🔒 **Inmutable:** se carga una sola vez al arrancar y su tamaño nunca cambia, respondas 1 pregunta o 10.000. Es tu precio de entrada fijo.

ANATOMÍA DE LA MEMORIA • VRAM & HARDWARE

# ¿En qué se gasta la Memoria? Pesos vs. KV Cache

🎮 Tanque de 24 GB (Qwen 3.6 27B INT4)

24 GB VRAM

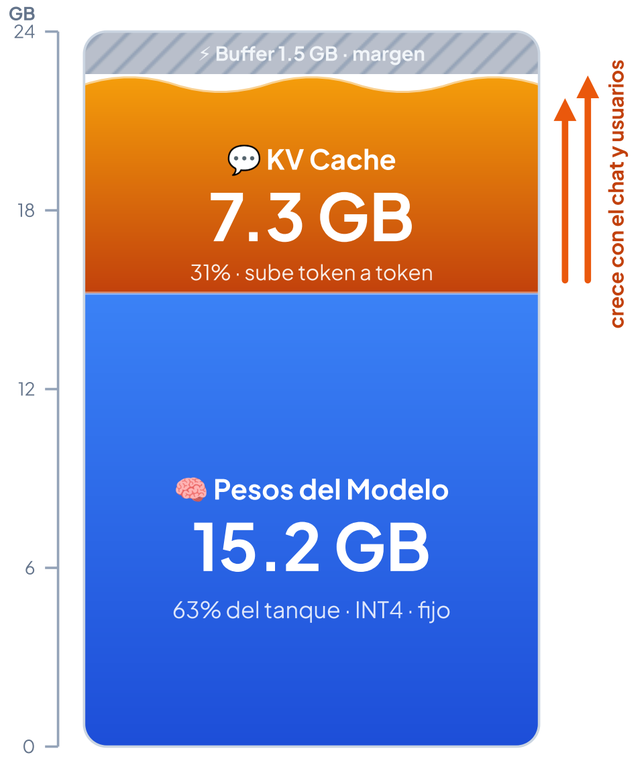


## 🧠 Pesos del Modelo

MEMORIA ESTÁTICA

🔒 **Inmutable:** se carga una sola vez al arrancar y su tamaño nunca cambia, respondas 1 pregunta o 10.000. Es tu precio de entrada fijo.

## 💬 KV Cache

MEMORIA DINÁMICA

📈 **Multiplicativa:** guarda preguntas, respuestas y PDFs para no recalcular desde cero. Crece token a token por cada usuario activo, y con contexto largo puede comerse el margen entero.

PRECISIÓN & BENCHMARKS • QWEN 122B MOE

# El Peaje de Comprimir: ¿Cuánta Inteligencia se Pierde?

🎮 Tanque de 24 GB (Qwen 3.6 27B INT4)

24 GB VRAM

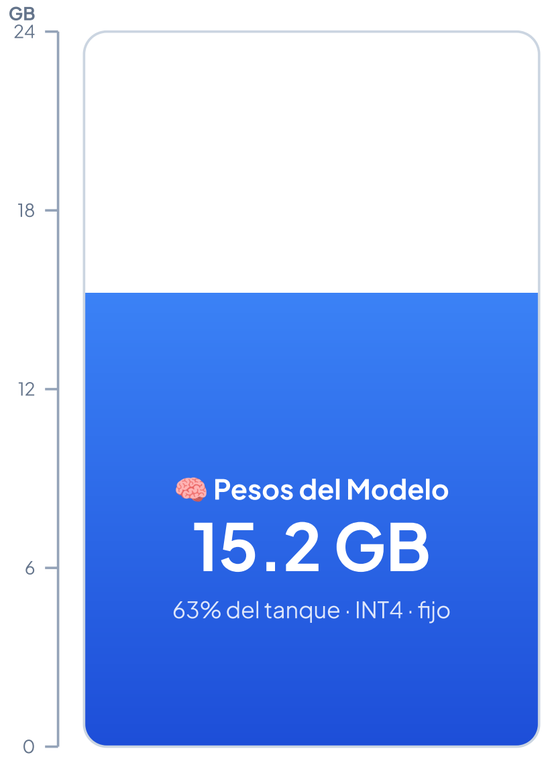

🔨 **La forja de la cuantización:** cada martillazo quita material (precisión) para que la hoja —el modelo de 244 GB— quepa en la fragua de 128 GB. La pregunta: ¿cuánto filo sobrevive?

PRECISIÓN & BENCHMARKS • QWEN 122B MOE

# El Peaje de Comprimir: ¿Cuánta Inteligencia se Pierde?

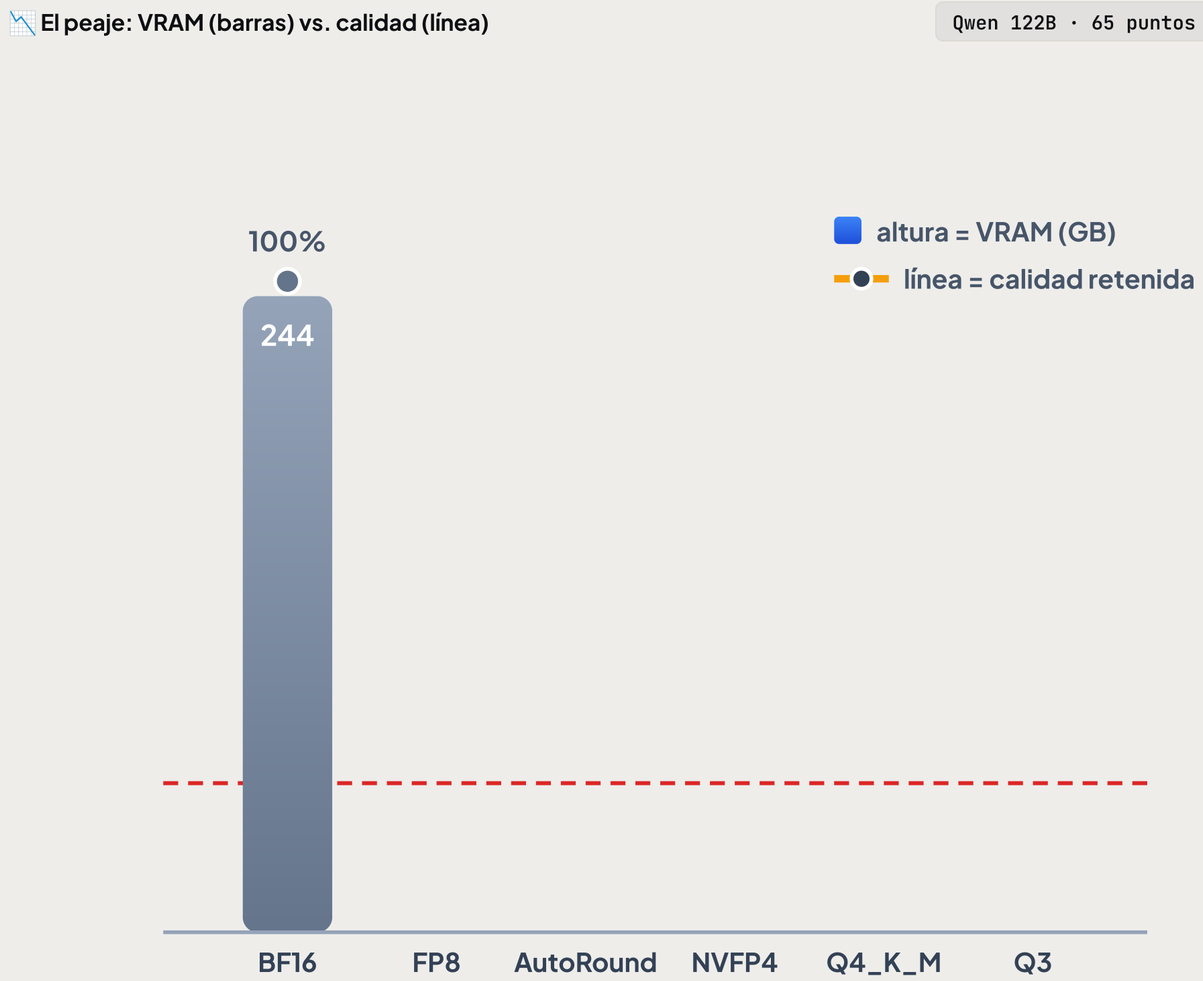


FP8: solo datacenter · INT4/NVFP4: el punto dulce de 128 GB · Q3: rompe el código

PRECISIÓN & BENCHMARKS • QWEN 122B MOE

# El Peaje de Comprimir: ¿Cuánta Inteligencia se Pierde?

📉 El peaje: VRAM (barras) vs. calidad (línea)

Qwen 122B · 65 puntos

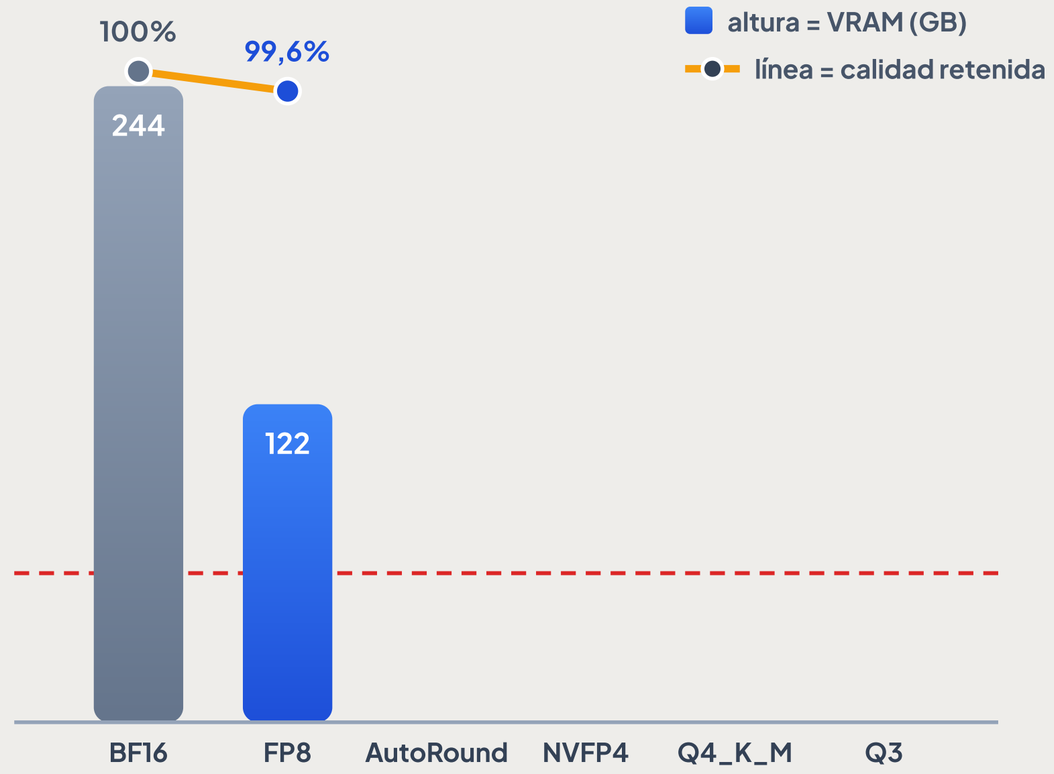


FP8: solo datacenter · INT4/NVFP4: el punto dulce de 128 GB · Q3: rompe el código

### 1. 💎 FP8 — el clon exacto

99,6% de calidad · 122 GB: impecable, pero solo vive en un datacenter.

PRECISIÓN & BENCHMARKS • QWEN 122B MOE

# El Peaje de Comprimir: ¿Cuánta Inteligencia se Pierde?

📉 El peaje: VRAM (barras) vs. calidad (línea)

Qwen 122B · 65 puntos

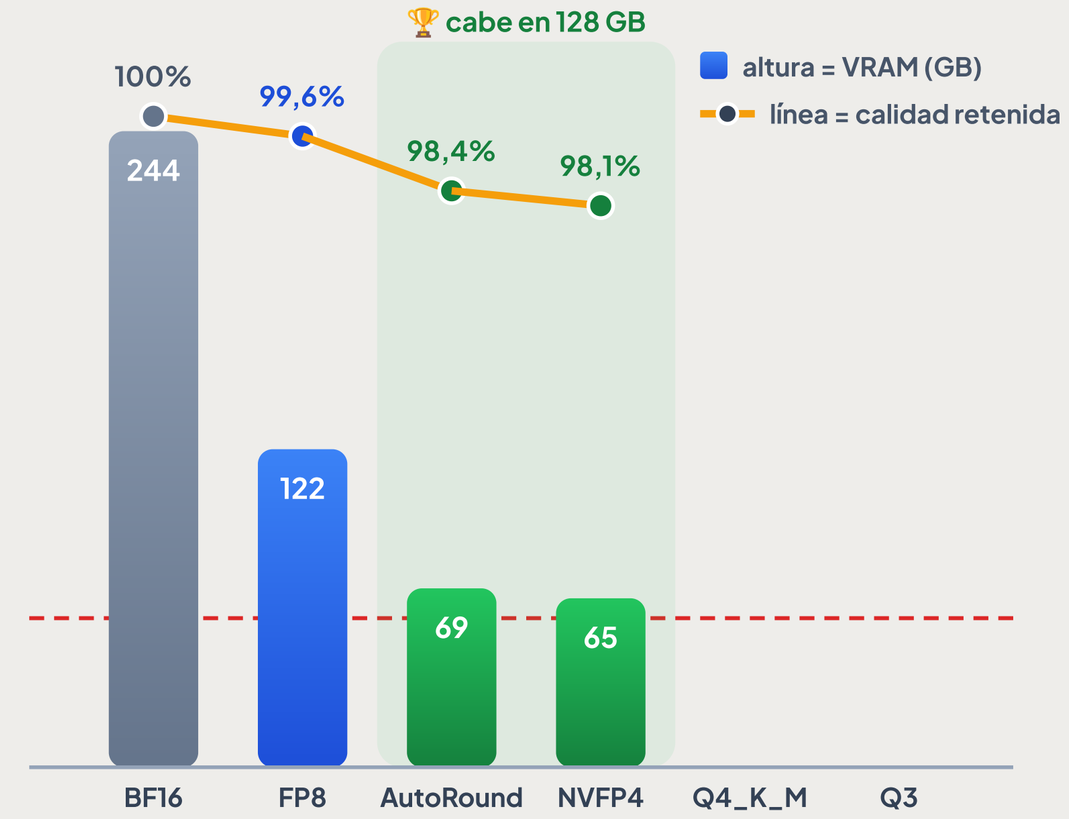


FP8: solo datacenter · INT4/NVFP4: el punto dulce de 128 GB · Q3: rompe el código

### 1. 💎 FP8 — el clon exacto

99,6% de calidad · 122 GB: impecable, pero solo vive en un datacenter.

### 2. 🌟 INT4 / NVFP4 — el punto dulce de 128 GB

AutoRound 98,4% · NVFP4 98,1% · 65–69 GB (3,5× más ligero): cabe en 128 con aire para la KV.

PRECISIÓN & BENCHMARKS • QWEN 122B MOE

# El Peaje de Comprimir: ¿Cuánta Inteligencia se Pierde?

📉 El peaje: VRAM (barras) vs. calidad (línea)

Qwen 122B · 65 puntos

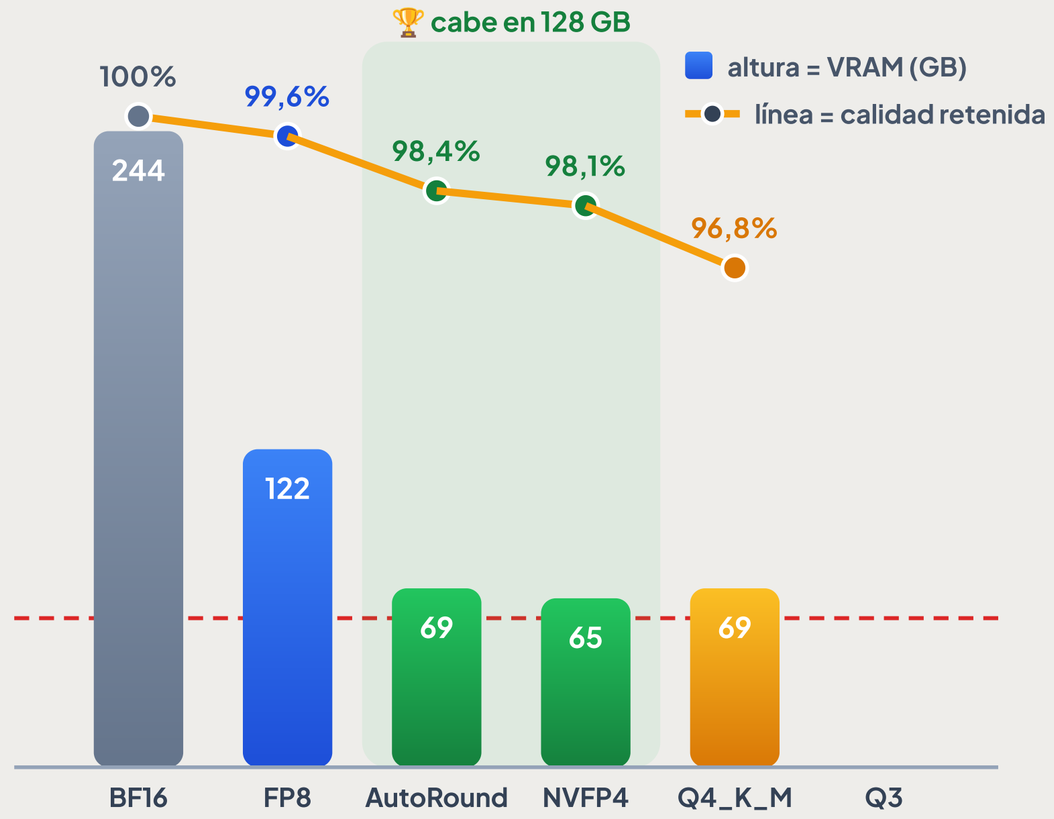


FP8: solo datacenter · INT4/NVFP4: el punto dulce de 128 GB · Q3: rompe el código

### 1. 💎 FP8 — el clon exacto

99,6% de calidad · 122 GB: impecable, pero solo vive en un datacenter.

### 2. 🌟 INT4 / NVFP4 — el punto dulce de 128 GB

AutoRound 98,4% · NVFP4 98,1% · 65–69 GB (3,5× más ligero): cabe en 128 con aire para la KV.

### 3. ⚙️ Q4 GGUF — el estándar local

96,8% · 69 GB · el formato de Ollama/Mac: −3,3% en código.

PRECISIÓN & BENCHMARKS • QWEN 122B MOE

# El Peaje de Comprimir: ¿Cuánta Inteligencia se Pierde?

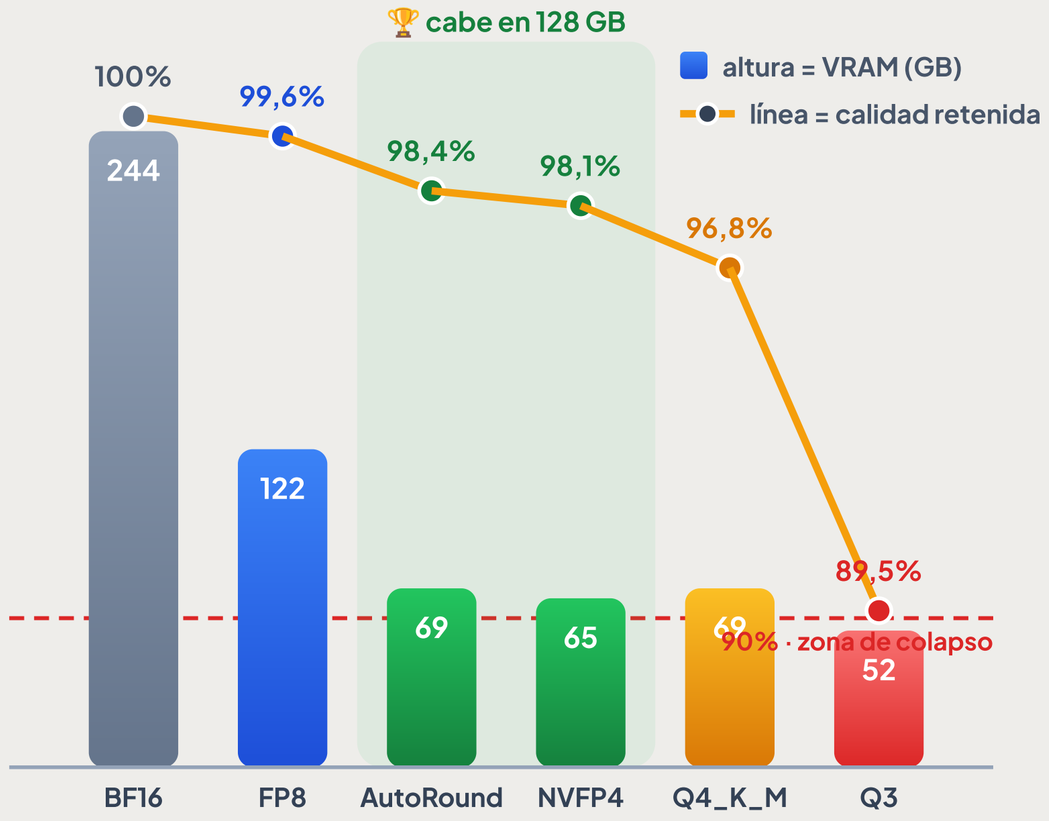


FP8: solo datacenter · INT4/NVFP4: el punto dulce de 128 GB · Q3: rompe el código

### 1. 💎 FP8 — el clon exacto

99,6% de calidad · 122 GB: impecable, pero solo vive en un datacenter.

### 2. 🌟 INT4 / NVFP4 — el punto dulce de 128 GB

AutoRound 98,4% · NVFP4 98,1% · 65–69 GB (3,5× más ligero): cabe en 128 con aire para la KV.

### 3. ⚙️ Q4 GGUF — el estándar local

96,8% · 69 GB · el formato de Ollama/Mac: –3,3% en código.

### 4. ⚠️ Q3 — la zona roja

<90% · 52 GB · colapso: paréntesis sin cerrar, imports inventados, bucles infinitos.

# La Trampa del Benchmark: El Efecto Dominó

💡 **Un acierto suelto vs. 50 pasos encadenados**

## 🎯 Benchmark estático · 1 token

**Pregunta MMLU**
elige A / B / C / D

→ **Modelo**
1 decisión puntual

→ **B ✓**

**89,5% ✓**

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

## 💥 Razonamiento real · thinking 5.000 tokens

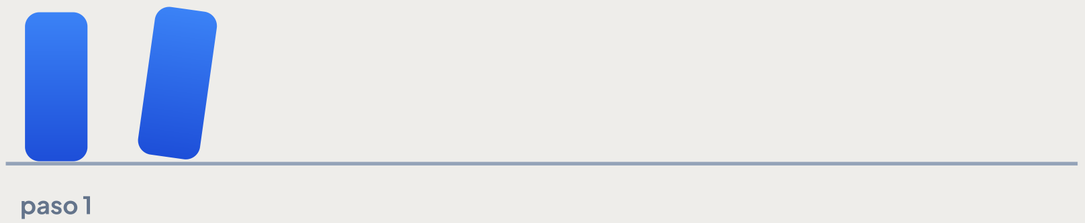

paso 1

# La Trampa del Benchmark: El Efecto Dominó

💡 **Un acierto suelto vs. 50 pasos encadenados**

## 🎯 Benchmark estático · 1 token

**Pregunta MMLU**
elige A / B / C / D

→ **Modelo**
1 decisión puntual

→ **B ✓**

**89,5% ✓**

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

## 💥 Razonamiento real · thinking 5.000 tokens

el error se acumula paso a paso →

# La Trampa del Benchmark: El Efecto Dominó

💡 **Un acierto suelto vs. 50 pasos encadenados**

## 🎯 Benchmark estático · 1 token

**Pregunta MMLU**
elige A / B / C / D

→ **Modelo**
1 decisión puntual

→ **B ✓**

**89,5% ✓**

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

## 💥 Razonamiento real · thinking 5.000 tokens

el error se acumula paso a paso →

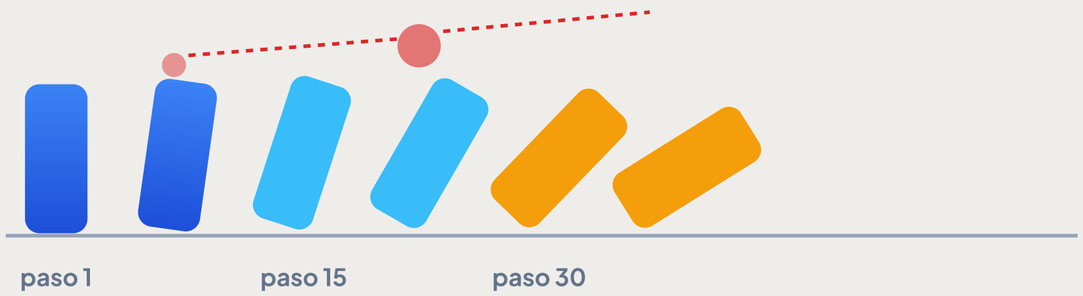

# La Trampa del Benchmark: El Efecto Dominó

💡 **Un acierto suelto vs. 50 pasos encadenados**

$(0{,}98)^{50} \approx 36\%$

## 🎯 Benchmark estático · 1 token

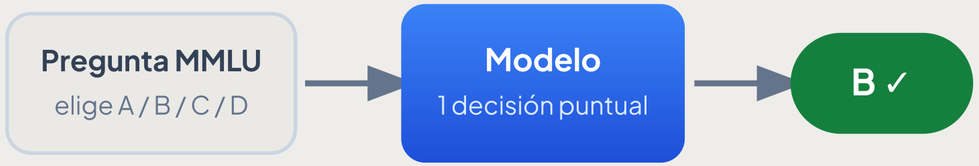


**89,5% ✓**

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

## 💥 Razonamiento real · thinking 5.000 tokens

el error se acumula paso a paso →

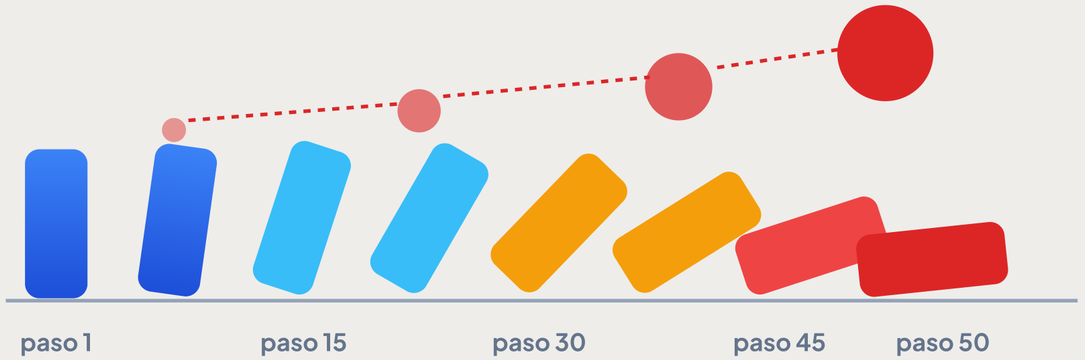


cada paso hereda el error del anterior → al paso 50 pierde el hilo

**≈ 36%**

# La Trampa del Benchmark: El Efecto Dominó

## 💡 Un acierto suelto vs. 50 pasos encadenados

$(0{,}98)^{50} \approx 36\%$

### 🎯 Benchmark estático · 1 token

**Pregunta MMLU**
elige A / B / C / D

→ **Modelo**
1 decisión puntual

→ **B ✓**

**89,5% ✓**

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

### 💥 Razonamiento real · thinking 5.000 tokens

el error se acumula paso a paso →

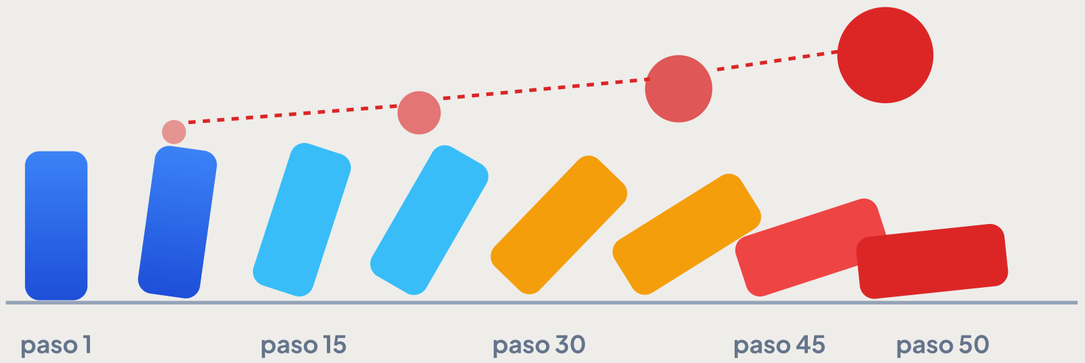


cada paso hereda el error del anterior → al paso 50 pierde el hilo

**≈ 36%**

### 🔴 Modelos de Razonamiento

CRÍTICA

**DeepSeek R1, Qwen-Thinking:** se desorientan con facilidad a menos de 4 bits; entran en bucle y no cierran la etiqueta `</think>`.

# La Trampa del Benchmark: El Efecto Dominó

## 💡 Un acierto suelto vs. 50 pasos encadenados

$(0{,}98)^{50} \approx 36\%$

### 🎯 Benchmark estático · 1 token

**Pregunta MMLU**
elige A / B / C / D

→ **Modelo**
1 decisión puntual

→ **B ✓**

**89,5% ✓**

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

### 💥 Razonamiento real · thinking 5.000 tokens

el error se acumula paso a paso →

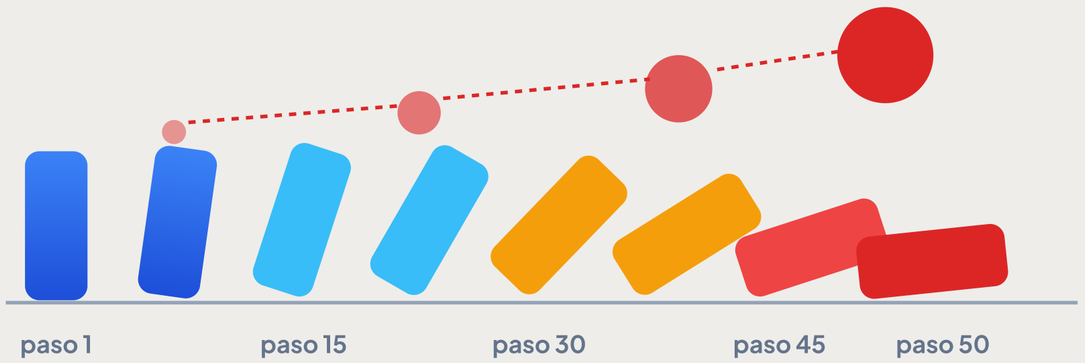


cada paso hereda el error del anterior → al paso 50 pierde el hilo

**≈ 36%**

### 🔴 Modelos de Razonamiento — CRÍTICA

**DeepSeek R1, Qwen-Thinking:** se desorientan con facilidad a menos de 4 bits; entran en bucle y no cierran la etiqueta `</think>`.

### 🟠 Modelos Pequeños (<9B) — ALTA

**Poca redundancia:** cada sinapsis cuenta. Cuantizar a 4-bit les hace perder mucha más lógica proporcional que a un modelo grande.

# La Trampa del Benchmark: El Efecto Dominó

## 💡 Un acierto suelto vs. 50 pasos encadenados

$(0{,}98)^{50} \approx 36\%$

### 🎯 Benchmark estático · 1 token

**Pregunta MMLU**
elige A / B / C / D

→ **Modelo**
1 decisión puntual

→ **B ✓**

**89,5% ✓**

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

### 💥 Razonamiento real · thinking 5.000 tokens

el error se acumula paso a paso →

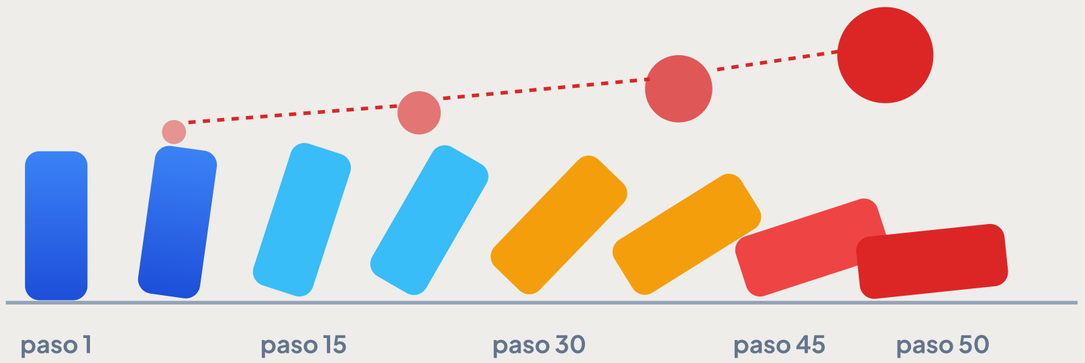


cada paso hereda el error del anterior → al paso 50 pierde el hilo

**≈ 36%**

### 🔴 Modelos de Razonamiento — CRÍTICA

**DeepSeek R1, Qwen-Thinking:** se desorientan con facilidad a menos de 4 bits; entran en bucle y no cierran la etiqueta `</think>`.

### 🟠 Modelos Pequeños (<9B) — ALTA

**Poca redundancia:** cada sinapsis cuenta. Cuantizar a 4-bit les hace perder mucha más lógica proporcional que a un modelo grande.

### 🟢 Modelos MoE / Grandes (122B) — RESISTENTE

**Alta masa crítica:** con *AutoRound INT4* o *NVFP4* absorben el ruido y mantienen la coherencia en agentes complejos.

RAZONAMIENTO & THINKING MODELS • COMPENSACIÓN DE ERROR

# El Equilibrista de la Inferencia: Compensación Activa de Pesos

🎪 Metáfora Visual · Cuerda Floja

DeepSeek R1 / Qwen Thinking

🚶 **Inspector Gadget:** El modelo avanzando a ciegas a lo largo de 50 pasos de razonamiento encadenado.

🐶 **Sultán (Compensación):** Coloca el plato justo bajo cada pisada, equilibrando los pesos para que no caiga al vacío.

## ⚖️ Sistemas de Compensación Activa de Pesos

INFERENCIA · DE PTQ A QAD

| SISTEMA | TIPO | MECANISMO DE COMPENSACIÓN | COSTE CÓMPUTO | HARDWARE / SOPORTE |
|---|---|---|---|---|
| **QAD** NVIDIA | Destilación | Teacher BF16 guía Student W4 | Medio (horas GPU) | Blackwell / TensorRT / vLLM |
| **AutoRound** Intel | PTQ Sign-SGD | Pares contiguos anulan error neto | Mínimo (10–30 min) | Universal (GGUF, AWQ, vLLM) |
| **ResComp** GPTAQ | PTQ Hessiano | Peso a peso vs salida FP16 virgen | Bajo (1–2 horas) | Universal |
| **SpinQuant** Meta | PTQ Rotación | Dispersión de outliers | Mínimo (minutos) | TensorRT-LLM / vLLM |
| **EfficientQAT** | QAT Modular | Block-AP (VRAM) + tuning step-size | Alto (horas en 1 GPU) | Universal |
| **QAT Clásico** | Re-entrenamiento | Red completa con forward simulado (STE) | Extremo (días clúster) | Específico del framework |
| GSQ + RCO ISTA ✨ 2-3 bits | Gumbel + Manifold | Optimización suave & variedad Riemanniana | Medio (1 GPU · <2h) | GGUF / ExLlamaV2 (35B en 16GB · 122B en 24GB) |

💡 **La clave práctica:** Para 4 bits (NVFP4), **AutoRound** y **QAD** garantizan máxima fidelidad sin deriva. Para romper el abismo de **2–3 bits**, la frontera de 2026 es **GSQ + RCO**.

RAZONAMIENTO & THINKING MODELS • COMPENSACIÓN DE ERROR

# El Equilibrista de la Inferencia: Compensación Activa de Pesos

🎪 Metáfora Visual · Cuerda Floja

DeepSeek R1 / Qwen Thinking

🚶 **Inspector Gadget:** El modelo avanzando a ciegas a lo largo de 50 pasos de razonamiento encadenado.

🐶 **Sultán (Compensación):** Coloca el plato justo bajo cada pisada, equilibrando los pesos para que no caiga al vacío.

## ⚖️ Sistemas de Compensación Activa de Pesos

INFERENCIA · DE PTQ A QAD

| SISTEMA | TIPO | MECANISMO DE COMPENSACIÓN | COSTE CÓMPUTO | HARDWARE / SOPORTE |
|---|---|---|---|---|
| **QAD** NVIDIA | Destilación | Teacher BF16 guía Student W4 | Medio (horas GPU) | Blackwell / TensorRT / vLLM |
| **AutoRound** Intel | PTQ Sign-SGD | Pares contiguos anulan error neto | Mínimo (10–30 min) | Universal (GGUF, AWQ, vLLM) |
| **ResComp** GPTAQ | PTQ Hessiano | Peso a peso vs salida FP16 virgen | Bajo (1–2 horas) | Universal |
| **SpinQuant** Meta | PTQ Rotación | Dispersión de outliers | Mínimo (minutos) | TensorRT-LLM / vLLM |
| **EfficientQAT** | QAT Modular | Block-AP (VRAM) + tuning step-size | Alto (horas en 1 GPU) | Universal |
| **QAT Clásico** | Re-entrenamiento | Red completa con forward simulado (STE) | Extremo (días clúster) | Específico del framework |
| **GSQ + RCO** ISTA ✨ 2-3 bits | Gumbel + Manifold | Optimización suave & variedad Riemanniana | Medio (1 GPU · <2h) | GGUF / ExLlamaV2 (35B en 16GB · 122B en 24GB) |

💡 **La clave práctica:** Para 4 bits (NVFP4), **AutoRound** y **QAD** garantizan máxima fidelidad sin deriva. Para romper el abismo de **2–3 bits**, la frontera de 2026 es **GSQ + RCO**.

ARQUITECTURA HÍBRIDA • FÍSICA DE LA MEMORIA

# DeltaNet vs. Attention: El Secreto de la Memoria Estable

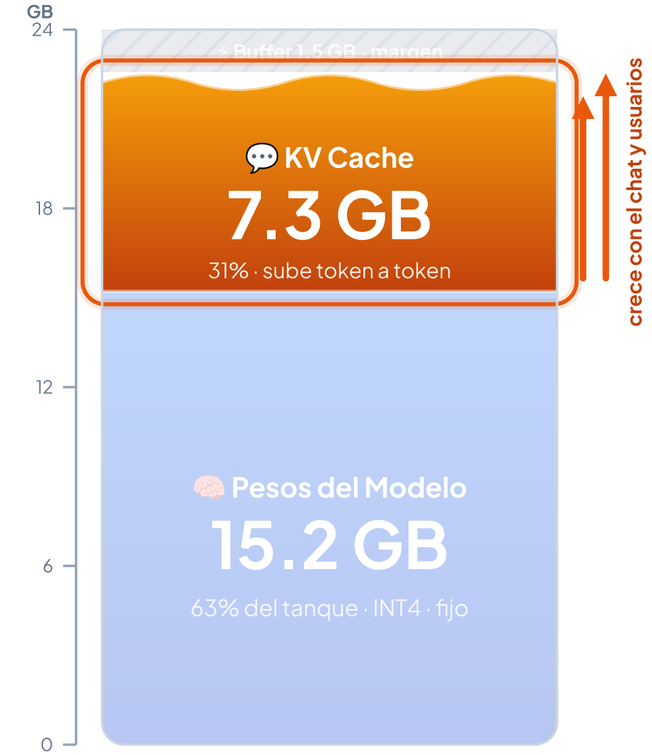

🧵 **El artesano de la KV Cache:** cada hilo luminoso es un intercambio de la conversación; los guarda todos, ordenados, para poder volver a cualquiera de ellos. Cuantos más hilos, más estantería: ¿cuánto aguanta la VRAM?

ARQUITECTURA HÍBRIDA • FÍSICA DE LA MEMORIA

# DeltaNet vs. Attention: El Secreto de la Memoria Estable

## Anatomía del Bloque Repetitivo 3:1

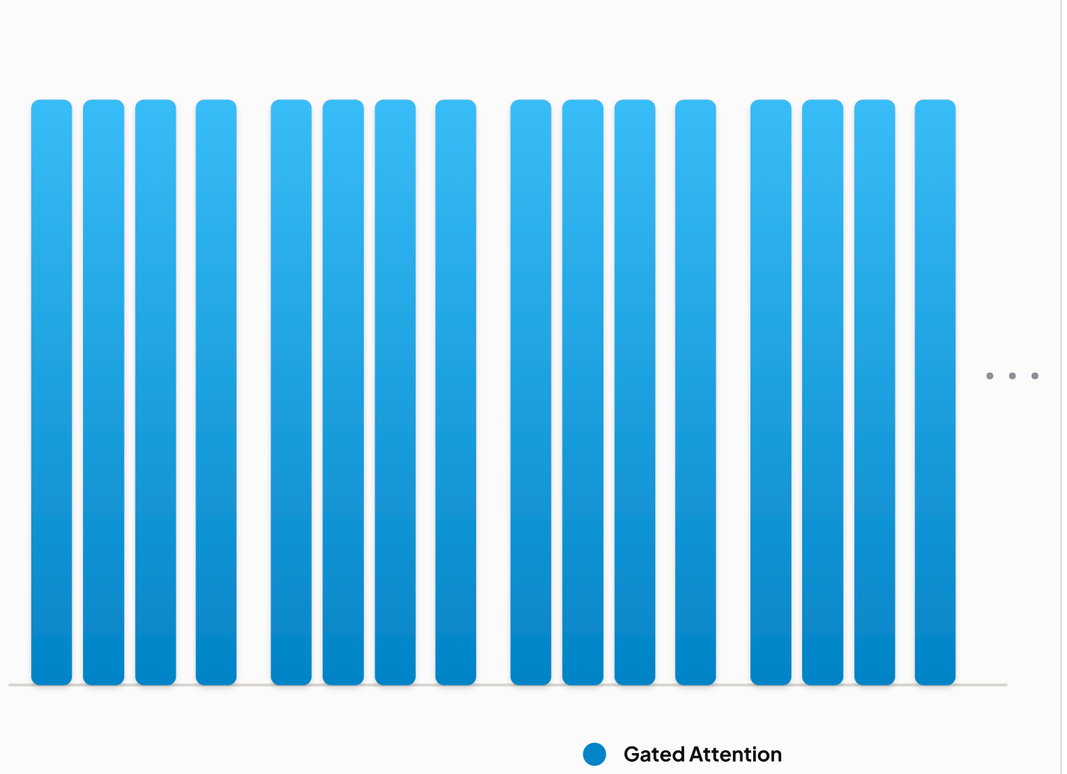


## Curva de VRAM: Memoria Fija O(1) vs. Crecimiento O(N)

Escala 0 → 256K Tokens

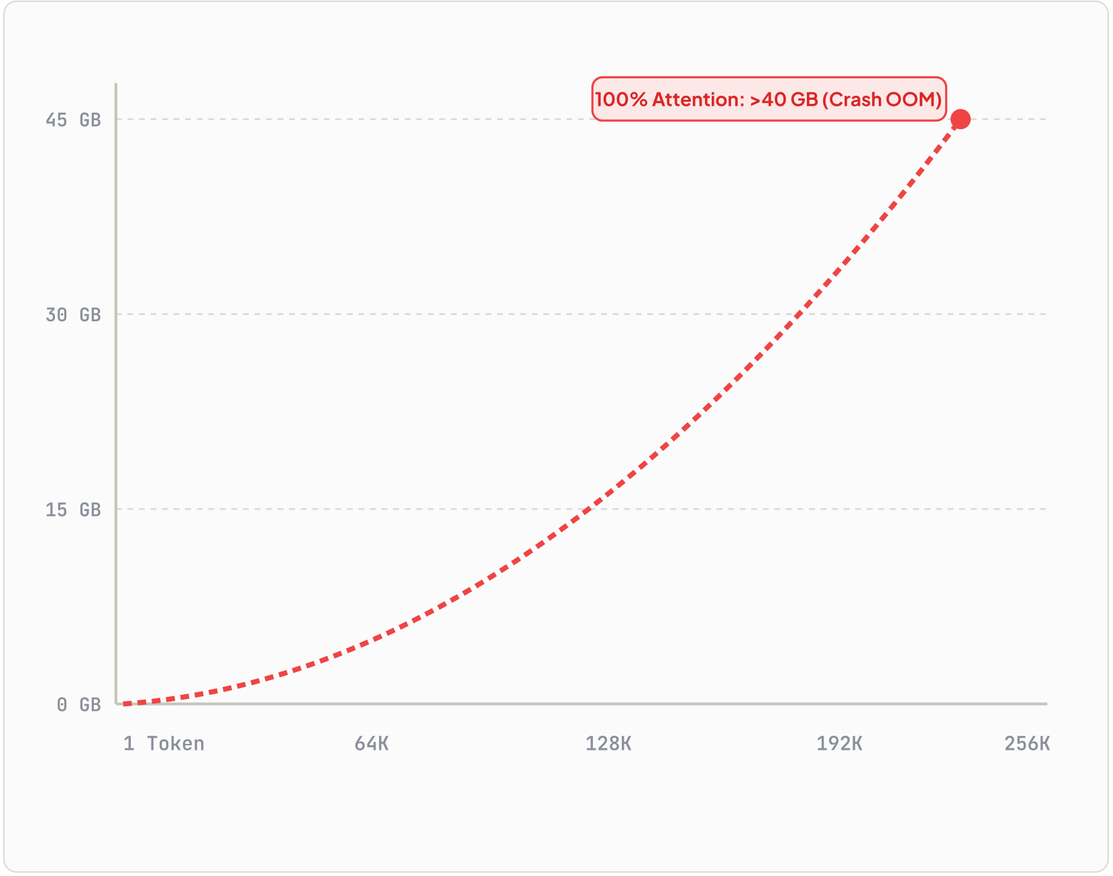

ARQUITECTURA HÍBRIDA • FÍSICA DE LA MEMORIA

# DeltaNet vs. Attention: El Secreto de la Memoria Estable

## Anatomía del Bloque Repetitivo 3:1

3 DeltaNet + 1 Attention

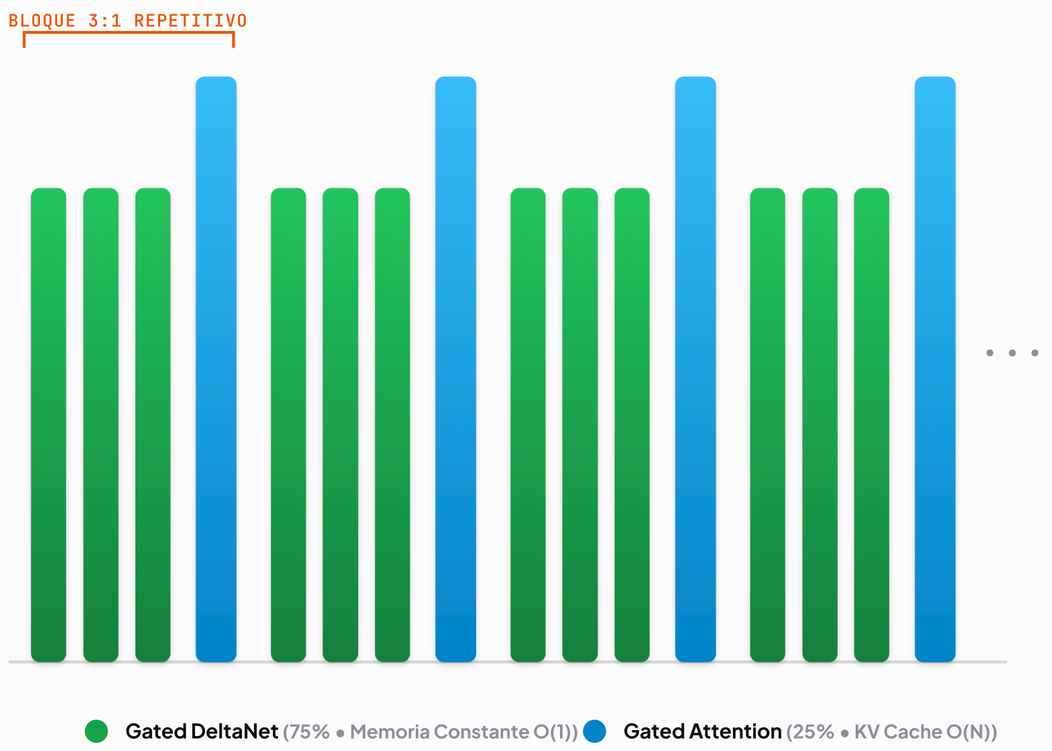


## Curva de VRAM: Memoria Fija O(1) vs. Crecimiento O(N)

Escala 0 → 256K Tokens

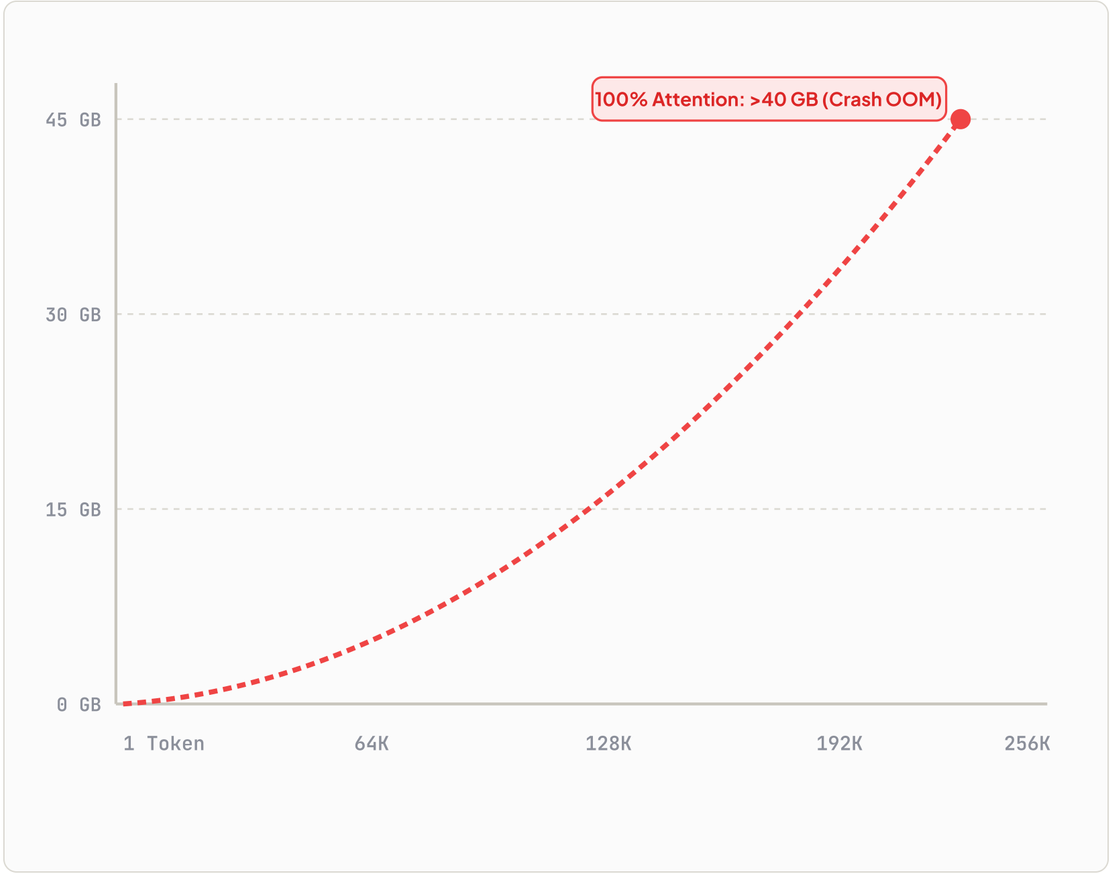

ARQUITECTURA HÍBRIDA • FÍSICA DE LA MEMORIA

# DeltaNet vs. Attention: El Secreto de la Memoria Estable

## Anatomía del Bloque Repetitivo 3:1

3 DeltaNet + 1 Attention

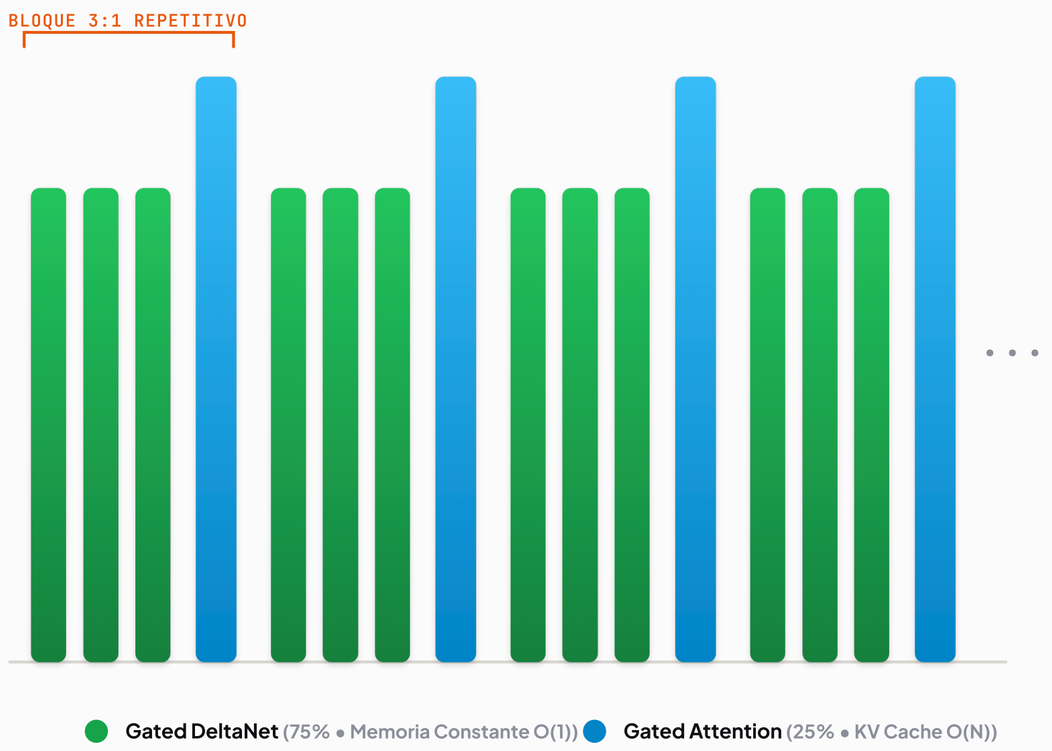


## Curva de VRAM: Memoria Fija O(1) vs. Crecimiento O(N)

Escala 0 → 256K Tokens

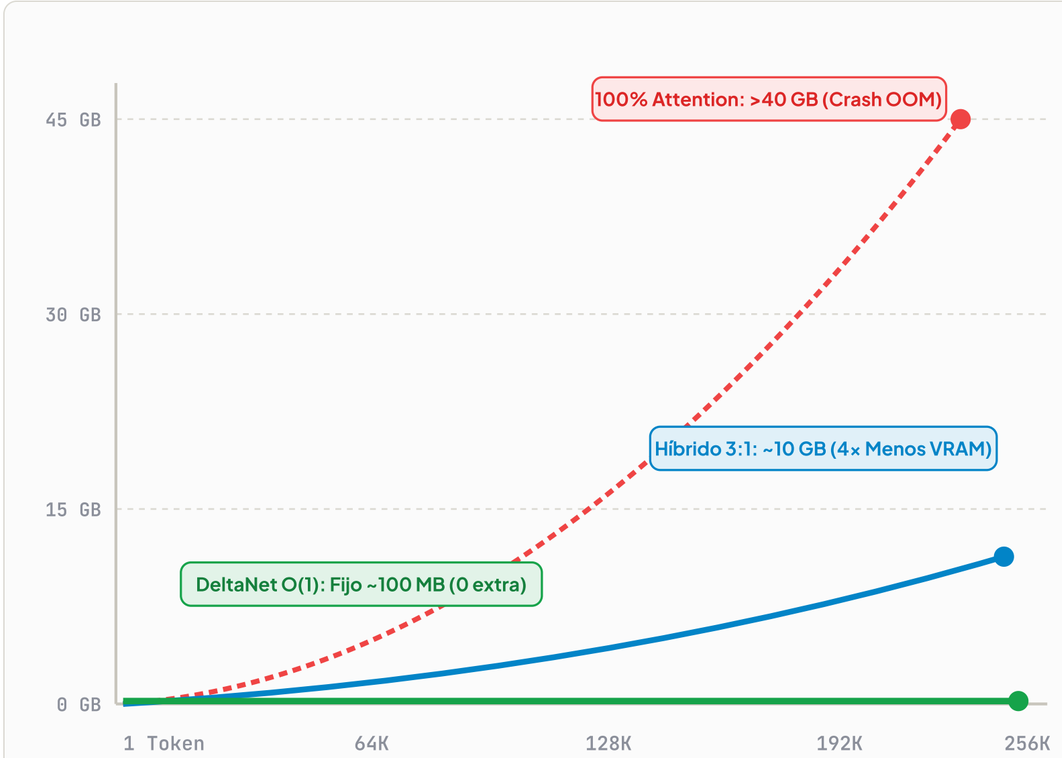


**El Resultado Práctico (Reducción 4× en KV Cache):** Al reservar el almacenamiento de tokens solo para el **25% de las capas**, un contexto masivo de 256.000 tokens consume **~10 GB de VRAM** en lugar de los >40 GB de un Transformer convencional, dejando espacio holgado en los 128 GB del equipo.

4X MENOS MEMORIA

# La Velocidad es Memoria: el Viaje del Token

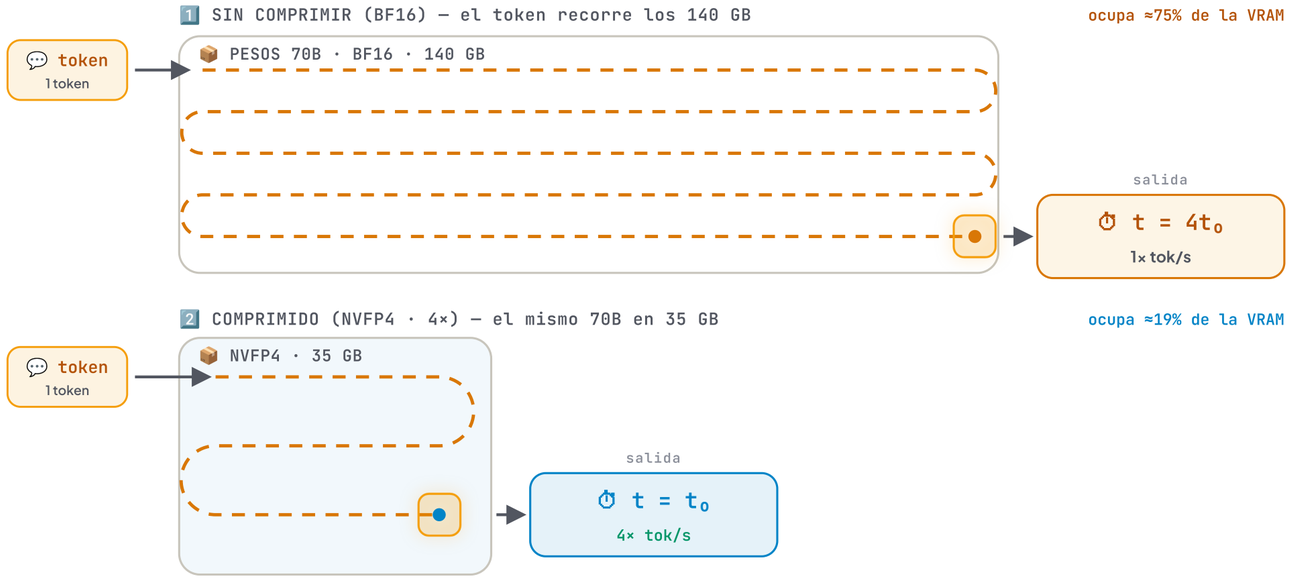


🏁 4× MENOS DISTANCIA = 4× MÁS TOK/S

tok/s ≈ ancho de banda ÷ GB leídos por token

comprimir pesos (FP8 · INT4 · NVFP4) = la palanca nº1 en local

🚀 El Viaje del Token — de la VRAM a la Salida

## 🧵 El Token Lee Todos los Pesos

BW-BOUND

Para generar **una sola palabra**, la GPU lee de VRAM los GB del modelo entero. El viaje del token es la factura de ancho de banda: **modelo grande = viaje largo = menos tok/s**.

## 🗜️ NVFP4: 4× Menos Distancia

4× TOK/S

El mismo 70B: **140 GB en BF16 → 35 GB en NVFP4**. Mismo ancho de banda y 1/4 de lectura: el viaje pasa de $4t_0$ a $t_0$. **Cuatro veces más tokens por segundo**.

## ⚡ La Palanca Nº1 en Local

TOK/S ≈ BW ÷ GB

Sin cambiar de GPU: **FP8, INT4 o NVFP4 acortan el viaje** del token y liberan VRAM para contexto largo. **Cuantizar es ganar velocidad** con la misma sabiduría.

ARQUITECTURA DE MODELOS • DENSOS — PANEL VISUAL

# Modelos Densos: Una Petición Enciende las 48 Luces

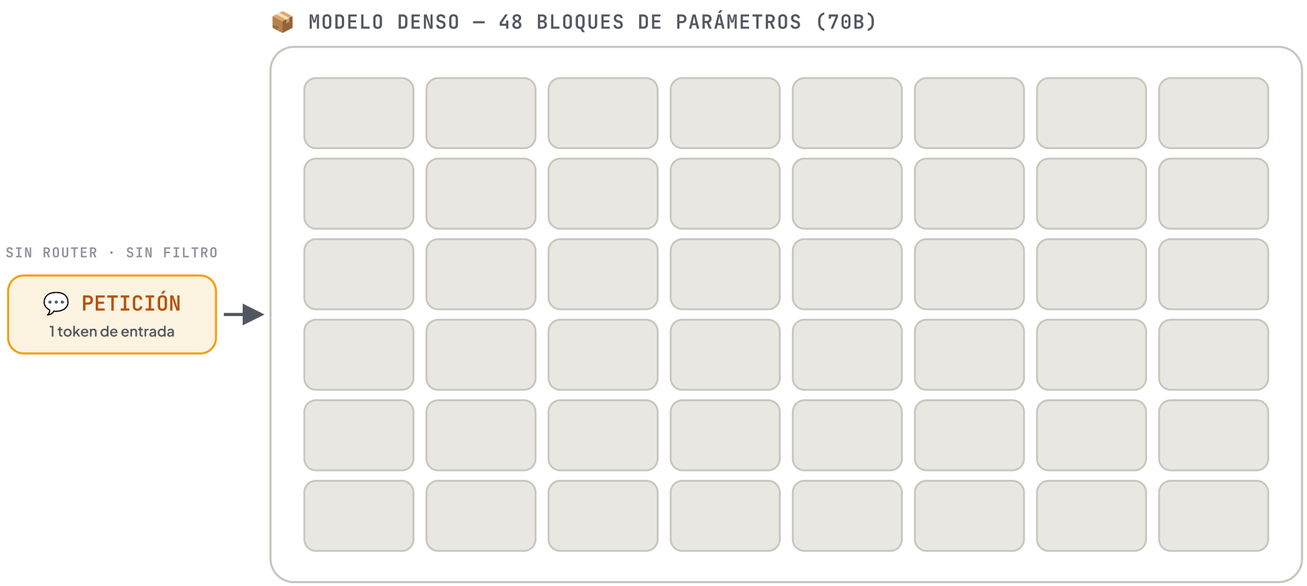


🟠 Modelo Denso — Panel de 48 Bloques

## 🟠 Sin Gatekeeper: se Encienden Todas

48/48 · 100%

La petición entra y **no existe filtro previo**: los 48 bloques que forman el modelo participan en el cálculo de esa palabra. Es la junta médica completa de la slide siguiente, vista como un panel eléctrico.

## ⚡ El Peaje: Fuerza Bruta Constante

70B OPS/TOKEN

La GPU **multiplica los 70B parámetros en cada token**, aunque la pregunta sea trivial. VRAM llena, calor y consumo al máximo: el precio de la consistencia total.

## 🧱 Cuándo Brillan los Densos

8B–32B LOCALES

**LLaMA 3 y Qwen densos**: predecibles, robustos y perfectos para fine-tuning especializado. En tamaños pequeños y medianos siguen siendo la opción sólida por defecto.

# Modelos Densos: Una Petición Enciende las 48 Luces

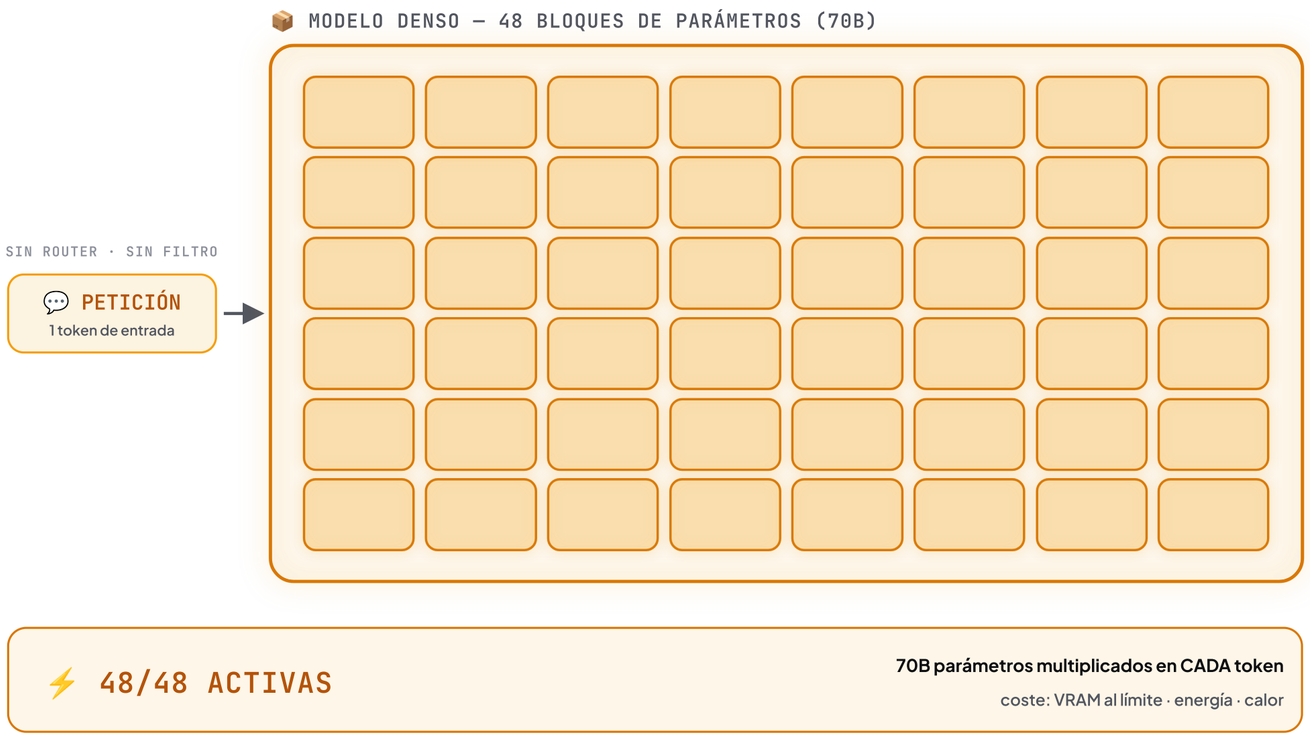


## 🟠 Sin Gatekeeper: se Encienden Todas

48/48 · 100%

La petición entra y **no existe filtro previo**: los 48 bloques que forman el modelo participan en el cálculo de esa palabra. Es la junta médica completa de la slide siguiente, vista como un panel eléctrico.

## ⚡ El Peaje: Fuerza Bruta Constante

70B OPS/TOKEN

La GPU **multiplica los 70B parámetros en cada token**, aunque la pregunta sea trivial. VRAM llena, calor y consumo al máximo: el precio de la consistencia total.

## 🧱 Cuándo Brillan los Densos

8B–32B LOCALES

**LLaMA 3 y Qwen densos**: predecibles, robustos y perfectos para fine-tuning especializado. En tamaños pequeños y medianos siguen siendo la opción sólida por defecto.

ARQUITECTURA DE MODELOS • DENSOS (100% ACTIVO)

# Modelos Densos: La Junta Médica Completa

🏥 Modelo Denso (100% Personal Activo) — Todo el hospital paralizado

## 🩺 La Analogía Hospitalaria

100% PARÁMETROS

Entras a la consulta por un simple dolor de cabeza y **se convoca a todo el cuadro médico del centro** (neurocirugía, cardiología, traumatología...) para deliberar conjuntamente sobre cada palabra.

## ⚡ El Peaje en Silicio

FUERZA BRUTA

La GPU no puede discriminar: debe **cargar y multiplicar cada parámetro del modelo** en cada token generado. Si el modelo es de 70B, calcula 70B de operaciones por letra.

## 📌 Ejemplos en Producción

CLÁSICOS

**LLaMA 3 (8B, 70B), Qwen 2.5 (27B, 72B):** Extremadamente sólidos y consistentes, pero **devoradores de energía, calor y memoria** en hardware local.

ARQUITECTURA DE MODELOS • MOE — PANEL VISUAL

# Modelos MoE: El Router Enciende solo 5 de 48 Luces

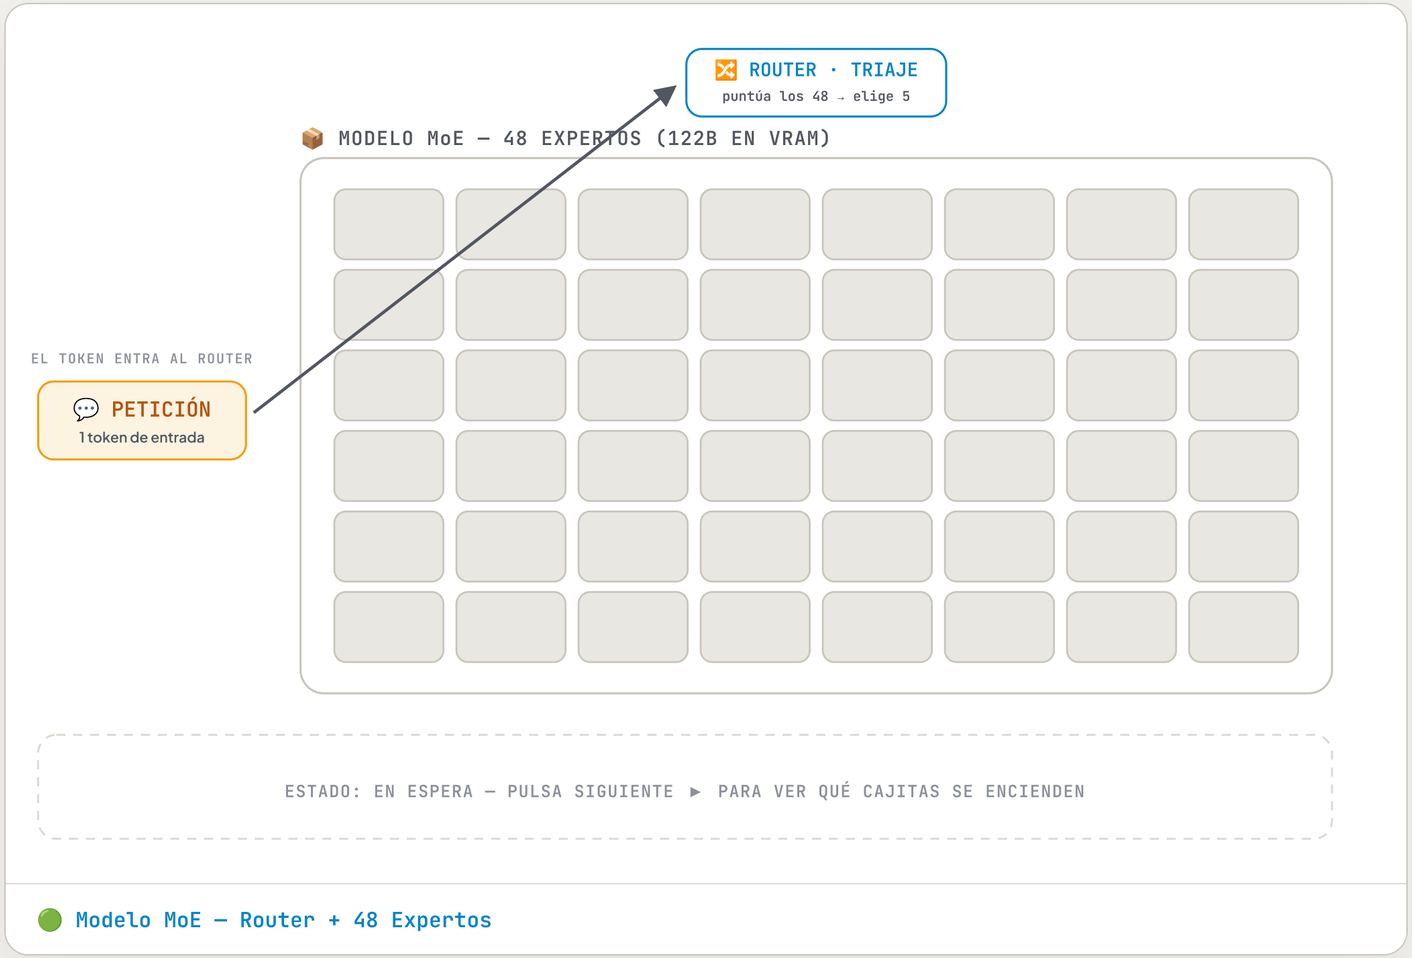


## 🎯 El Router Hace el Triaje

TOP-K = 5

Un **gatekeeper ultrarrápido puntúa a los 48 expertos** en milisegundos y despierta solo a los 5 más afines al token. Los otros 43 ni se inmutan: **su cálculo simplemente no ocurre**.

## 🚀 VRAM Llena, Cuenta Ligera

122B / 10B

En memoria guardas **la enciclopedia completa (122B)**, pero por token solo se mueve **~10B de cómputo**: velocidad relámpago y hueco libre para contexto largo en 128 GB.

## 🌟 El Estándar de la Nueva Era

QWEN · DEEPSEEK · MIXTRAL

**Qwen 3.5/3.8 MoE, DeepSeek V3/R1, Mixtral**: la frontera corre en estaciones locales. El panel con 5 luces encendidas de 48 es hoy la arquitectura dominante.

ARQUITECTURA DE MODELOS • MOE — PANEL VISUAL

# Modelos MoE: El Router Enciende solo 5 de 48 Luces

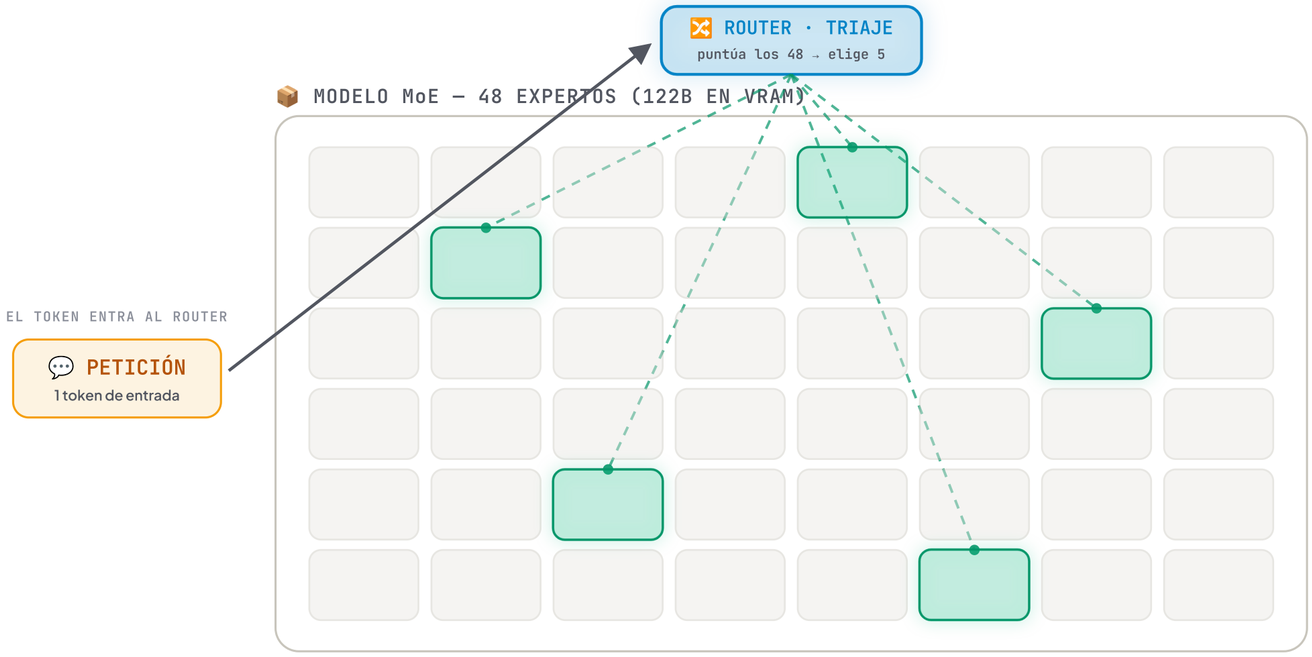


## 🎯 El Router Hace el Triaje

`TOP-K = 5`

Un **gatekeeper ultrarrápido puntúa a los 48 expertos** en milisegundos y despierta solo a los 5 más afines al token. Los otros 43 ni se inmutan: **su cálculo simplemente no ocurre**.

## 🚀 VRAM Llena, Cuenta Ligera

`122B / 10B`

En memoria guardas **la enciclopedia completa (122B)**, pero por token solo se mueve **~10B de cómputo**: velocidad relámpago y hueco libre para contexto largo en 128 GB.

## 🌟 El Estándar de la Nueva Era

`QWEN · DEEPSEEK · MIXTRAL`

**Qwen 3.5/3.8 MoE, DeepSeek V3/R1, Mixtral**: la frontera corre en estaciones locales. El panel con 5 luces encendidas de 48 es hoy la arquitectura dominante.

ARQUITECTURA DE MODELOS • MIXTURE OF EXPERTS (MOE)

# Modelos MoE: El Servicio de Triaje Inteligente

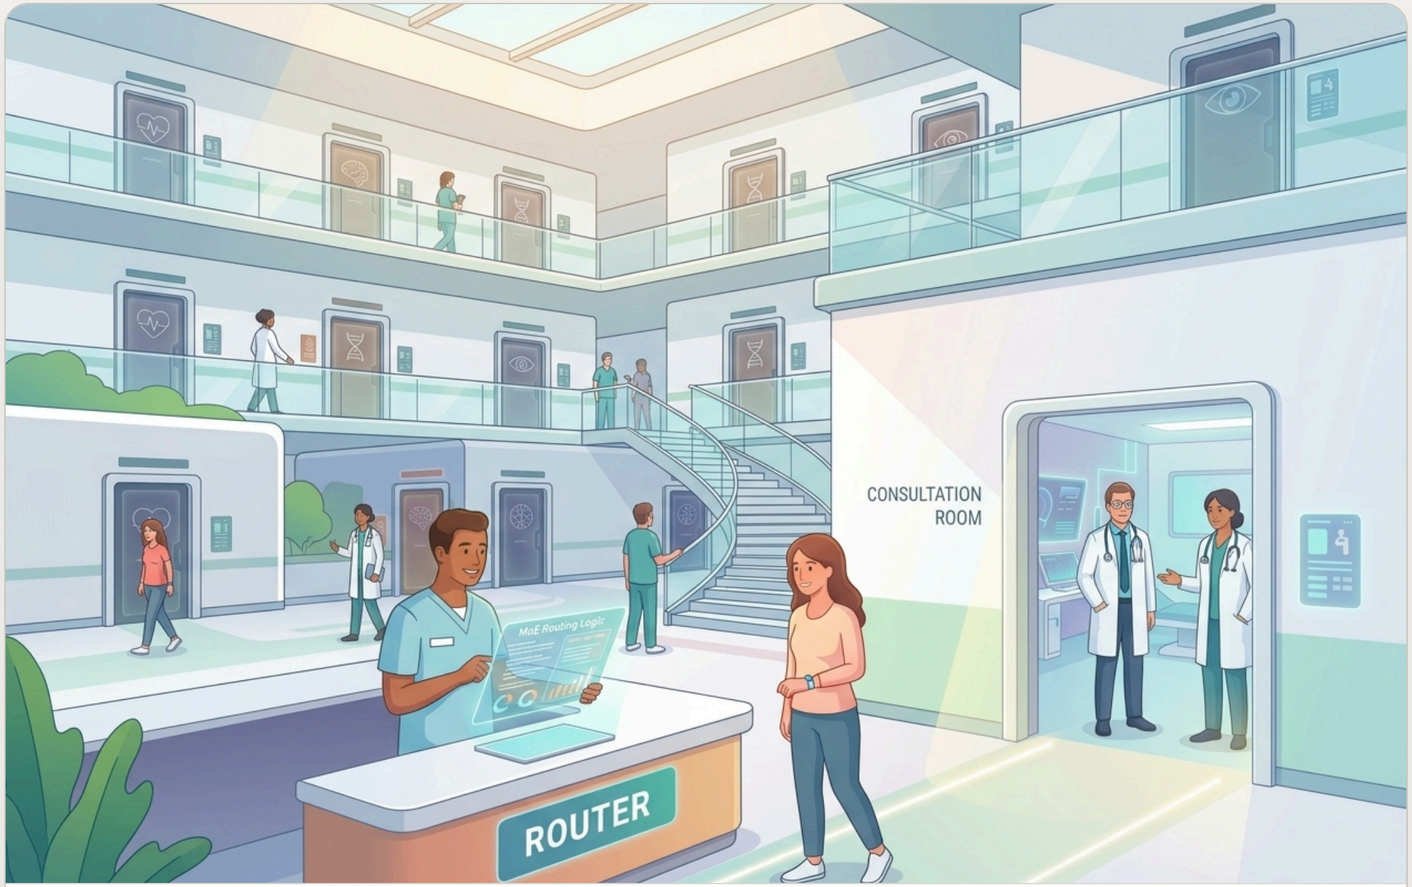


🩺 Modelo MoE (Servicio de Triaje / Router) — Solo 2 Especialistas Activos

## 🔀 El Servicio de Triaje (*Router*)

SPARSE / EFICIENTE

Un sistema de triaje ultra-rápido clasifica la consulta en un milisegundo y **deriva al paciente exclusivamente a los 2 especialistas necesarios**. El resto del hospital sigue atendiendo en paz.

## 🚀 La Magia de la Velocidad

122B TOTAL / 10B ACTIVO

En VRAM almacenas la sabiduría de **todo el hospital (122B)**, pero la GPU solo procesa **10B de cálculo activo** por token: velocidad relámpago con máxima inteligencia.

## 🌟 El Estándar Moderno

NUEVA ERA

**Qwen 3.5 (35B / 122B), DeepSeek V3 / R1, Mixtral:** Permiten correr modelos de frontera en estaciones de 128 GB dejando espacio holgado para el contexto.

RENDIMIENTO · DOS VELOCIDADES

# Prefill vs. Decode: la velocidad tiene dos perfiles

La analogía del corral: el prompt entra como un saco de pienso de golpe; la respuesta sale huevo a huevo.

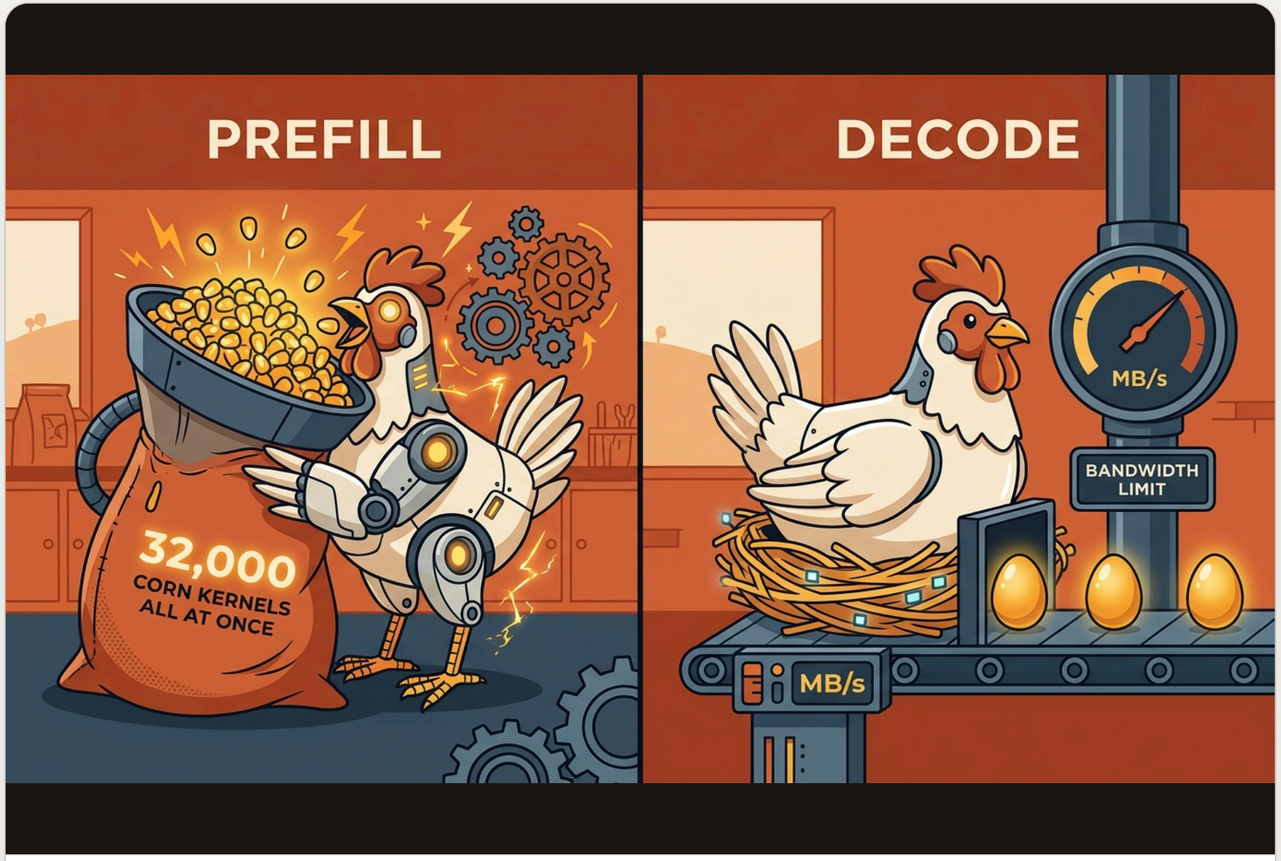


🌾 Prefill: Cómputo (FLOPs) 🥚 Decode: Ancho de banda (GB/s)

### 🌾 PREFILL

El Saco de Pienso · TTFT

Lee 32.000 tokens **en paralelo** de golpe para construir la atención y la KV Cache.

Cuello de botella: **fuerza bruta de cómputo (FLOPs)** — Tensor Cores FP4/FP8.

👑 NVIDIA Blackwell domina: **~7.600 tok/s en un 8B**

### 🥚 DECODE

Poner el Huevo · tok/s

Genera **token a token**: cada huevo exige leer los 40 GB enteros de los pesos en memoria.

Cuello de botella: **ancho de banda de memoria (GB/s)**.

👑 Apple Silicon domina: **546 GB/s → 1,2 TB/s**

`Ley del corral: velocidad máx. ≈ GB/s ÷ tamaño (GB)`

Modelo denso 70B en 4-bit (~40 GB): **273 GB/s → ~6,8 tok/s** · 1,2 TB/s → ~30

ECOSISTEMA & INFERENCIA ACELERADA

# 2026: Timeline de Modelos & Aceleración

Línea temporal de la revolución open-weights: lanzamientos de arquitecturas y evolución del *speculative decoding* (MTP ➔ DSpark ➔ DFlash ➔ DFlash 2).

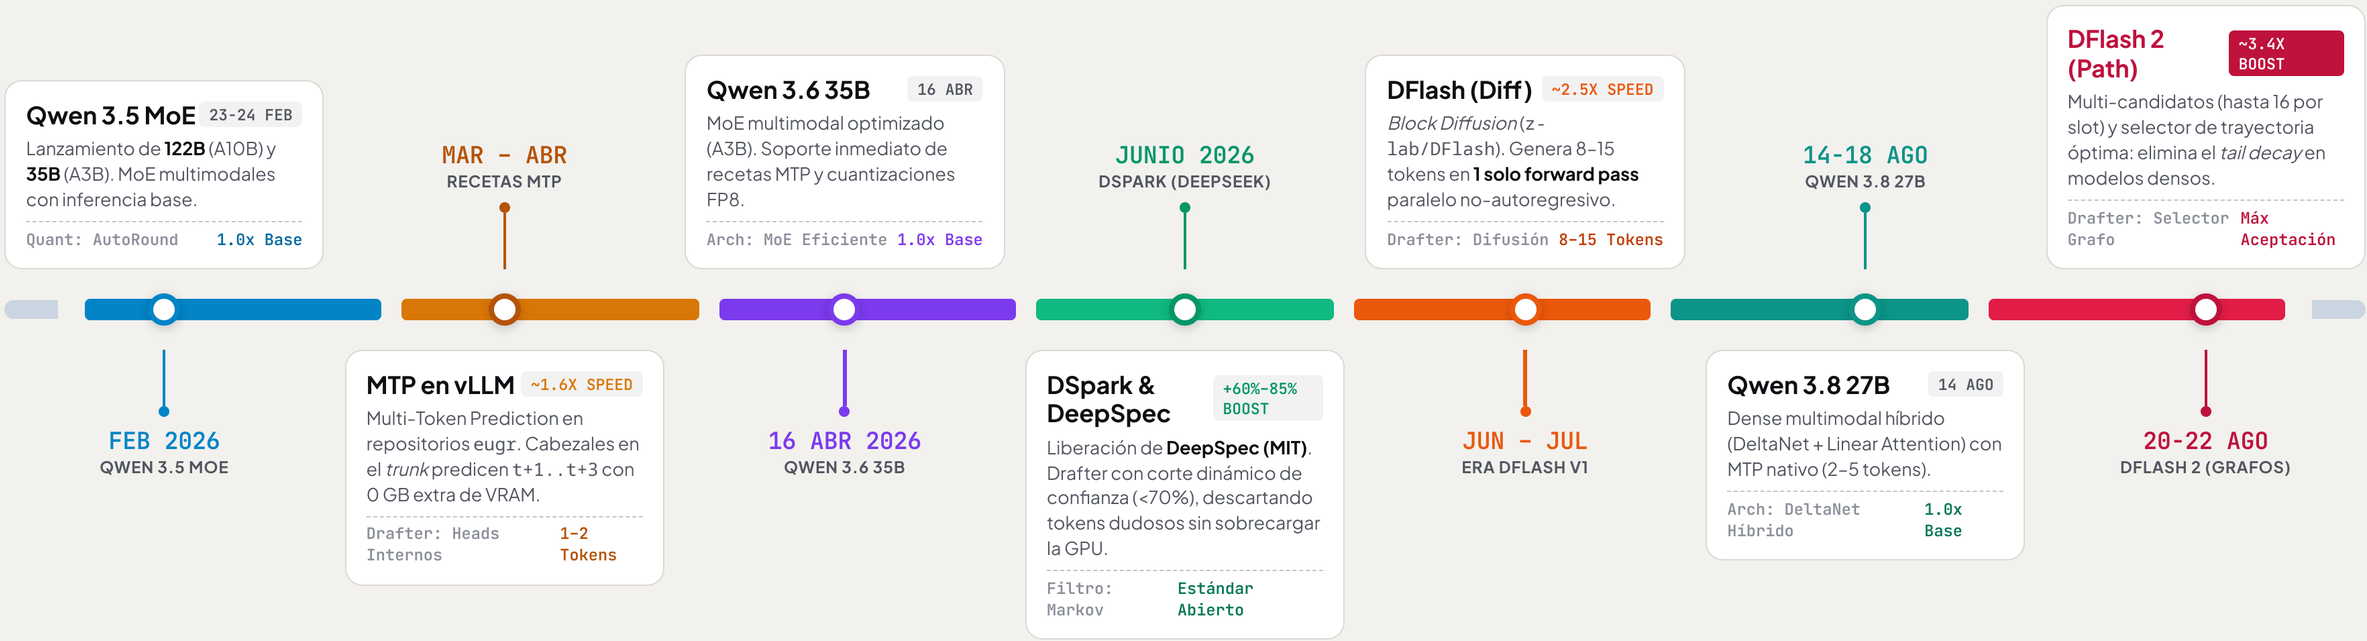

HARDWARE SIZING • FAMILIA QWEN (3.5 – 3.8)

# Matriz de Pesos: La Zona Ricitos de Oro

| MODELO | PARÁMETROS (TOT. / ACT.) | BF16 / FP16 | FP8 / Q8_0 | GGUF Q5_K_M | AWQ INT4 | INT4 AUTOROUND | NVFP4 (BLACKWELL) | TOK/SEG | CON MTP |
|---|---|---|---|---|---|---|---|---|---|
| Qwen 3.5 – 0.8B | 0.8B / 0.8B (Dense) | ~1.6 GB | ~0.8 GB | ~0.55 GB | ~0.48 GB | ~0.45 GB | *No optimizado* | – | – |
| Qwen 3.5 – 4B | 4B / 4B (Dense) | ~8.0 GB | ~4.0 GB | ~2.8 GB | ~2.4 GB | ~2.3 GB | *No optimizado* | – | – |
| Qwen 3.5 – 9B | 9B / 9B (Dense) | ~18.0 GB | ~9.0 GB | ~6.2 GB | ~5.3 GB | ~5.0 GB | *No optimizado* | – | – |
| Qwen 3.5 – 27B | 27B / 27B (Dense) | ~54.0 GB | ~27.0 GB | ~18.5 GB | ~15.5 GB | ~15.2 GB | ~14.5 GB | – | – |
| Qwen 3.6 – 27B | 27B / 27B (Dense) | ~54.0 GB | ~27.0 GB | ~18.5 GB | ~15.5 GB | ~15.2 GB | ~14.5 GB | 8 | 16 (×2) |
| ★ Qwen 3.8 – 27B MTP / DFlash | 27B / 27B (Dense) | **~53.0 GB** | **~28.0 GB** | **~19.0 GB** | **~21.0 GB** | **~21.0 GB** | **~22.0 GB** | 12 | 28 (×2.3) |
| ★ Qwen 3.6 – 35B | 35B / 3B (MoE) | **~70.0 GB** | **~35.0 GB** | **~24.0 GB** | **~20.2 GB** | **~19.8 GB** | **~18.5 GB** | 74 | 134 (×1.8) |
| ★ Qwen 3.8 Flash Next | 125B + 51B / 6B (MoE híbrido) | **~360.0 GB** | **~185.5 GB** | **~158.0 GB** | **~168.0 GB** | **~178.0 GB** | **~105.0 GB** | 24 | 38 (×1.6) |
| Qwen 3.5 – 122B | 122B / 10B (MoE) | **~244.0 GB** | **~122.0 GB** | **~84.0 GB** | **~71.5 GB** | **~69.0 GB** | **~65.0 GB** | 28 | 54 (×1.9) |
| Qwen 3.5 – 397B | 397B / 17B (MoE) | ~794.0 GB | ~397.0 GB | ~273.0 GB | ~231.0 GB | ~223.0 GB | ~210.0 GB | – | – |

**La "Zona Ricitos de Oro" (Goldilocks Zone)**
Ni demasiado pequeños (falta de razonamiento) ni inasumibles (>200 GB en GPU): **Qwen 3.8 27B, 35B MoE, 122B MoE y el híbrido Flash Next** (125B+51B: cabe entero en 128 GB) ofrecen la máxima velocidad e inteligencia dejando margen holgado para KV Cache en hardware de 128 GB.

Target: DGX Spark / GB10 (128 GB)

“

El hardware puede encarecerse.

**Los pesos, no.**

# Paradigma Cloud: API Token & Fuerza Bruta

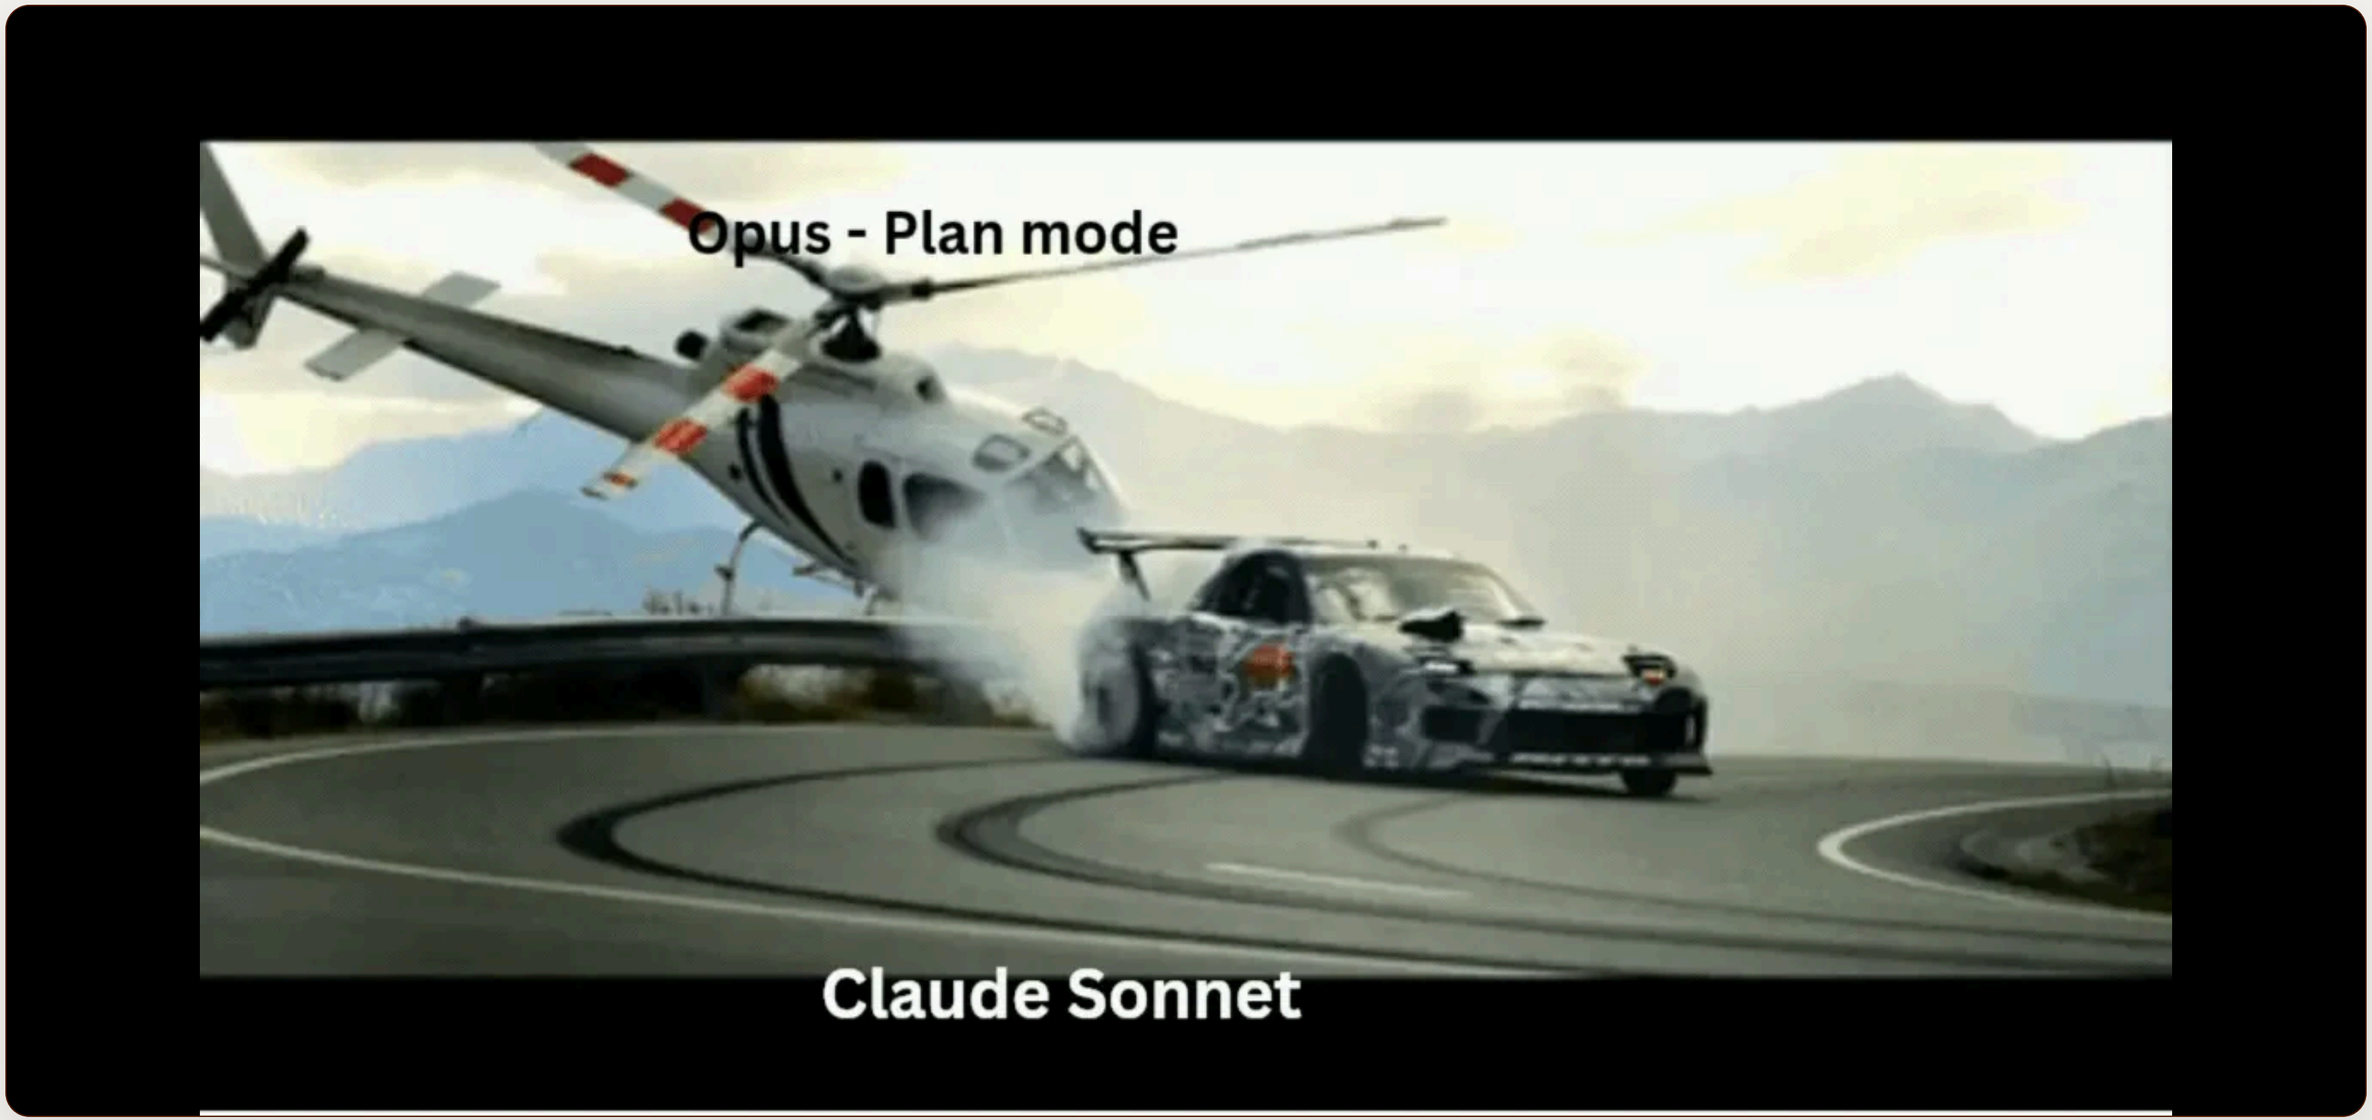

# Paradigma Local: Tracción, Control & Coste Cero

“

**Cuando te equivocas**,
con una **API**
tu enemigo es el **dinero**.
Con **IA local**,
tu enemigo es el **tiempo**.

# El Embudo del SDLC: Del Caos a la Certeza

Cada fase del SDLC es un filtro que reduce la entropía hasta lograr una solución determinista y verificada.

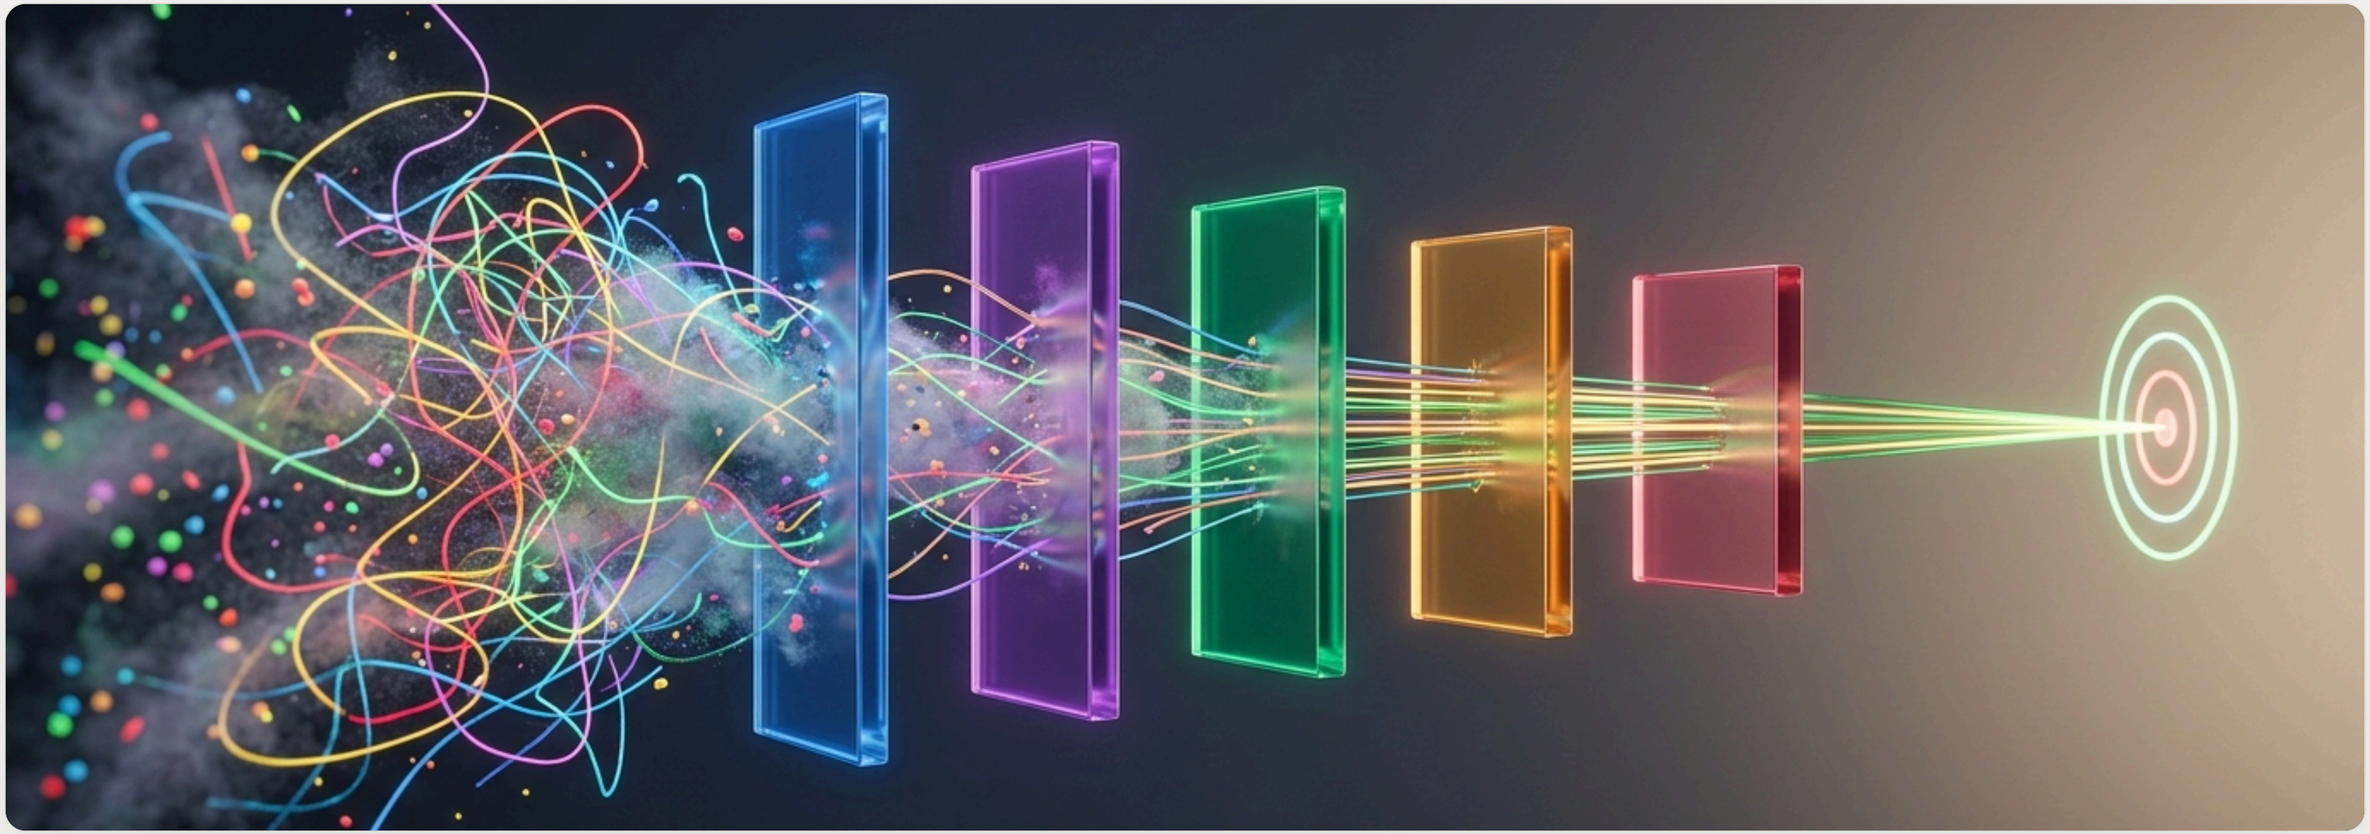

🌪️ ENTRADA **Prompting Libre**

~$10^6$ caminos posibles • Alucinación y alcance infinito.

🎯 SALIDA **Certeza Verificada**

1 único camino verificado • Tests en verde y cero drift.

FASE 2 • EL ESLABÓN DEL PRODUCT DEVELOPER

# El Product Developer: ¿qué hay entre él y la IA?

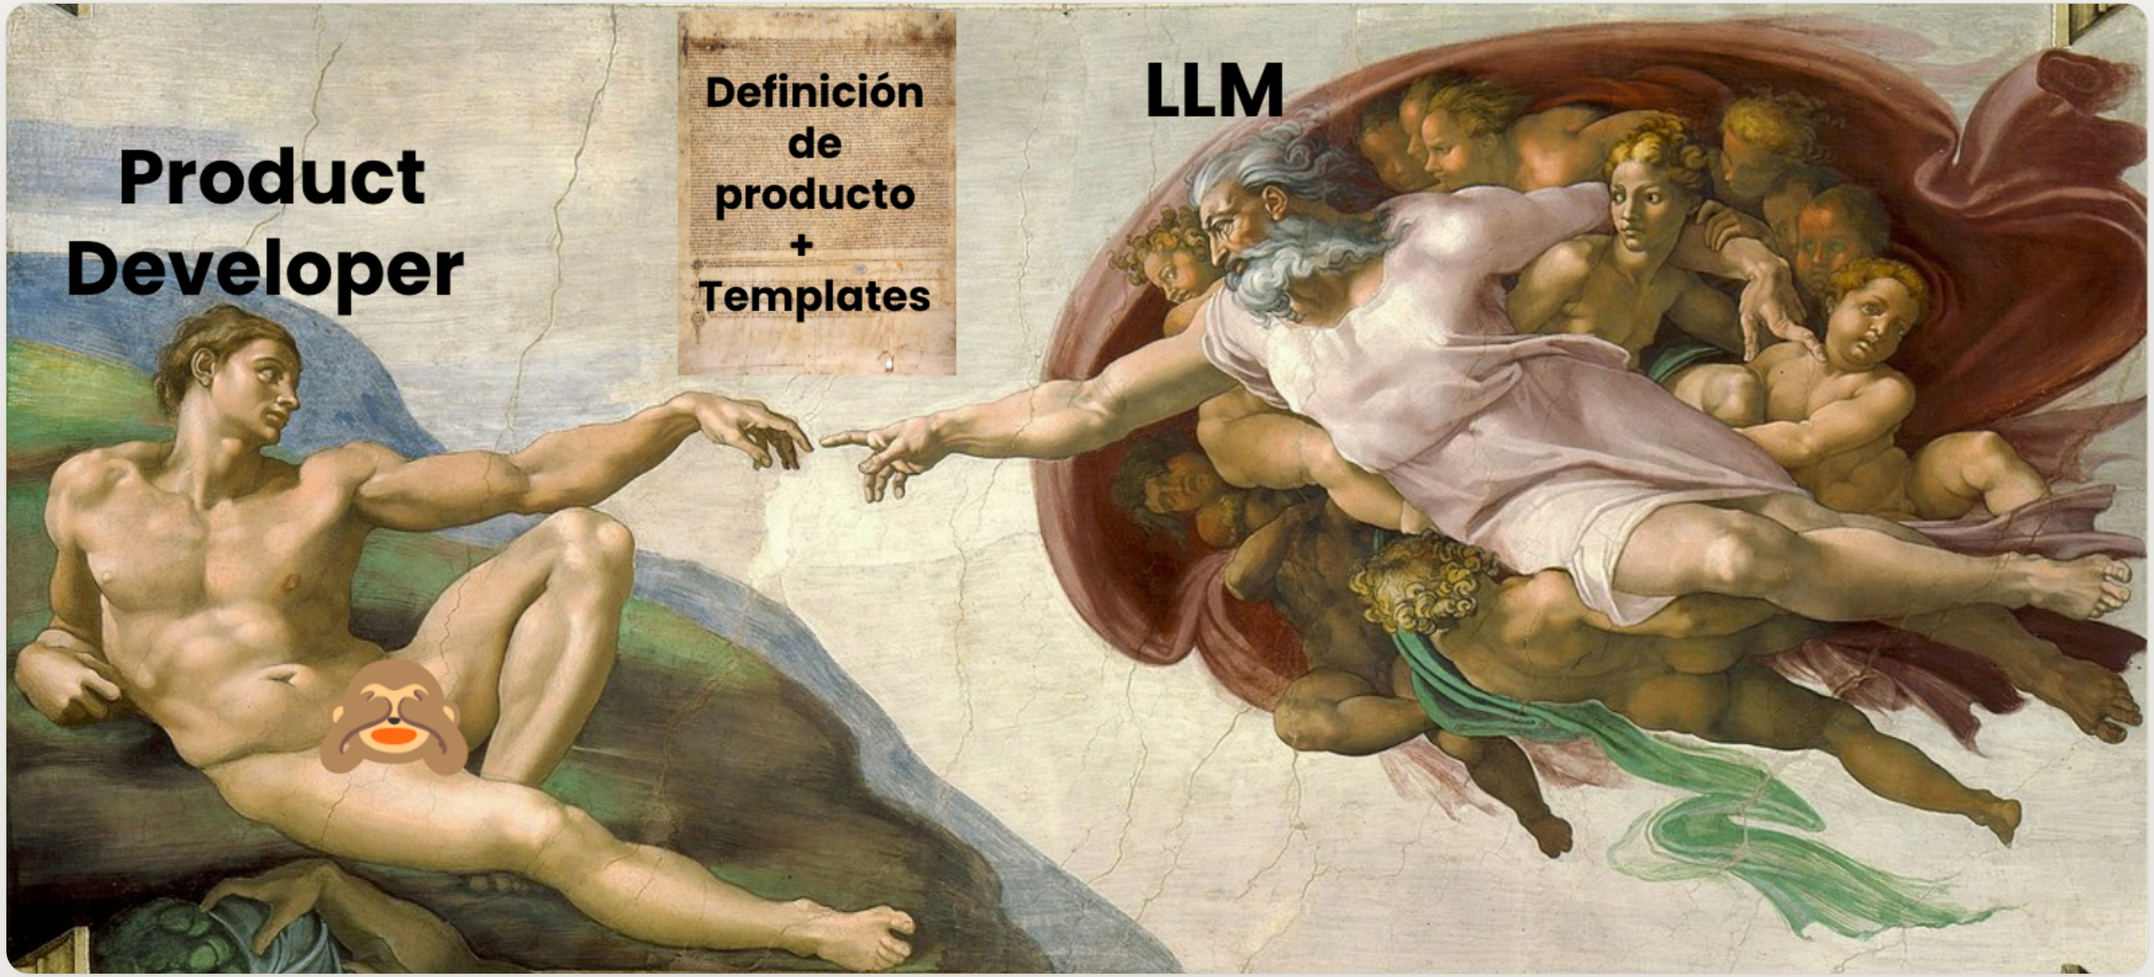

# Los Tres Pilares: Código de Calidad con IA

PILAR 1 • PRODUCTO

### Inception & Story Mapping

**Decide:** Problema real, fronteras defensivas y valor MVP.

PILAR 2 • TECNOLOGÍA

### ADRs & Arquitectura

**Decide:** Stack, límites arquitectónicos y ergonomía para IA.

PILAR 3 • VERIFICACIÓN

### Tests & Tests de Arquitectura

**Decide:** Invariantes ejecutables, TDD y reglas arquitectónicas (ArchUnit / fitness functions).

# El Ciclo de Desarrollo con IA: 5 Fases Disciplinadas

Un pipeline estructurado donde cada fase acota el contexto mediante Skills especializadas.

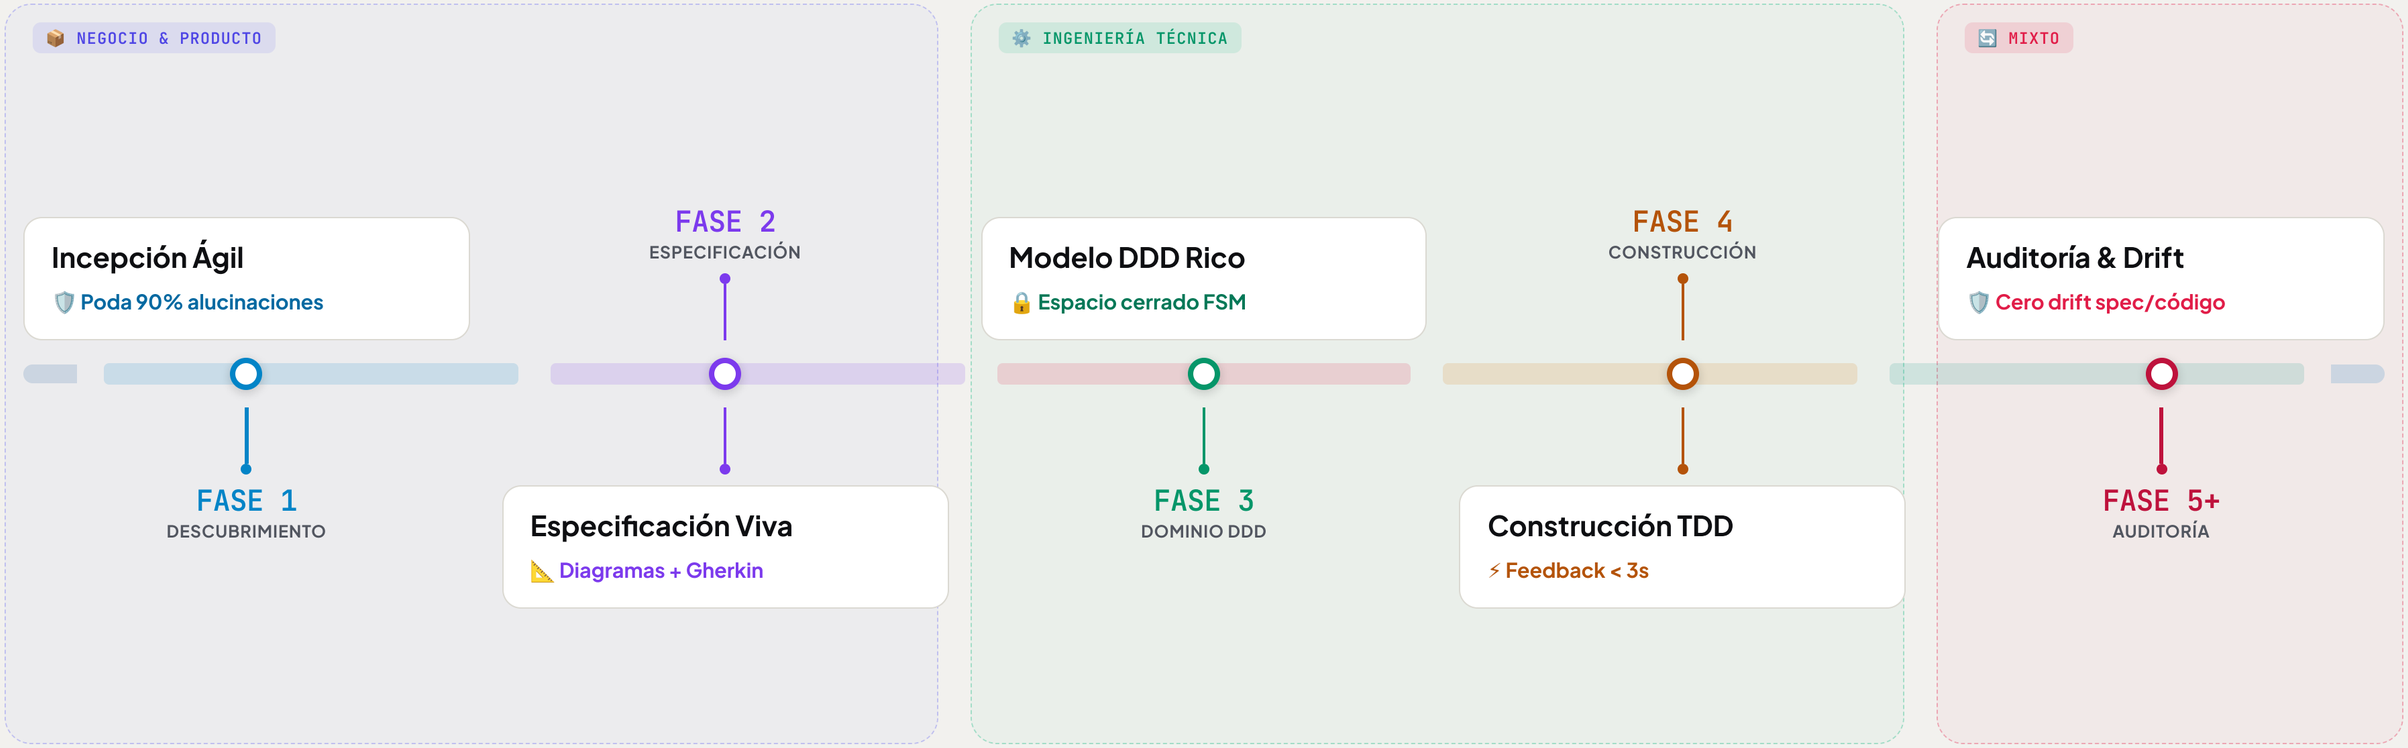


💡 **Sinergia Crafter:** Producto acota el contrato (Fases 1–2), Ingeniería verifica con TDD (Fases 3–4) y ambos evolucionan sin drift (Fase 5+).

FASE 2 • ESPECIFICACIÓN VIVA • LO QUE FIJA EL DOCUMENTO

# ¿De qué hablan estos documentos? (¿memoria viva?)

usuarios

necesidades

*objetivos*

flujo de información

reglas de negocio

comportamiento

decisiones cerradas

invariantes

estados y transiciones

eventos asíncronos

📌 **Todo esto es lo que debería estar en nuestro día a día:** escrito donde el modelo lo entiende — y así nos comunicamos con él de forma efectiva.

FASE 2 • ESPECIFICACIÓN VIVA • FORMATO DE DOCUMENTO

# Un Documento, Dos Mitades: Negocio y Técnica

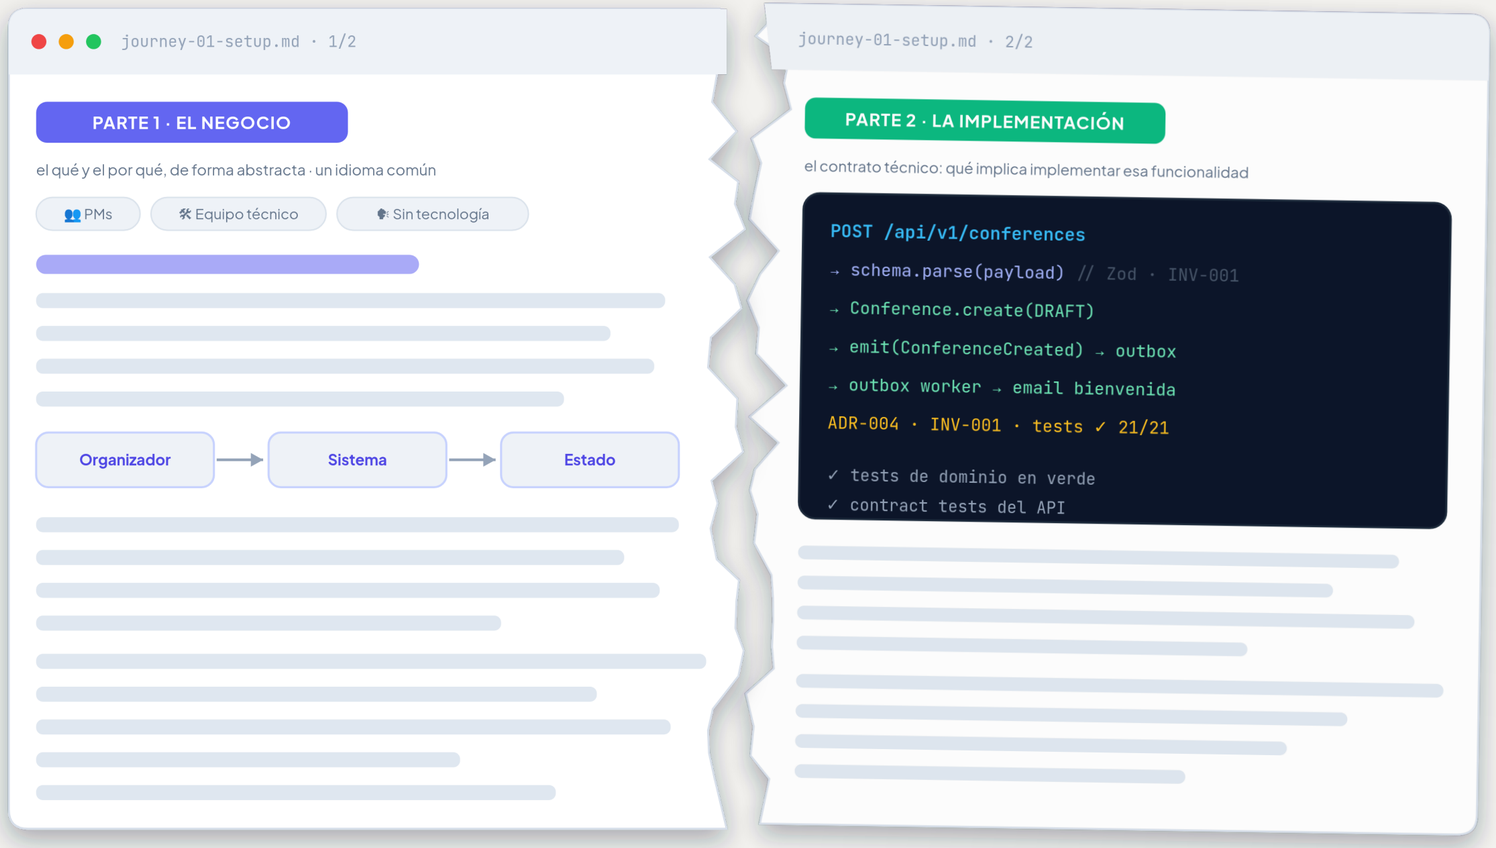


📖 **Leído por humanos**
Se entiende en menos de 2 minutos

⚡ **Pocos tokens**
Compacto para la IA: no infla el contexto

👁 **Flujos en visual**
Los esquemas explican el camino

FASE 2 • ESPECIFICACIÓN VIVA • DIAGRAMA DE SECUENCIA

# Esquema 1 · La Secuencia: Quién habla con Quién

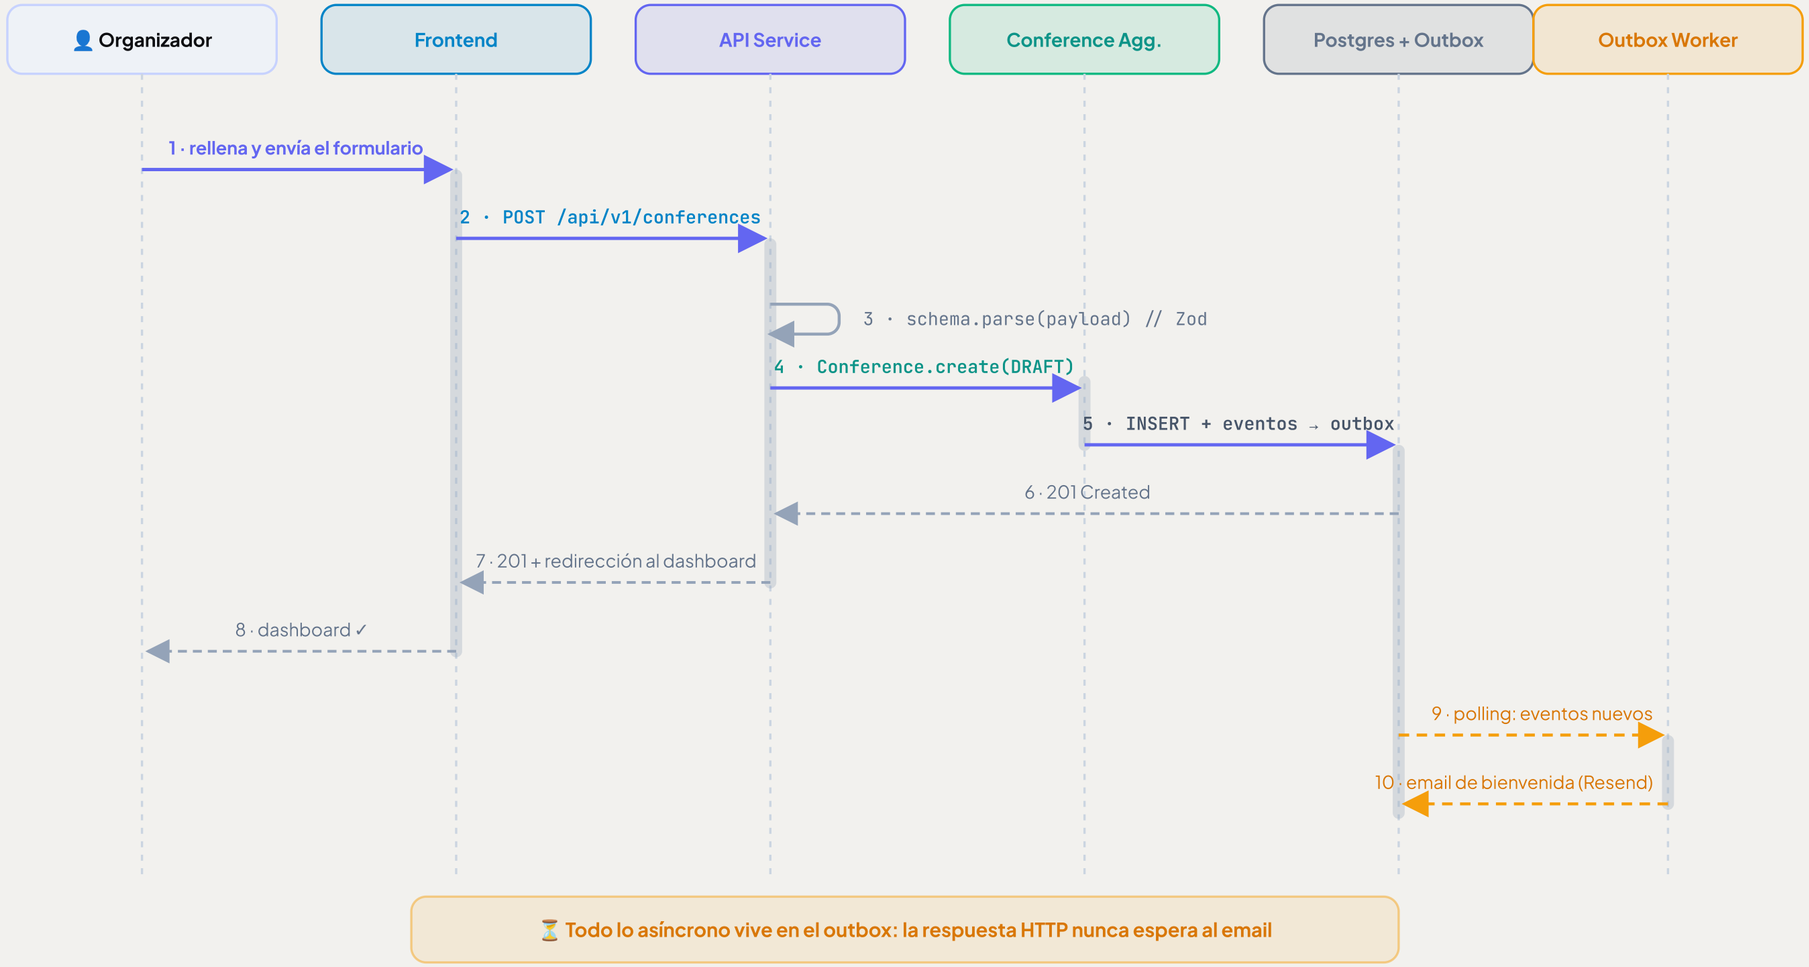

FASE 2 • ESPECIFICACIÓN VIVA • FLOWCHART DE DECISIONES

# Esquema 2 · El Flowchart: Toda Bifurcación, Cerrada

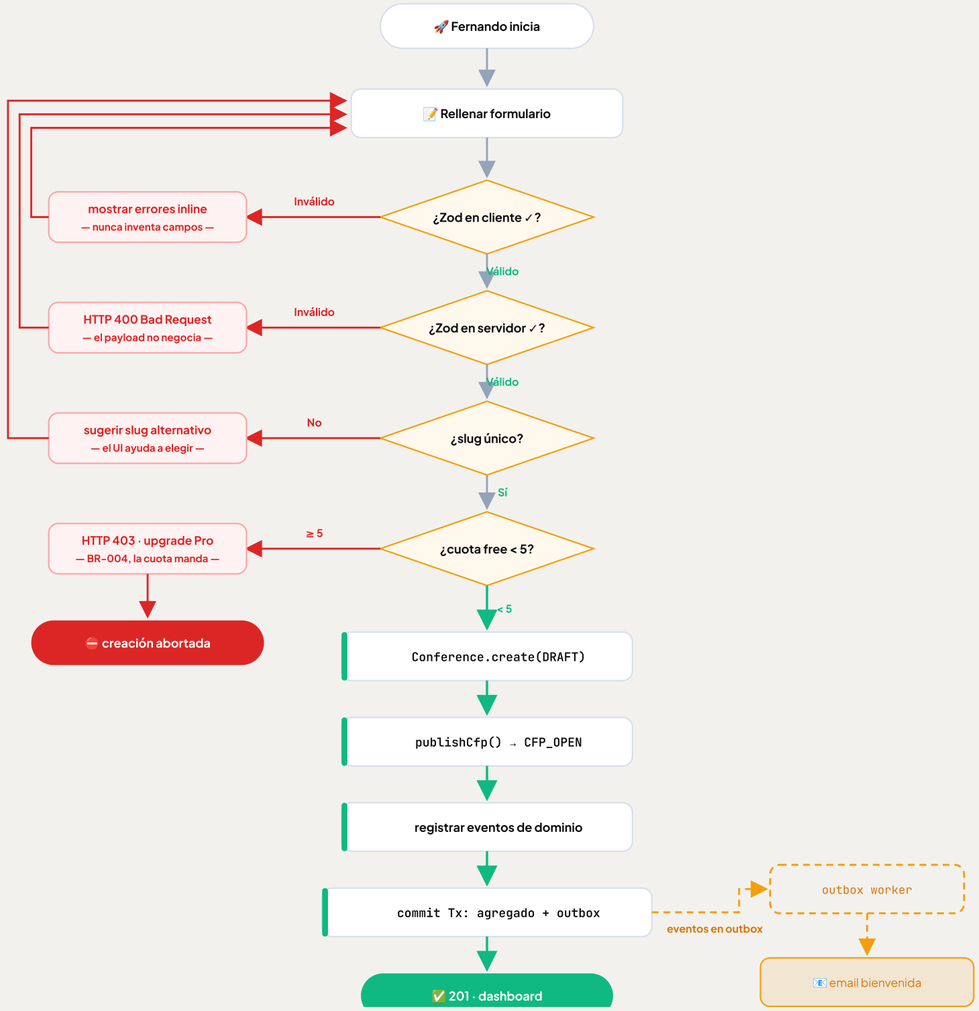

FASE 2 • ESPECIFICACIÓN VIVA • MÁQUINA DE ESTADOS (FSM)

# Esquema 3 · La FSM: Estados que no se Inventan

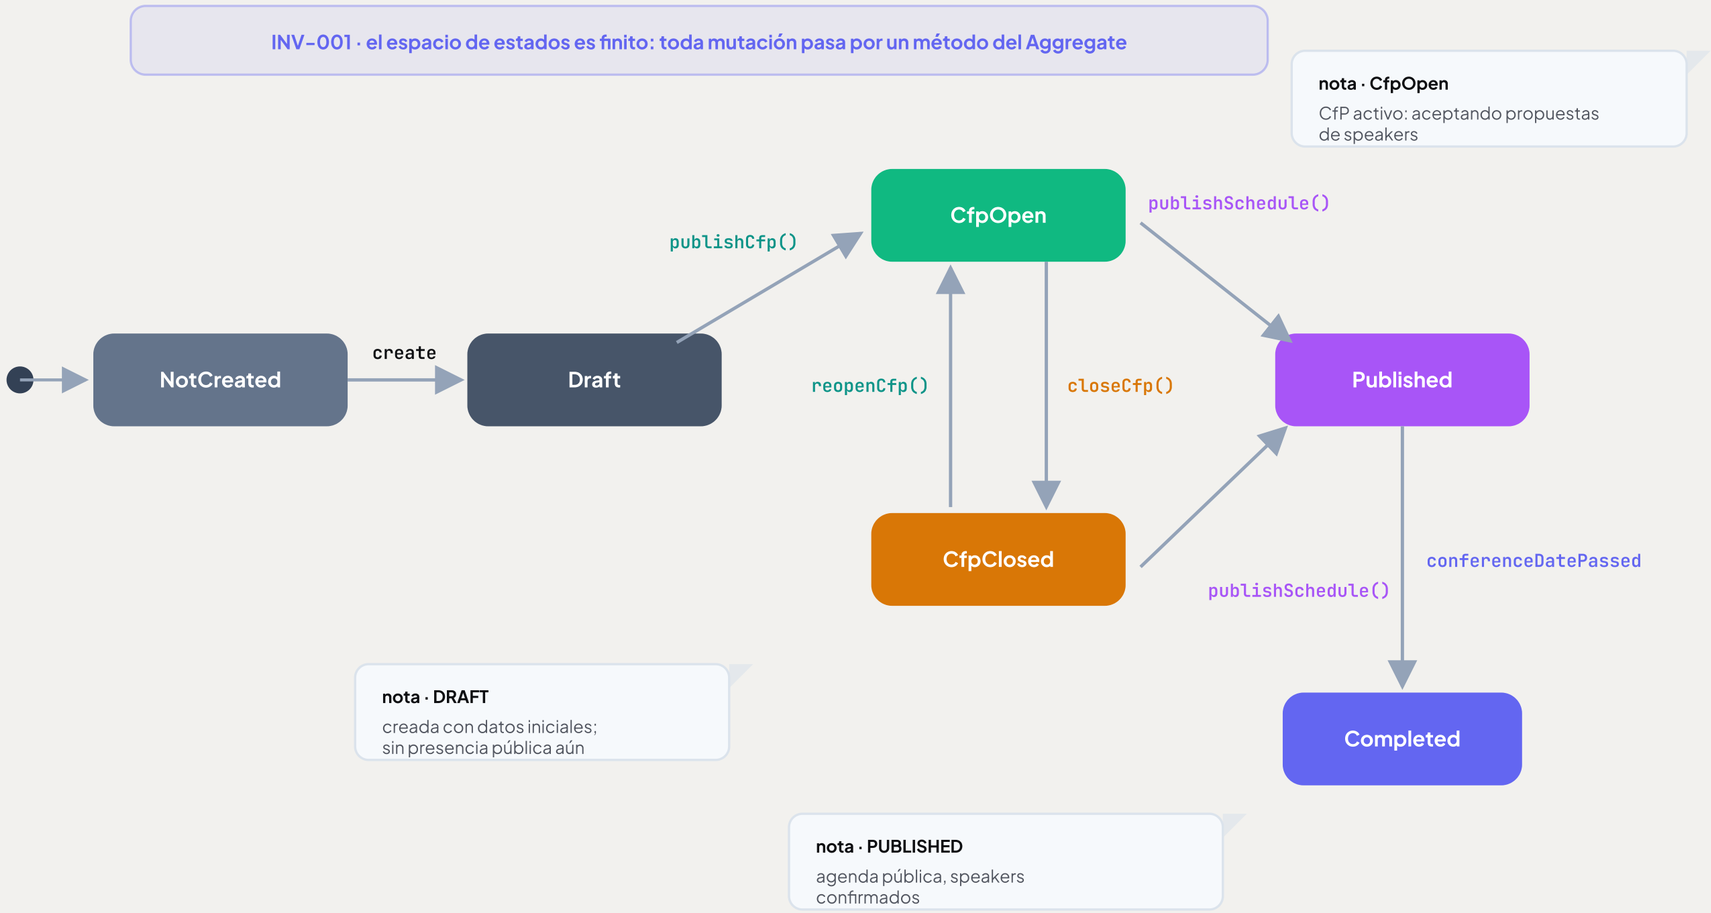

FASE 2 • ESPECIFICACIÓN VIVA • ESCRIBIR… ¿O MEJOR HABLAR?

# Hello, computer: escribir ya está anticuado

1986 → HOY

## Hello, computer

En 1986, a Scotty le dijeron que usara el teclado. Hoy el ordenador escucha de verdad — y con los esquemas y templates ya sabes exactamente qué pedirle.

### Primero, el esquema

Los gráficos y las plantillas fijan lo que quieres antes de abrir la boca.

### Luego, la voz

Hablar es más rápido que teclear: ya se me hace raro hacerlo de otro modo.

Habla con el ordenador

MAPA INTERACTIVO • DOCS/SDLC-WORKFLOW-DIRECTORY.MD

# El Mapa Real del SDLC: Skills, Artefactos y Gobierno

Skills encadenadas por artefactos; los ADRs gobiernan todo el ciclo.

## 📍 ESTAMOS AQUÍ • GOBERNANZA: ADRS

El dominio está blindado. ¿Quién garantiza que se respeta? La banda ADR: decisiones que el código no puede ignorar.

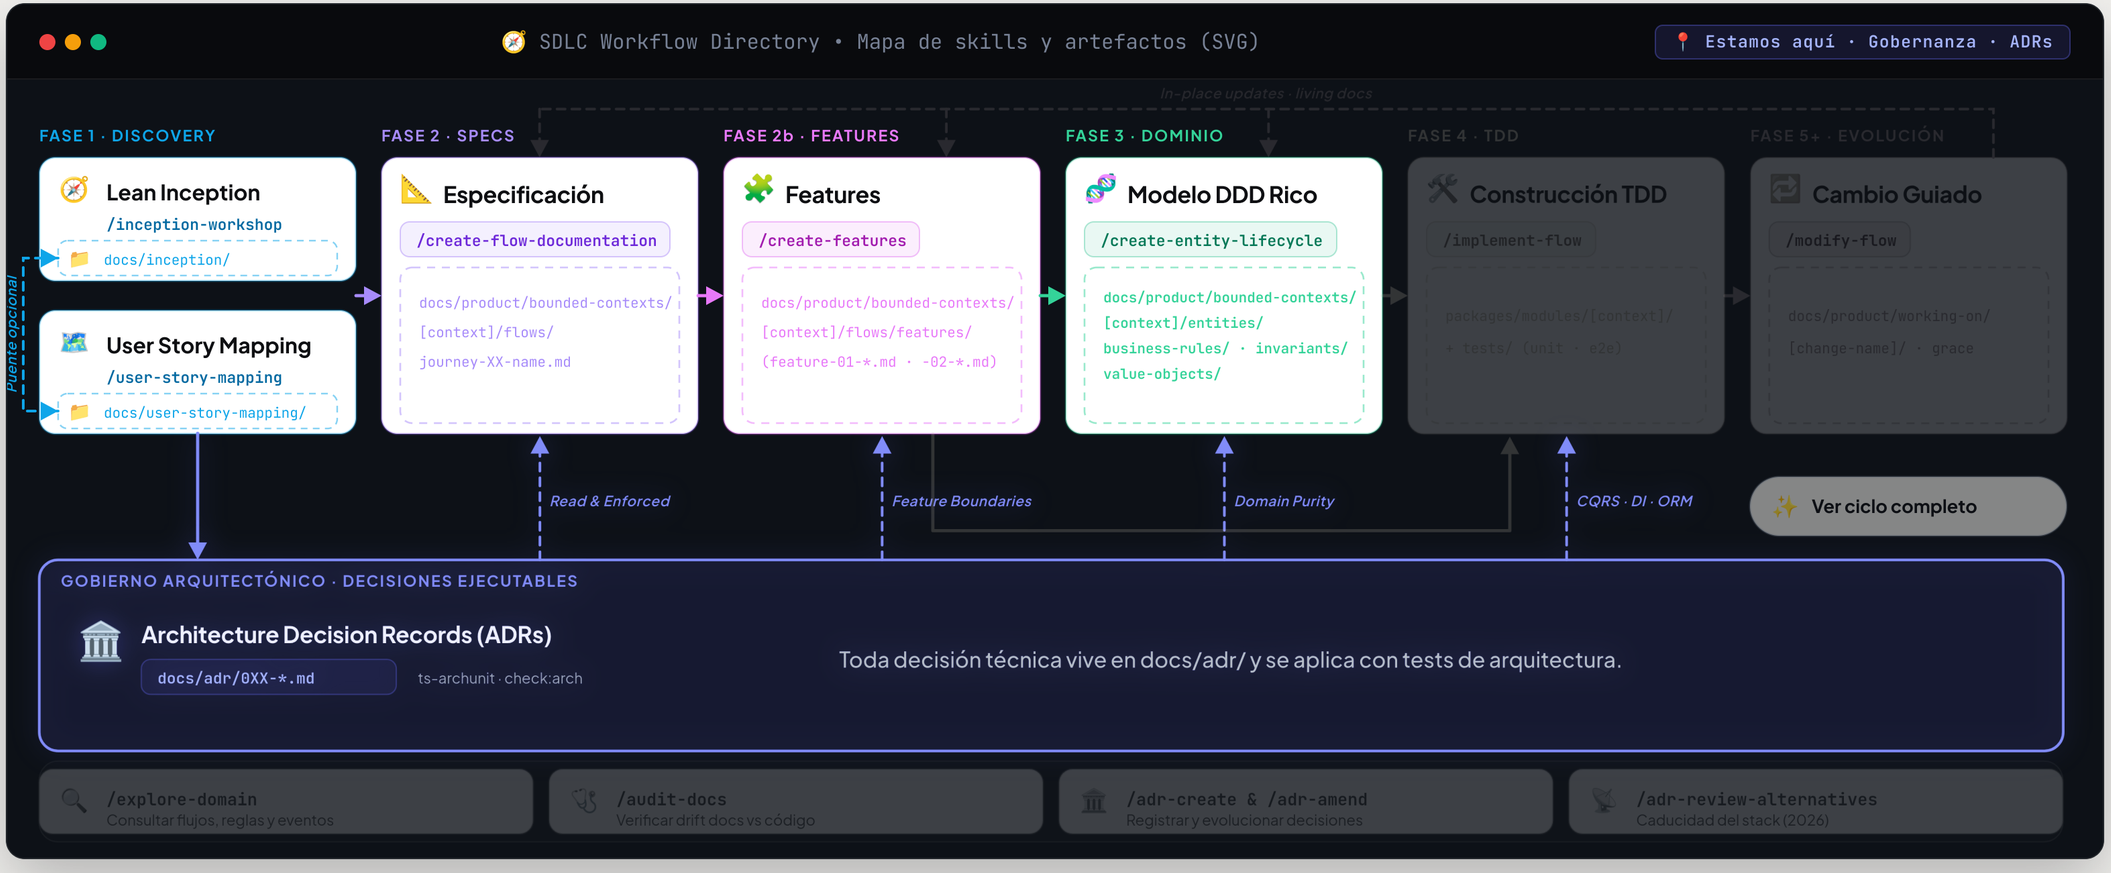

PILAR 2 • AI & AGENTIC ERGONOMICS (AX) • CORPUS ALIGNMENT VS. INERCIA DEL LLM

# La Fricción: ADRs vs. Pre-entrenamiento del Modelo

1. INERCIA DEL LLM

## El Sesgo de Internet

El modelo ha visto millones de repositorios mediocres y tutoriales obsoletos. Por defecto tenderá a **regresión a la media**: modelos anémicos y patrones genéricos.

2. GUARDRAIL TAX

## El Coste de Contención

Cuanto más choque tu ADR con los hábitos del modelo (ej. Controller Factories vs. NestJS), más **contexto, tipado defensivo y prompts** tendrás que pagar para mantenerlo en los raíles.

3. SOLUCIÓN CRAFTER

## Tipado & ts-archunit

No confíes en convencer al modelo con prosa: **blinda tus ADRs con contratos TypeScript estrictos y tests automáticos en CI** que rechacen cualquier alucinación en el acto.

EVIDENCIA TÉCNICA • VERCEL / NEXT.JS 16.3+ • DOCUMENTACIÓN & REPOSITORIOS

# Guardrail Tax: "This is NOT the Next.js you know"

NEXT.JS DOCS / GUIDES Next.js 16.3+

DOCUMENTACIÓN OFICIAL

## «Next.js empaqueta su documentación en node_modules para evitar el drift de los agentes»

A partir de Next.js 16.3+, Vercel incluye especificaciones completas dentro de `node_modules/next/dist/docs/`. Así los agentes consultan la versión exacta instalada sin peticiones externas y sin depender de datos de entrenamiento desfasados.

🔗 nextjs.org/docs/app/guides/ai-agents ↗

GITHUB / VERCEL/NEXT.JS Discussion #92197

EVOLUCIÓN DEL TEXTO

## «De "ALWAYS read docs" a "This is NOT the Next.js you know": sincronización en upgrades»

La discusión técnica #92197 documenta la transición hacia el aviso explícito de incompatibilidad. Al actualizar dependencias con npm las reglas podían desfasarse, lo que motivó a integrar la actualización de `AGENTS.md` en `next upgrade`.

🔗 github.com/vercel/next.js/discussions/92197 ↗

VERCEL LABS / CANARY Monorepo & Labs

IMPLEMENTACIÓN TÉCNICA

## «Detección de agentes y bloques delimitados: generate-agent-files.js en next dev»

Al arrancar `next dev`, el entorno detecta si hay un agente activo e inyecta la sección delimitada `<!-- BEGIN:nextjs-agent-rules -->`. Esto respeta las reglas custom del desarrollador y permite exclusión limpia con `agentRules: false`.

🔗 github.com/vercel/next.js (canary) ↗

AGENT SKILLS / MBLODE (GITHUB) Arquitectura IA

ANÁLISIS DE ECOSISTEMA

## «Scaffold Next.js: la documentación local como estándar de verdad frente a la inercia del modelo»

El análisis de `scaffold-nextjs` confirma que los LLMs arrastran patrones obsoletos si no se acota su contexto. Que un framework deba gobernar activamente a los agentes refuerza la necesidad de ADRs y especificaciones deterministas en el repositorio.

🔗 blode.co/agent-skills/scaffold-nextjs ↗

ARTEFACTO REAL • AGENTS.MD • PARADA ABRUPTA Y GOBERNANZA DETERMINISTA

# El Artefacto Inyectado: "This is NOT the Next.js you know"

📄 **AGENTS.md** MANAGED BLOCK — `node_modules/next/dist/server/lib/generate-agent-files.js`

*<!— BEGIN:nextjs-agent-rules —>*

## This is NOT the Next.js you know

This version has breaking changes — APIs, conventions, and file structure may all differ from your training data. Read the relevant guide in `node_modules/next/dist/docs/` (resolved from this file's directory; in monorepos the `next` package may not be visible from the repo root) before writing any code. Heed deprecation notices.

This block is written and re-added by `next dev` — verify at `node_modules/next/dist/server/lib/generate-agent-files.js`. Removing it from a diff only re-creates the uncommitted change; committing it with your work keeps the tree clean.

*<!— END:nextjs-agent-rules —>*

Inyectado y reescrito deterministamente en next dev — github.com/vercel/next.js (canary) ↗

### ⚠️ El fallo de las advertencias suaves

Cuando las directrices usan frases amables o condicionales (*"Please check the docs"*), los LLMs tienden a tratarlas como sugerencias de baja prioridad frente a los millones de ejemplos de versiones anteriores que dominan sus pesos de entrenamiento.

### 🛑 Técnica de *pattern interruption*

El encabezado `# This is NOT the Next.js you know` funciona como una instrucción de parada abrupta. Al contradecir categóricamente la premisa previa del modelo, eleva la probabilidad de que ejecute la llamada a herramienta (*tool use* en `node_modules/next/dist/docs/`) antes de alucinar código.

### 🔄 El problema de Next.js en particular

Pocos frameworks acumularon tantas capas divergentes en tan poco tiempo: Pages Router (2021), App Router con fetch cacheado (2023), y Server Actions/Components asíncronos en 15 y 16. La única forma de evitar que mezcle 2021 con 2026 era forzarla a ignorar su memoria base y consultar la versión empaquetada.

PILAR 1 • DOCS/ADR/ADR-WORKFLOW.MD • FLUJO SECUENCIAL DE IZQUIERDA A DERECHA

# El Ciclo Canónico de un ADR de la Duda a la Ley

01 PROPOSED

🎯

## Dilema & Drivers

`/adr-create`

Nace de una encrucijada técnica real o cambio de stack. El skill **reserva el siguiente ID secuencial (0XX)** y documenta las fuerzas impulsoras.

- **Artefacto:** `docs/adr/0XX-*.md`
- **Foco:** Define drivers y problema real

🎯 Acota el problema

02 2-3 OPCIONES

⚖️

## Exploración Real

`Matriz Pros / Cons`

Prohibido el sesgo de confirmación. Se evalúan **2 o 3 alternativas viables** contrastando pros, contras, mantenimiento y deuda técnica.

- **Matriz:** Mínimo 2–3 opciones viables
- **Criterio:** Pros, contras y trade-offs

⚖️ Criterio sin sesgos

03 OBLIGATORIO

🤖

## Ergonomía IA (AX)

`Corpus & Guardrails`

¿Choca con el sesgo del LLM? Se evalúa el **Corpus Alignment**, el **Guardrail Tax** (coste en prompts y tests) y el riesgo de deriva.

- **Corpus Bias:** Hábitos previos del LLM
- **Guardrail Tax:** Coste en prompts y tests

🤖 Mitiga la inercia LLM

04 COMPROMISO

📌

## Decisión & Reglas

`Contrato Firme`

Elección formal con honestidad intelectual: se explicitan los **beneficios**, los **trade-offs asumidos** y qué queda terminantemente prohibido.

- **Contrato:** Elección formal e inmutable
- **Invariante:** Qué queda prohibido

📌 Reglas innegociables

05 ACCEPTED ✅

🛡️

## Auditoría & Sello

`/adr-validate`

Pasa la **rúbrica automática (Score ≥ Medium)** y se indexa en `docs/adr/README.md`. Queda blindado como constitución inmutable del código.

- **Rúbrica:** Score ≥ Medium para aceptar
- **Catálogo:** `docs/adr/README.md`

🏛️ Ley viva del repositorio

💡 **Principio Artesano:** Ninguna decisión de arquitectura se toma en un prompt efímero. Cada ADR es una ley verificada que convierte la ambigüedad en determinismo reproducible para agentes e ingenieros.

PILAR 1 • DOCS/ADR/ADR-WORKFLOW.MD • FLUJO SECUENCIAL DE IZQUIERDA A DERECHA

# El Ciclo Canónico de un ADR de la Duda a la Ley

01 PROPOSED

🎯

## Dilema & Drivers

`/adr-create`

Nace de una encrucijada técnica real o cambio de stack. El skill **reserva el siguiente ID secuencial (0XX)** y documenta las fuerzas impulsoras.

- **Artefacto:** `docs/adr/0XX-*.md`
- **Foco:** Define drivers y problema real

🎯 Acota el problema

02 2-3 OPCIONES

⚖️

## Exploración Real

`Matriz Pros / Cons`

Prohibido el sesgo de confirmación. Se evalúan **2 o 3 alternativas viables** contrastando pros, contras, mantenimiento y deuda técnica.

- **Matriz:** Mínimo 2–3 opciones viables
- **Criterio:** Pros, contras y trade-offs

⚖️ Criterio sin sesgos

03 OBLIGATORIO

🤖

## Ergonomía IA (AX)

`Corpus & Guardrails`

¿Choca con el sesgo del LLM? Se evalúa el **Corpus Alignment**, el **Guardrail Tax** (coste en prompts y tests) y el riesgo de deriva.

- **Corpus Bias:** Hábitos previos del LLM
- **Guardrail Tax:** Coste en prompts y tests

🤖 Mitiga la inercia LLM

04 COMPROMISO

📌

## Decisión & Reglas

`Contrato Firme`

Elección formal con honestidad intelectual: se explicitan los **beneficios**, los **trade-offs asumidos** y qué queda terminantemente prohibido.

- **Contrato:** Elección formal e inmutable
- **Invariante:** Qué queda prohibido

📌 Reglas innegociables

05 ACCEPTED ✅

🛡️

## Auditoría & Sello

`/adr-validate`

Pasa la **rúbrica automática (Score ≥ Medium)** y se indexa en `docs/adr/README.md`. Queda blindado como constitución inmutable del código.

- **Rúbrica:** Score ≥ Medium para aceptar
- **Catálogo:** `docs/adr/README.md`

🏛️ Ley viva del repositorio

💡 **Principio Artesano:** Ninguna decisión de arquitectura se toma en un prompt efímero. Cada ADR es una ley verificada que convierte la ambigüedad en determinismo reproducible para agentes e ingenieros.

ESTACIÓN DEL MAPA • ENTRANDO EN FASE 4

## 📍 ESTAMOS AQUÍ • FASE 4: CONSTRUCCIÓN TDD

Del mapa al código: cada feature (2b) es un ciclo TDD completo — y cuando algo cambie, la Fase 5 (/modify-flow) te devuelve al mapa.

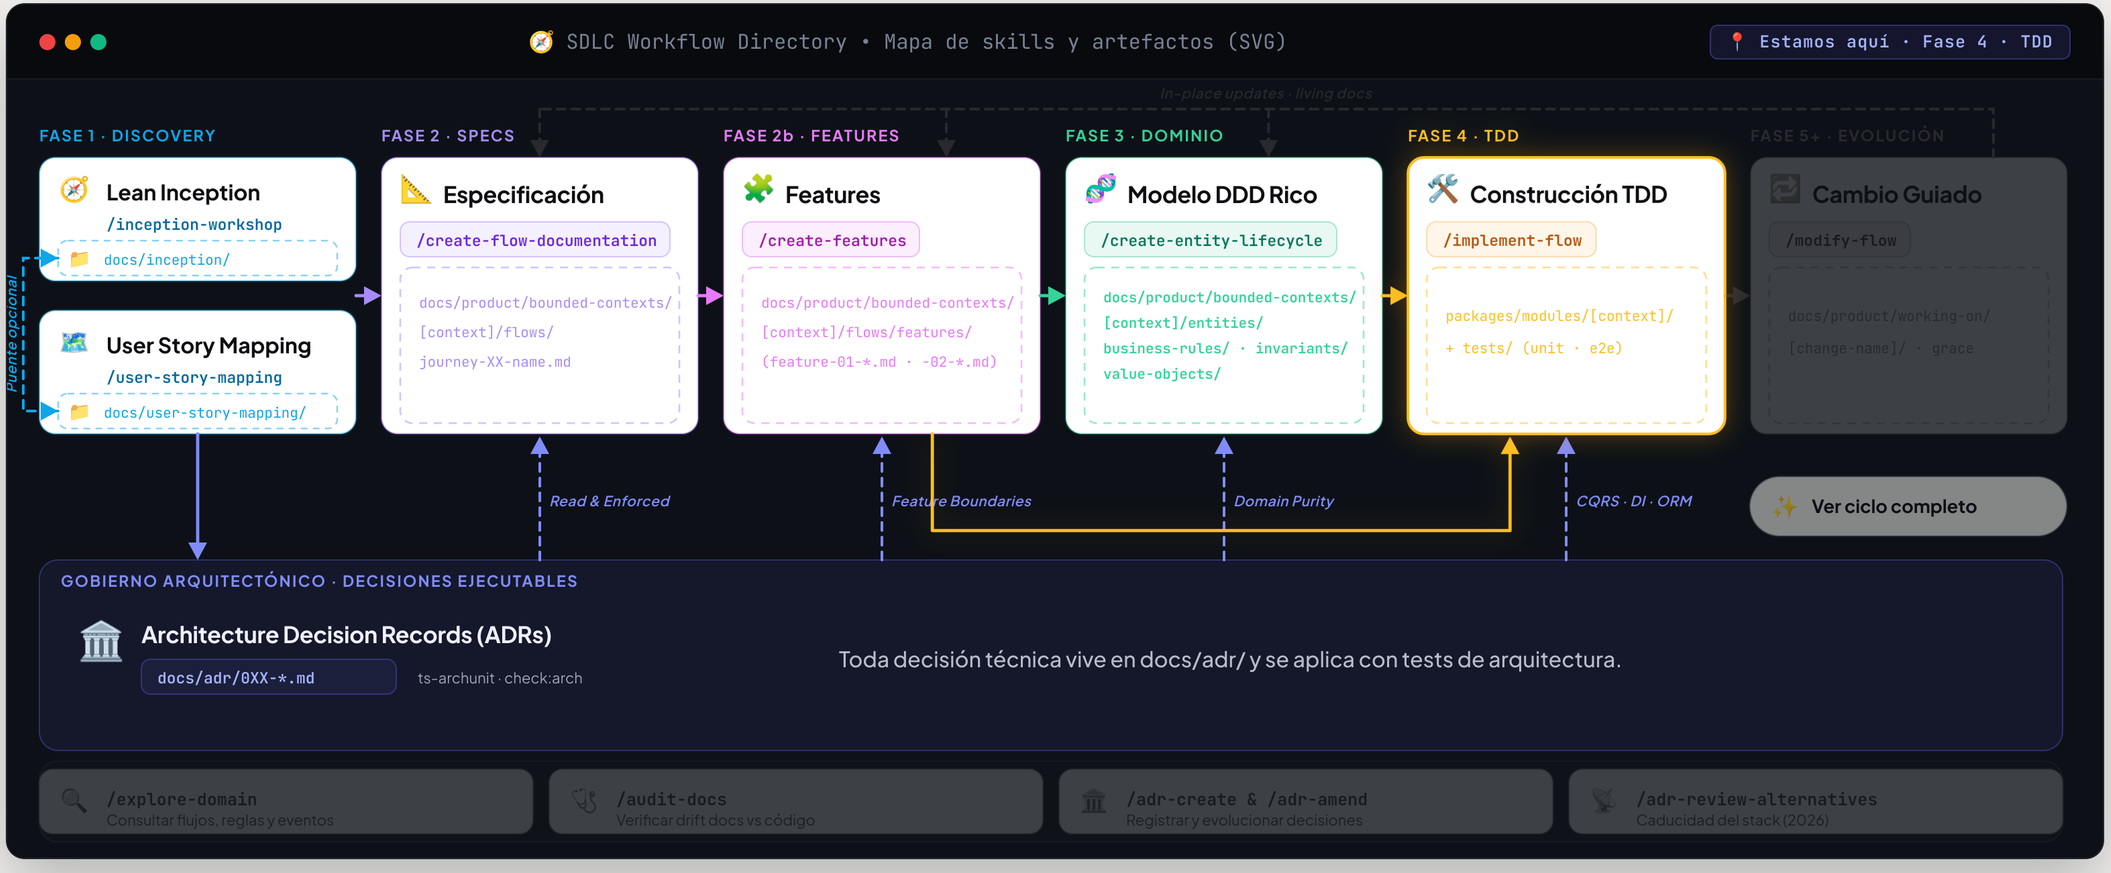

← Estación: Mapa · Fase 4

FASES 4 Y 5+ • CONSTRUCCIÓN, CAMBIO Y AUDITORÍA

# Evolución sin Drift: TDD Híbrido y Living Docs

Escribir código capa por capa guiado por tests que fallan y sincronizar la documentación en el mismo commit.

## 🧪 TDD Híbrido Capa por Capa

Fase 4 • /implement-flow

| | |
|---|---|
| 🔴 1. E2E Test (Falla) | Goal Post |
| 🔴➔🟢 2. Dominio Puro | domain/ |
| 🔴➔🟢 3. Casos de Uso | application/ |
| 🔴➔🟢 4. Infraestructura & Eventos | infrastructure/ |
| 🚀🟢 5. API & Controllers | api/ |

## 🔄 Gestión del Cambio

Fase 5+ • /modify-flow

1. Leer docs y código real
2. Redactar `proposal.md`
3. Plan por fases DDD
4. Actualización in-place

## 🛡️ Cero Drift de Documentación

/AUDIT-DOCS

✅ Confirmed ⚠️ Stale ❌ Missing ➕ Undocumented

## ✨ CICLO COMPLETO • TODO EL ECOSISTEMA ENCENDIDO

Nueve pasos encendidos a la vez: del /inception-workshop al /modify-flow, con el gobierno ADR y las operaciones continuas — así sube el ecosistema entero.

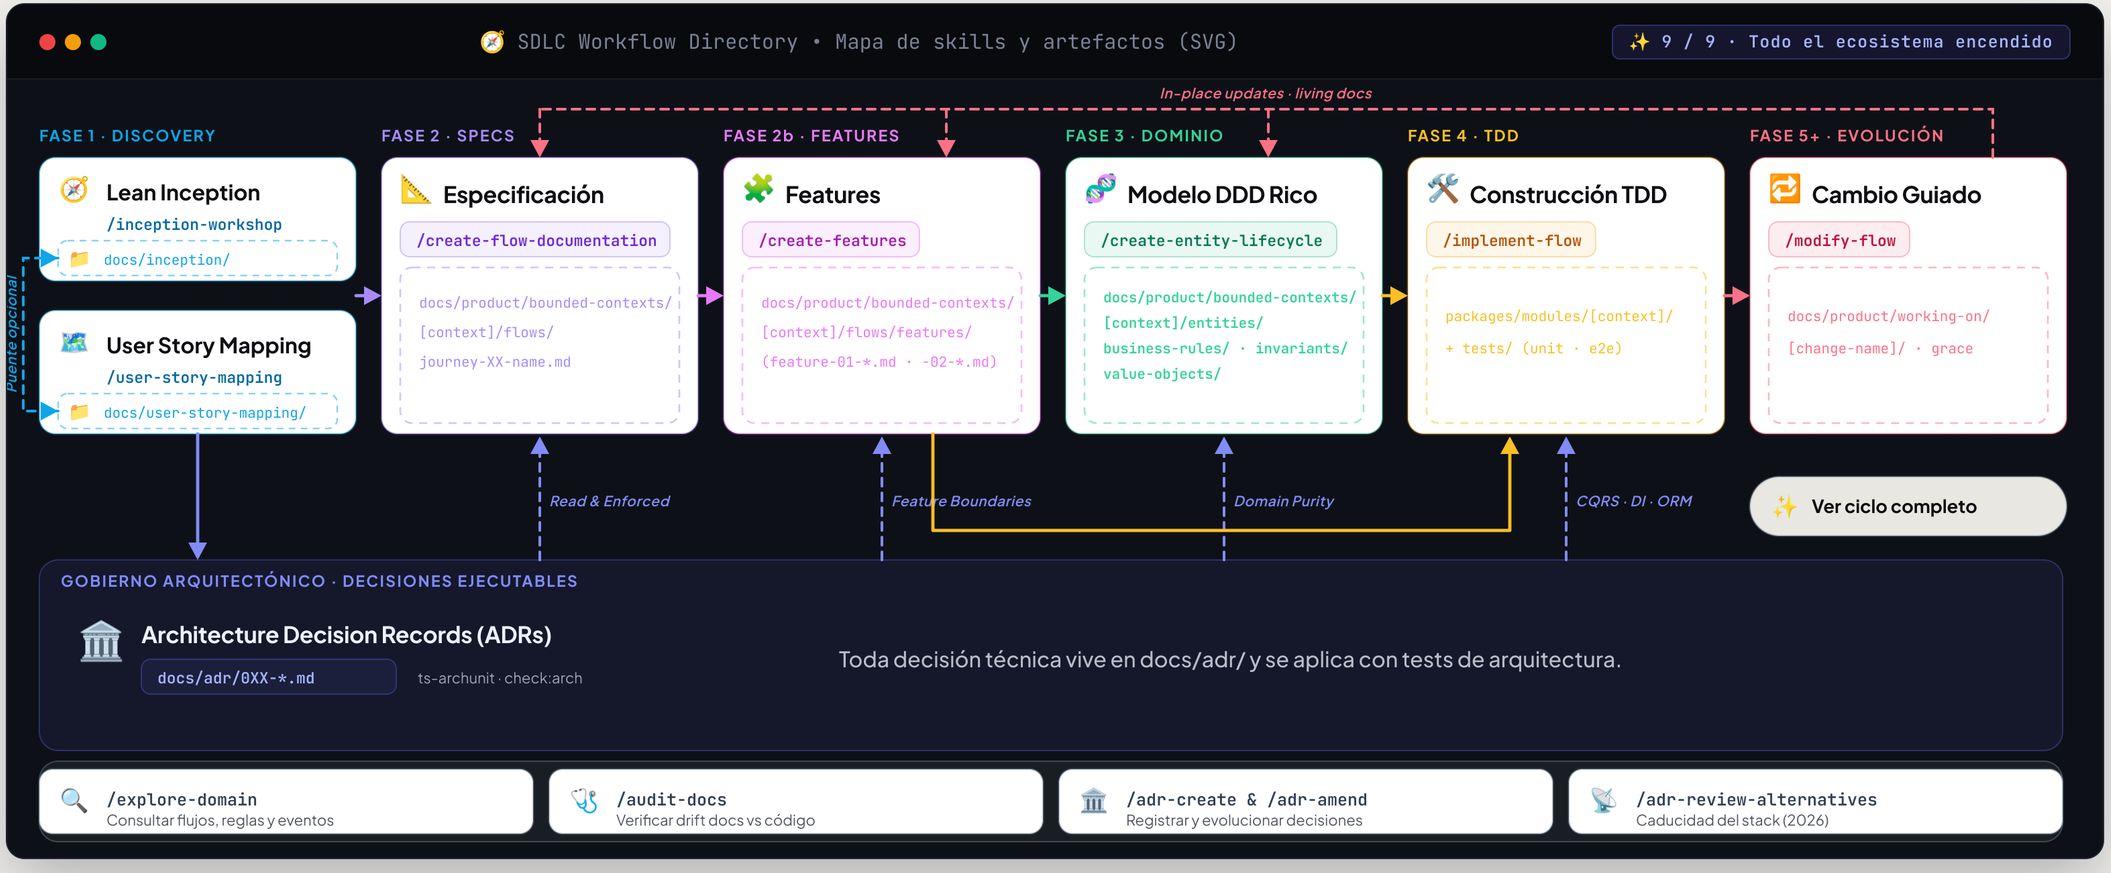

FASES 4 Y 5+ • SÍNTESIS DEL CICLO

# Ciclos Conectados: la documentación nunca envejece

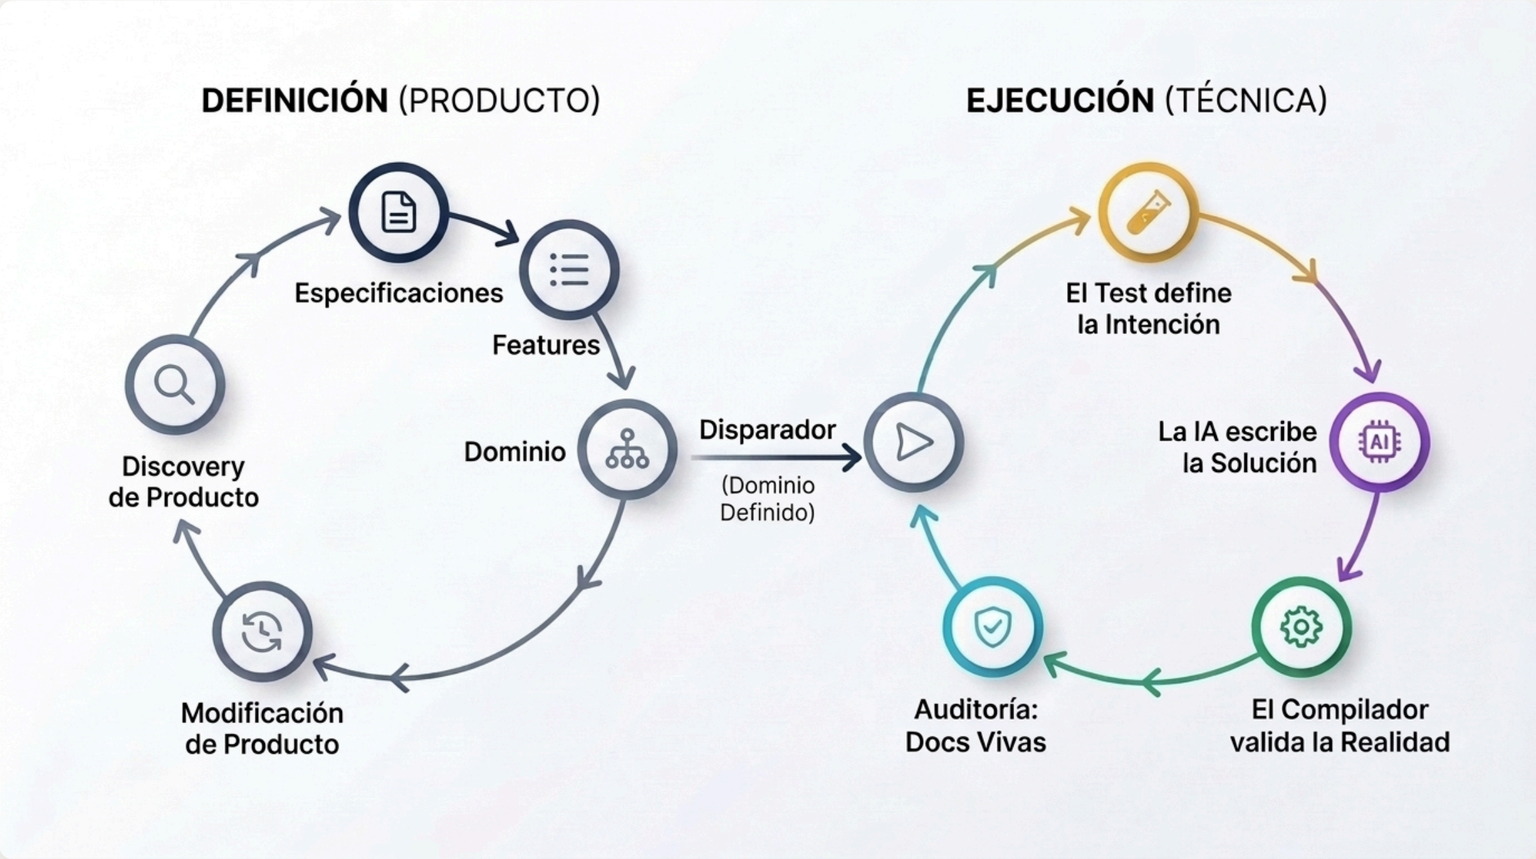

“La verdadera maestría artesanal consiste en entender el producto y controlar las herramientas que moldean nuestro código.”

— ARTESANÍA DE SOFTWARE EN LA ERA DE LA IA

LinkedIn

SessioFlow

SDLC Skills

La charla, en web