Crear Software en la Era de los Pesos Abiertos

Hardware, modelos y el ciclo de desarrollo completo.

01

Fernando

Software Crafter · AI Survivor

Software Crafters Barcelona

XIII EDITION #SCBCN26

SPONSORS SCBCN26

UNIXCORN

540

PEGASO

next digital

PONIA

seQura

manfred

sirviendo código;

CODESAI

codely

basetis

CAMBIO DE PARADIGMA

El Fin del Bufé Libre

La fase de adquisición masiva subvencionada por capital riesgo ha terminado. Creada la dependencia en el flujo diario de los desarrolladores, llega el despertar de la factura real.

2022 – 2024

🎁

La Era Dorada

10 $ / mes (o gratis)

✨ **Acceso Ilimitado**
Modelos punteros sin límites de tokens para crear el hábito.

💸 **Cómputo a Pérdidas**
Los fondos de inversión absorben miles de millones en GPUs.

Fidelización Total
El autocomplete y el chat se vuelven indispensables en el IDE.

`Objetivo: Enganche de Mercado`

2025 – 2026

⚠️

El Despertar

200 $ - 275 € / mes + Credits

⚡ **Cambio de Condiciones**
Límites arbitrarios y multiplicadores a mitad de contrato.

🔒 **Razonamiento Encarcelado**
Modelos de razonamiento profundo fuera del plan estándar.

📈 **"Es el Mercado, Amigo"**
Monetización forzada sabiendo que no puedes dar marcha atrás.

`Realidad: Sostenibilidad Forzada`

PRENSA Y ANÁLISIS

El choque de precios en los medios

NYT / TECHCRUNCH 27 Sep 2024

FILTRACIÓN

«La hoja de ruta de OpenAI para subir ChatGPT hasta 44 $ al mes»

Planes internos filtrados detallan la duplicación progresiva del precio de la suscripción Plus para compensar la factura masiva de servidores.

techcrunch.com/openai-pricing-roadmap ↗

XATAKA ANDROID 4 Nov 2025

MERCADO PRO

«La batalla de los 200 € al mes: ChatGPT Pro vs. Gemini Ultra»

Fragmentación del mercado: las funciones potentes de razonamiento profundo y agentes autónomos se desplazan a tramos de 229 € a 275 € mensuales.

xatakandroid.com/batalla-precios-ia-espana ↗

XATAKA 12 Jun 2026

ECONOMÍA IA

«Las suscripciones de IA son un chollo insostenible: el fin del bufé libre»

200 dólares al mes dan acceso a 14.000 $ en tokens reales. La llegada de agentes autónomos obliga a cerrar el grifo de las tarifas planas ilimitadas.

xataka.com/suscripciones-ia-chollo-insostenible ↗

MINDSTUDIO 15 Jun 2026

CAPITAL RIESGO

«Por qué la era de los 20 $/mes se acaba y llega el pricing shock»

La fase de adquisición subvencionada por fondos de inversión ha terminado; las plataformas recortan el plan básico y cobran recargos por cada tarea pesada.

mindstudio.ai/ai-pricing-shock ↗

CASO DE ESTUDIO • REBELIÓN DEV

Especial GitHub Copilot: La crisis de los Refunds

GITHUB BLOG OFICIAL 20 Abr 2026

COMUNICADO

«Changes to Copilot Individual Plans and Refund Clarifications»

La dirección de GitHub se ve obligada a publicar aclaraciones oficiales sobre los límites por créditos y a habilitar el reembolso prorrateado para calmar las bajas.

🔗 github.blog/copilot-individual-plans ↗

REDDIT (R/GITHUBCOPILOT) 28 Abr 2026

CHARGEBACKS

«Massive Backlash: Model Downgrades and Refund Disputes»

Hilos con miles de votos organizando disputas en PayPal y tarjetas por *bait-and-switch* tras la degradación automática a modelos básicos en 2–3 días.

🔗 reddit.com/r/GithubCopilot/…/1sy2ka1 ↗

TECH ANALYSIS / MEDIUM 3 Jun 2026

IMPACTO GLOBAL

«GitHub Copilot Just Betrayed 4.7 Million Devs: The End of Flat Rate»

Crónica del colapso del modelo económico de suscripción fija tras la llegada de agentes autónomos y la frustración masiva en la comunidad de software.

🔗 medium.com/@shahadilh18/github-copilot-just-betrayed ↗

GITHUB COMMUNITY FORUM 5 Jun 2026

QUEJA FORMAL

«Formal Complaint: Copilot Pricing Changes and Breach of Contract»

Suscriptores anuales denuncian la introducción de AI Credits con multiplicadores abusivos que reducen el valor útil a menos de un tercio a mitad de contrato.

🔗 github.com/orgs/community/discussions/198080 ↗

INFERENCIA POR API

Modelos Cloud: Occidentales vs. Asiáticos

PROPIETARIO CLOUD

$2.00 - $5.00 / 1M

APIs norteamericanas

OpenAI (GPT-5.6 / o3) • Anthropic (Claude 5) • Google

PROS & VENTAJAS

- ✓ Integración inmediata sin infraestructura propia
- ✓ Modelos frontera con razonamiento profundo puntero
- ✓ Ecosistema de SDKs y herramientas consolidado

CONTRAS & RIESGOS

- ✗ Subidas arbitrarias de cuotas y multiplicadores de créditos
- ✗ Telemetría externa y procesamiento fuera de tu control
- ✗ Riesgo total de encierro (Vendor Lock-in)

Seguridad: Privacidad de tercero

Modelo: Coste Variable Flotante

OPEN-WEIGHTS CLOUD

$0.08 - $0.55 / 1M

APIs chinas

DeepSeek (V4 / R1) • Alibaba Qwen (3.8 Max / 72B)

PROS & VENTAJAS

- ✓ Reducción drástica de factura (hasta 20× más barato)
- ✓ Calidad y benchmarks equiparables a modelos frontera
- ✓ API REST 100% compatible con estándar OpenAI

CONTRAS & RIESGOS

- ✗ Inferencia en servidores de terceros fuera de la UE
- ✗ Dependencia de disponibilidad de API del proveedor
- ✗ Latencias variables bajo alta demanda global

Seguridad: Servidor externo

Modelo: Alta Eficiencia ($/1M)

PRENSA Y ANÁLISIS · PRIVACIDAD

El espionaje de modelos: destilación y rutas ocultas

ANTHROPIC · THREAT REPORT Sep 2026

INVESTIGACIÓN

«7 laboratorios chinos destilaron Claude a escala industrial»

Campañas con 24.000+ cuentas fraudulentas y 151M de interacciones (Alibaba) para clonar razonamiento, código y cadenas de pensamiento.

anthropic.com/detecting-countering-misuse-of-ai ↗

ANTHROPIC · INFORME AMPLIADO Sep 2026

RUTEO OCULTO

«Moonshot AI desviaba los prompts de sus usuarios a Claude… y revendía la respuesta»

En tiempo real, las consultas de sus propios clientes iban a los servidores de Claude y volvían al usuario presentadas como producción de su propia IA.

anthropic.com/detecting-countering-misuse-of-ai ↗

CYBERSPACE ADMIN. OF CHINA Oct 2026

INSPECCIÓN

«China interroga a DeepSeek y Moonshot: sus usuarios hablaban con EE.UU.»

Al desviar prompts locales hacia servidores americanos, información sensible corporativa y gubernamental quedó expuesta ; la CAC abre inspecciones por seguridad nacional.

thehackernews.com · cobertura CAC ↗

NSA · CISA · FBI Sep 2026

ALERTA CONJUNTA

«EE.UU. confirma el ataque sistemático a los modelos frontera occidentales»

Alerta de inteligencia conjunta: DeepSeek y Alibaba atacan sistemáticamente los modelos frontera mediante destilación no autorizada.

cisa.gov · alerta conjunta ↗

ESCENA REAL · FILTRACIÓN DE DATOS

Conversación con el CEO: APIs chinas 🇨🇳

*«Bro, sospecho que nuestro prompt se ha **filtrado por medio planeta**.»*

PRENSA Y ANÁLISIS · VARIABILIDAD

El nerfeo: tu modelo cambia bajo tus pies

ANTHROPIC ENGINEERING 23 Abr 2026 — POST-MORTEM

«Anthropic reconoce la caída de calidad: 3 experimentos degradaron Claude Code»

Razonamiento High→Medium, amnesia de caché de sesión y concisión forzada en el system prompt. Revertidos entre el 7 y el 20 de abril tras las quejas masivas.

anthropic.com/engineering/claude-code-quality ↗

OPENAI COMMUNITY 9 Oct 2026 — SILENT ROUTING

«Downgrades encubiertos: el flagship se reenruta sin avisar»

Con proxies locales, los desarrolladores cazaron rutas hacia variantes degradadas (gpt-5.6-luna) cuando el clúster devolvía "selected model is at capacity".

community.openai.com/…/1404987 ↗

REDDIT · R/CHATGPT 6 Ago 2026 — NERFEO

«GPT 5.6 Sol High feels severely nerfed since 08/06»

Más de 100 votos denunciando la caída repentina del razonamiento complejo, con quejas por el enrutador Auto ineludible: no puedes fijar el modelo.

reddit.com/r/ChatGPT/…/1vl1anl ↗

REDDIT · R/CLAUDEAI 18 Ago 2026 — DEGRADACIÓN

«Discussion Hub: degraded performance for multiple models»

Hilos masivos de seguimiento con picos documentados en agosto y septiembre: la comunidad mide el rendimiento del modelo día a día porque ya no se fía.

reddit.com/r/ClaudeAI/…/1vrtyin ↗

ESCENA REAL · VARIABILIDAD

Conversación con el CEO: APIs norteamericanas 🇺🇸

«Bro, me han nerfeado el modelo. Esto antes molaba…»

INFRAESTRUCTURA DEDICADA

Tu Infraestructura: Alquilar o Poseer

GPU CLOUD IAAS

3,22 € - 33 € / h

Alquiler de GPUs Cloud

RunPod • Lambda • 1× a 8× NVIDIA H200 (141GB - 1.128GB)

PROS & VENTAJAS

✓ Inferencia masiva de MoE gigantes (230B-405B) en FP8/FP16

✓ Flexibilidad total: encender, escalar o apagar sin permanencia

✓ Alta concurrencia para servir a un equipo entero de devs

CONTRAS & RIESGOS

✗ Facturación continua mientras la máquina esté activa

✗ Requiere sysadmin y configuración de vLLM / Ollama

✗ Los pesos del modelo residen en la nube de un tercero

Seguridad: Instancia Cloud Privada

Modelo: Coste Fijo Horario

100% SOBERANO

0,00 € / token

Hardware Propio Local

Apple Silicon (Mac Studio M-series) • Workstations RTX/NPU

PROS & VENTAJAS

✓ Privacidad absoluta: zero data leaks y 100% offline (air-gapped)

✓ Coste marginal por token exactamente de 0,00 €

✓ Control artesanal total, soberanía de datos y latencia fija

CONTRAS & RIESGOS

✗ Inversión inicial en compra de hardware propio

✗ Tamaño de modelo limitado por la VRAM física del equipo

Seguridad: 100% Local / Air-Gapped

Modelo: Coste Marginal Nulo

💸 **...hasta la factura del silicio:** $25/GB y la caja agotada

PRENSA Y ANÁLISIS

El choque de precios II: la caja se disparó

EQUIPO	CONFIGURACIÓN	EVOLUCIÓN DE PRECIO	Δ	ESTADO (OCT 2026)
Framework Desktop	**128 GB unificada**	$1.999 → $2.459 → $3.449	+72%	🔴 Agotado en tienda
NVIDIA DGX Spark	**GB10 · 128 GB**	**$3.999 → $4.699 → $6.950**	**+74%**	🔴 **Agotado en canal**
NVIDIA DGX Spark	**GB10 · 64 GB (recorte)**	anuncio: $4.999	+25% vs. 128 GB orig.	🟡 Anunciado 23 Oct
Bosgame M5 / MS-S1 Max	**Strix Halo · 128 GB**	$2.899 → $3.099 – $3.799	+7 – 31%	🟡 Stock fugaz
GMKtec EVO-X2	**Strix Halo · 128 GB**	–	–	🔴 Agotado (todas)
Apple Mac Studio	**M5 Max · 128 GB**	$5.099	+$1.600 por 64 GB ($25/GB)	🟢 Disponible
Apple Mac Studio	**M5 Ultra · 256 GB**	$9.499	–	🟢 Disponible
Gorgon Halo	**AI Max+ Pro 495 · 192 GB**	$6.799	–	🟢 Escalón de entrada 192 GB

La promesa de amortizar una caja de **$2.000** se convirtió en un ticket de entrada de **$5.000–7.000**, con roturas de stock sistemáticas y 25 $ por cada GB de memoria. **La IA local dejó de ser la puerta de entrada para todo el mundo.**

EL PIVOTE DE 2026

Tarifas H200 verificadas el 19 sep 2026 · DeepInfra · Vast.ai · Latitude.sh

La salida honesta: alquilar GPUs para pesos abiertos

NIVEL 1

1× H200

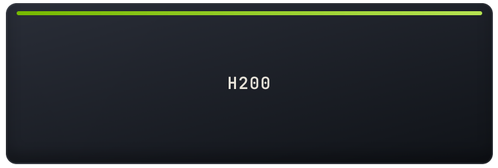

141 GB VRAM

4,8 TB/s por GPU

3,22 – 4,22 €/h

Caben: **Qwen 3.8 Flash Next** · **DeepSeek V4 Flash** en NVFP4, sin repartir

NIVEL 2

2× H200

282 GB VRAM

NVLink une las 2 GPUs

6,44 – 8,45 €/h

Caben: **DeepSeek V3** · **Qwen 3.8** en FP8, repartido entre las 2

NIVEL 3

4× H200

564 GB VRAM

NVLink: 4 GPUs fusionadas

12,88 – 16,89 €/h

Caben: modelos frontera **230B–405B** con tensor paralelismo

NIVEL 4

8× H200

1.128 GB VRAM

NVSwitch conecta las 8

25,76 – 33,12 €/h

Caben: **DeepSeek V3/V4** a precisión nativa, sin comprometer

VIVENCIA PERSONAL • LA DECISIÓN

La Decisión: Haciendo «calculasiones»

⏳ ANTES DE QUE EL MERCADO EXPLOTARA

1 **Cálculo de Inferencia Cloud vs Local**

Las APIs de frontera ($1.25 – $4.00 / 1M tok) en un flujo de desarrollo diario intensivo escalan a cientos de euros al mes.

2 **La Ecuación de la VRAM (128 GB)**

INT4 / NVFP4 permite encajar modelos MoE de 122B y 35B con 256K de contexto nativo sin recurrir a terceros.

3 **La Conclusión Inevitable**

Amortización en meses, latencia cero, soberanía total de código y experimentación sin mirar el taxímetro de tokens.

VIVENCIA PERSONAL • CASO DE ESTUDIO

¡Llegó el Aparato! (llegué a tiempo)

📦 1. Hardware (GB10 • 128 GB)

+

vLLM PAGED

llama.cpp GGUF

SGLang RADIX

🔩 2. Motores de Inferencia

+

Qwen 3.8 FlashNext MoE NUEVO

Qwen 3.6 35B A3B MoE NVFP4

🧠 3. Modelos Open-Weights

=

⚗️ 4. «Alquimia de la buena»

FOROS & COMUNIDAD • EARLY ADOPTERS

El Drama de Blackwell GB10: La odisea en los foros

NVIDIA DEV FORUMS 14 Mar 2026

POWER THROTTLE

«DGX Spark & ASUS GX10 stuck at 611MHz / 13W throttle state»

Bugs en el controlador USB-C PD bloquean la GPU en modo seguro inutilizable. El soporte oficial confirma que el único fix temporal es el "cold drain" : desconectar físicamente de la corriente y esperar a vaciar condensadores.

GITHUB ISSUES (VLLM) 8 Abr 2026

SM 12.1A MISMATCH

«Fatal CUDA error: Datacenter sm_100 containers fail on GB10»

La arquitectura de consumo SM 12.1a no es compatible con binarios oficiales. Los kernels de Tensor Core tcgen05 para FP4 vienen deshabilitados o sin compilar , provocando fallos inmediatos.

REDDIT (R/LOCALLLAMA) 19 May 2026

ROADMAP TRAP

«NVFP4 on GB10 performs WORSE than INT4 on Ada: Where are the kernels?»

Compradores de estaciones de 128GB descubren que NVIDIA no liberará soporte maduro de NVFP4 hasta finales de 2026 , dejando el hardware puntero a un tercio de su velocidad teórica.

COMMUNITY RELEASE 2 Jun 2026

OPEN SOURCE FIX

«avarok/vllm-nvfp4-gb10 & spark-vllm-docker: Unlocking 128GB Unified Memory»

Desarrolladores independientes publican imágenes Docker con kernels CUTLASS recompilados a mano , permitiendo correr Nemotron y Qwen 72B a máxima velocidad sin esperar a los drivers oficiales.

FOROS & COMUNIDAD • LA PROMESA NVFP4

El Drama de Blackwell GB10: La odisea en los foros

COMUNIDAD & DESARROLLADORES La Promesa Blackwell

«¡Me dijiste que podría ejecutar NVFP4!»

NVIDIA & DRIVERS OFICIALES Roadmap Oficial

«Pero no dije cuándo...» (A finales de 2026)

ARTESANÍA DE SOFTWARE & OPEN SOURCE • HACKERS DE SILICIO

Hackeando el Hierro: La Comunidad al Rescate

Eugr

Independent Hacker & ML Engineer

`eugr/spark-vllm-docker`

`@eugr`

✓ Contenedores Docker para DGX Spark

Creó las primeras imágenes y *build recipes* de vLLM optimizadas para Asus Ascent GX10 / DGX Spark, permitiendo levantar el stack de inferencia.

✓ Soporte MTP & Aceleración Especulativa

Integró recetas de Multi-Token Prediction directamente en vLLM para multiplicar la velocidad de inferencia sin VRAM adicional.

✓ 128 GB Unificados al Máximo

Habilitó la ejecución de modelos MoE y densos masivos (Qwen, Nemotron) sorteando las trabas iniciales de software del vendor.

Thomas Braun

Founder of Avarok & Kernel Hacker

`avarok/vllm-nvfp4-gb10`

`@tbraun96 • Avarok`

✓ Recompilación de Kernels CUTLASS

Parcheó y recompiló a mano los kernels para la microarquitectura `sm_121a` de Blackwell GB10 saltándose los binarios oficiales.

✓ NVFP4 Nativo Meses Antes del Roadmap

Desbloqueó la aceleración FP4 en Tensor Cores en mayo/junio 2026, mientras NVIDIA posponía el soporte oficial a finales de año.

✓ Rendimiento Teórico Recuperado

Multiplicó por 3× la velocidad de Nemotron y Qwen 72B frente a los lentos fallbacks por software estándar.

🛠️ **El Ecosistema vLLM & SGLang al Rescate:** La comunidad y los mantenedores integran continuamente parches de kernels CUTLASS/PTX y PRs upstream para que el hardware funcione a máxima potencia sin esperar a los drivers oficiales.

`COMUNIDAD OPEN SOURCE`

MARCO MENTAL • LAS 3 VARIABLES CLAVE

El Trilema de la IA Local: Memoria, Calidad y Velocidad

1. **Memoria · El límite físico**
2. **Calidad · La lógica intacta**
3. **Velocidad · La fluidez interactiva**

ANATOMÍA DE LA MEMORIA • VRAM & HARDWARE

¿En qué se gasta la Memoria? Pesos vs. KV Cache

🎮 Tanque de 24 GB (Qwen 3.6 27B INT4)

24 GB VRAM

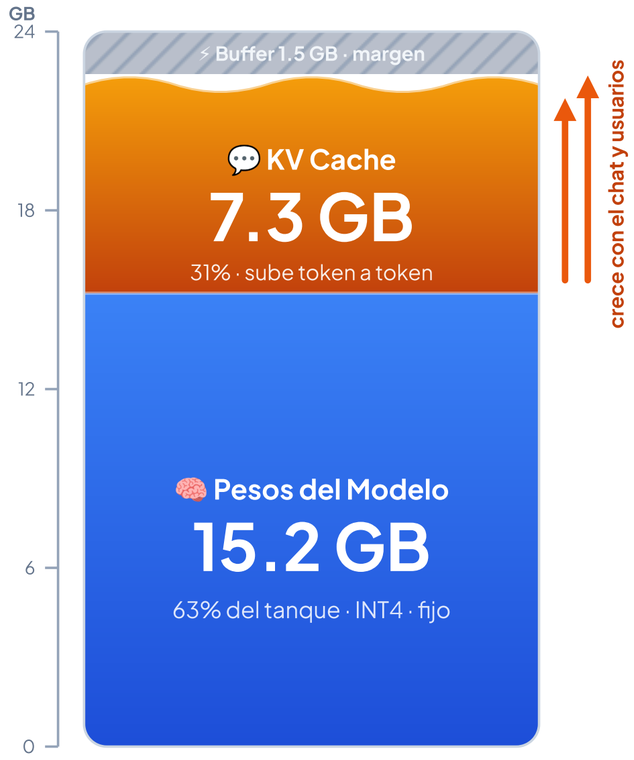

🧠 Pesos del Modelo

MEMORIA ESTÁTICA

🔒 **Inmutable:** se carga una sola vez al arrancar y su tamaño nunca cambia, respondas 1 pregunta o 10.000. Es tu precio de entrada fijo.

💬 KV Cache

MEMORIA DINÁMICA

📈 **Multiplicativa:** guarda preguntas, respuestas y PDFs para no recalcular desde cero. Crece token a token por cada usuario activo, y con contexto largo puede comerse el margen entero.

PRECISIÓN & BENCHMARKS • QWEN 122B MOE

El Peaje de Comprimir: ¿Cuánta Inteligencia se Pierde?

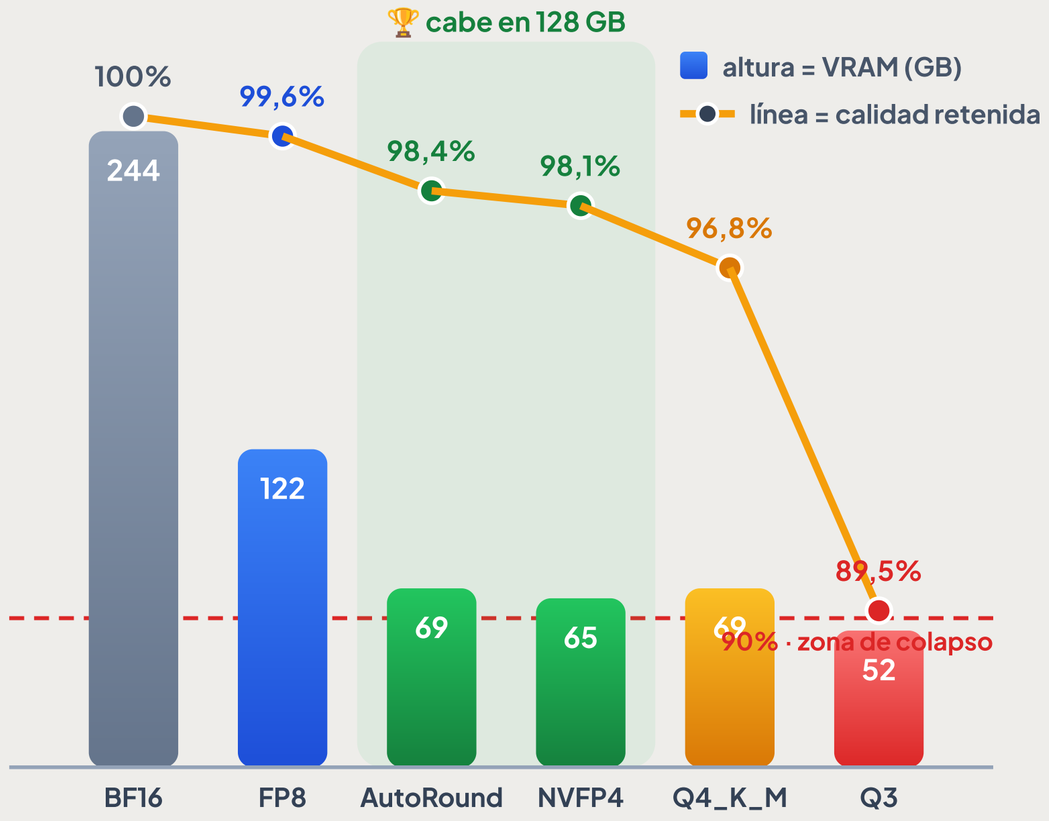

FP8: solo datacenter · INT4/NVFP4: el punto dulce de 128 GB · Q3: rompe el código

1. 💎 FP8 — el clon exacto

99,6% de calidad · 122 GB: impecable, pero solo vive en un datacenter.

2. 🌟 INT4 / NVFP4 — el punto dulce de 128 GB

AutoRound 98,4% · NVFP4 98,1% · 65–69 GB (3,5× más ligero): cabe en 128 con aire para la KV.

3. ⚙️ Q4 GGUF — el estándar local

96,8% · 69 GB · el formato de Ollama/Mac: –3,3% en código.

4. ⚠️ Q3 — la zona roja

<90% · 52 GB · colapso: paréntesis sin cerrar, imports inventados, bucles infinitos.

La Trampa del Benchmark: El Efecto Dominó

💡 Un acierto suelto vs. 50 pasos encadenados

$(0{,}98)^{50} \approx 36\%$

🎯 Benchmark estático · 1 token

Pregunta MMLU
elige A / B / C / D

→ **Modelo**
1 decisión puntual

→ **B ✓**

89,5% ✓

una tirada, un acierto: el test aprueba

error tolerado: si se desvía un 2%, nadie lo nota

💥 Razonamiento real · thinking 5.000 tokens

el error se acumula paso a paso →

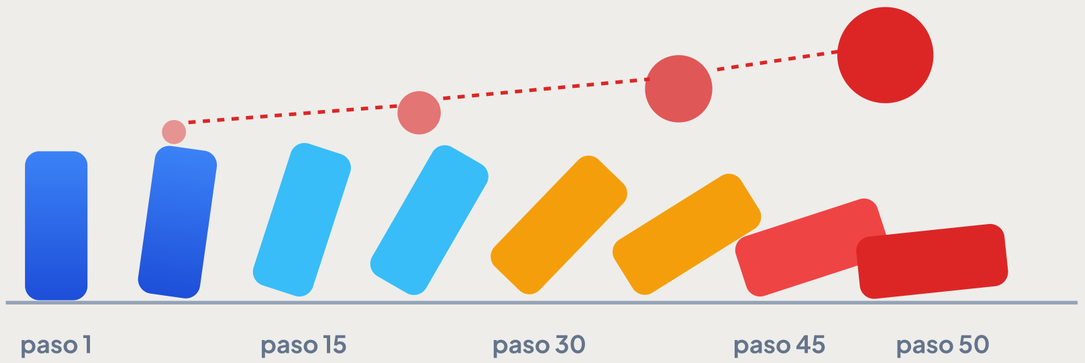

cada paso hereda el error del anterior → al paso 50 pierde el hilo

≈ 36%

🔴 Modelos de Razonamiento — CRÍTICA

DeepSeek R1, Qwen-Thinking: se desorientan con facilidad a menos de 4 bits; entran en bucle y no cierran la etiqueta `</think>`.

🟠 Modelos Pequeños (<9B) — ALTA

Poca redundancia: cada sinapsis cuenta. Cuantizar a 4-bit les hace perder mucha más lógica proporcional que a un modelo grande.

🟢 Modelos MoE / Grandes (122B) — RESISTENTE

Alta masa crítica: con *AutoRound INT4* o *NVFP4* absorben el ruido y mantienen la coherencia en agentes complejos.

RAZONAMIENTO & THINKING MODELS • COMPENSACIÓN DE ERROR

El Equilibrista de la Inferencia: Compensación Activa de Pesos

🎪 Metáfora Visual · Cuerda Floja

DeepSeek R1 / Qwen Thinking

🚶 **Inspector Gadget:** El modelo avanzando a ciegas a lo largo de 50 pasos de razonamiento encadenado.

🐶 **Sultán (Compensación):** Coloca el plato justo bajo cada pisada, equilibrando los pesos para que no caiga al vacío.

⚖️ Sistemas de Compensación Activa de Pesos

INFERENCIA · DE PTQ A QAD

SISTEMA	TIPO	MECANISMO DE COMPENSACIÓN	COSTE CÓMPUTO	HARDWARE / SOPORTE
QAD NVIDIA	Destilación	Teacher BF16 guía Student W4	Medio (horas GPU)	Blackwell / TensorRT / vLLM
AutoRound Intel	PTQ Sign-SGD	Pares contiguos anulan error neto	Mínimo (10–30 min)	Universal (GGUF, AWQ, vLLM)
ResComp GPTAQ	PTQ Hessiano	Peso a peso vs salida FP16 virgen	Bajo (1–2 horas)	Universal
SpinQuant Meta	PTQ Rotación	Dispersión de outliers	Mínimo (minutos)	TensorRT-LLM / vLLM
EfficientQAT	QAT Modular	Block-AP (VRAM) + tuning step-size	Alto (horas en 1 GPU)	Universal
QAT Clásico	Re-entrenamiento	Red completa con forward simulado (STE)	Extremo (días clúster)	Específico del framework
GSQ + RCO ISTA ✨ 2-3 bits	Gumbel + Manifold	Optimización suave & variedad Riemanniana	Medio (1 GPU · <2h)	GGUF / ExLlamaV2 (35B en 16GB · 122B en 24GB)

💡 **La clave práctica:** Para 4 bits (NVFP4), **AutoRound** y **QAD** garantizan máxima fidelidad sin deriva. Para romper el abismo de **2–3 bits**, la frontera de 2026 es **GSQ + RCO**.

ARQUITECTURA HÍBRIDA • FÍSICA DE LA MEMORIA

DeltaNet vs. Attention: El Secreto de la Memoria Estable

Anatomía del Bloque Repetitivo 3:1

3 DeltaNet + 1 Attention

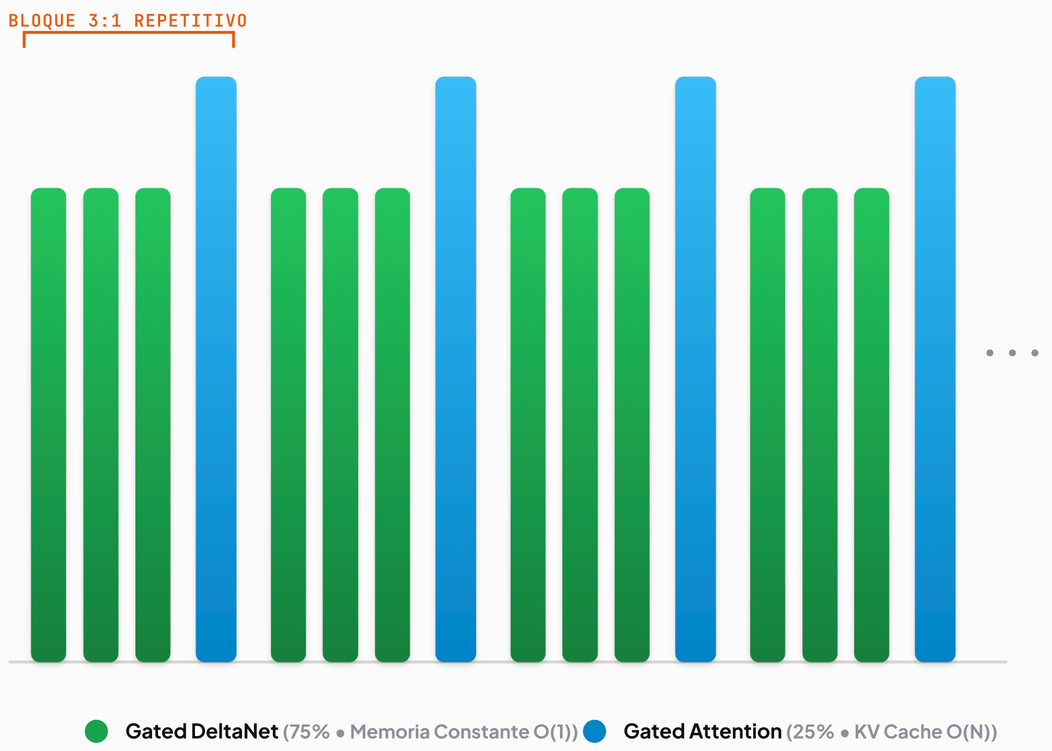

Curva de VRAM: Memoria Fija O(1) vs. Crecimiento O(N)

Escala 0 → 256K Tokens

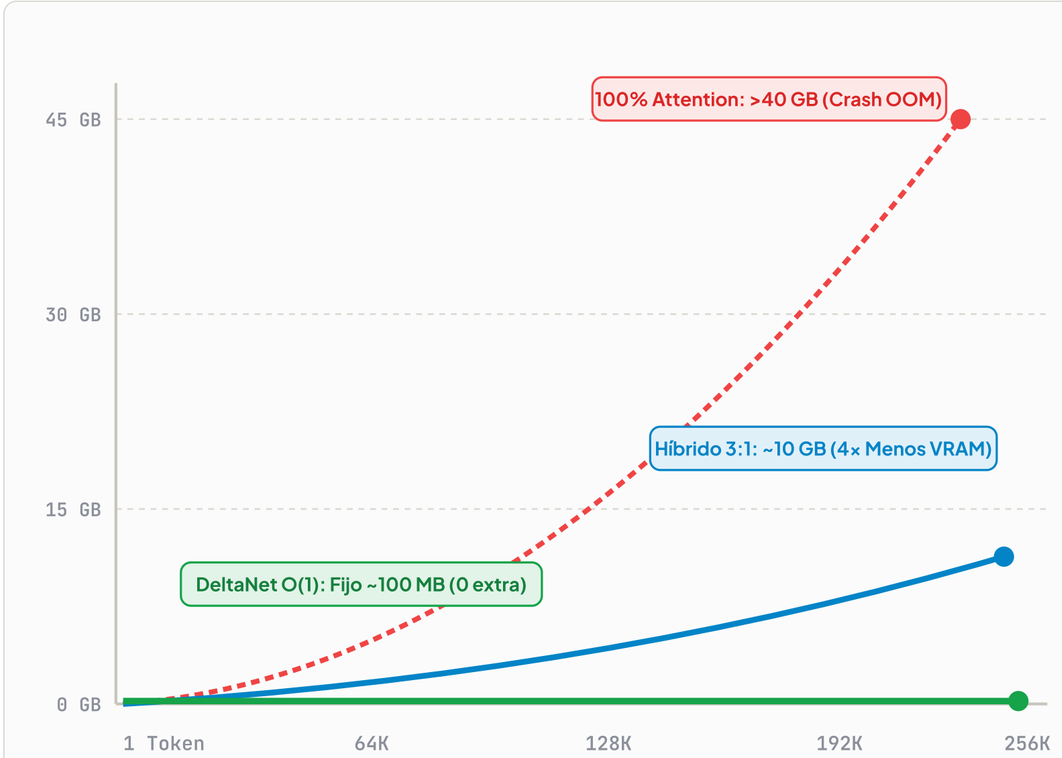

El Resultado Práctico (Reducción 4× en KV Cache): Al reservar el almacenamiento de tokens solo para el **25% de las capas**, un contexto masivo de 256.000 tokens consume **~10 GB de VRAM** en lugar de los >40 GB de un Transformer convencional, dejando espacio holgado en los 128 GB del equipo.

4X MENOS MEMORIA

La Velocidad es Memoria: el Viaje del Token

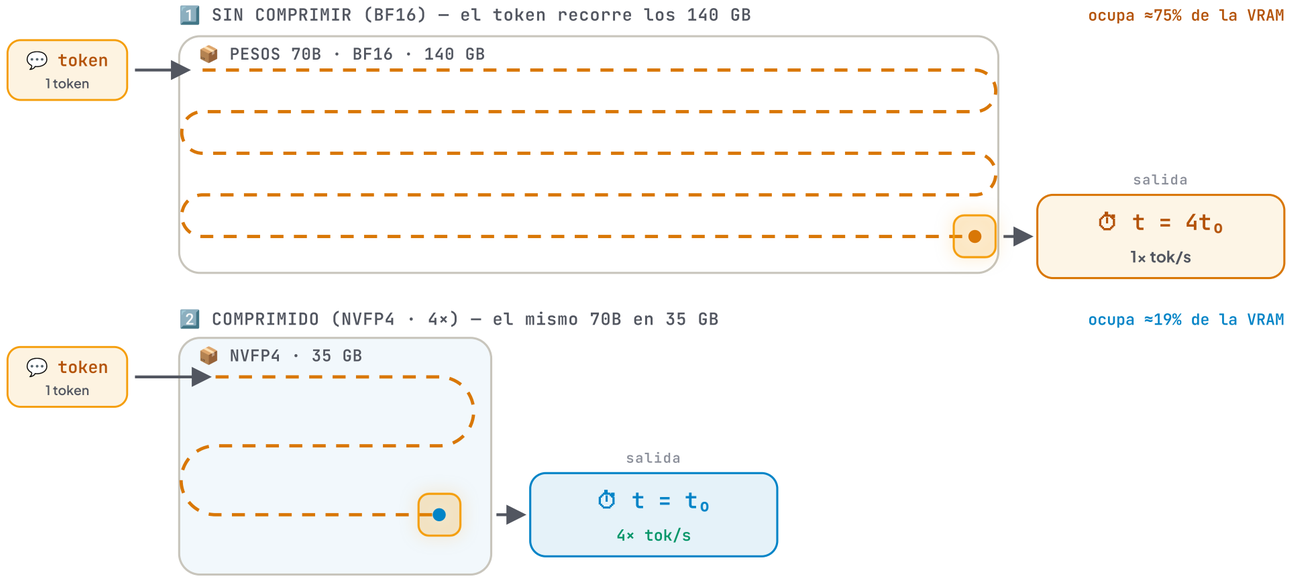

🏁 4× MENOS DISTANCIA = 4× MÁS TOK/S

tok/s ≈ ancho de banda ÷ GB leídos por token

comprimir pesos (FP8 · INT4 · NVFP4) = la palanca nº1 en local

🚀 El Viaje del Token — de la VRAM a la Salida

🧵 El Token Lee Todos los Pesos

BW-BOUND

Para generar **una sola palabra**, la GPU lee de VRAM los GB del modelo entero. El viaje del token es la factura de ancho de banda: **modelo grande = viaje largo = menos tok/s**.

🗜️ NVFP4: 4× Menos Distancia

4× TOK/S

El mismo 70B: **140 GB en BF16 → 35 GB en NVFP4**. Mismo ancho de banda y 1/4 de lectura: el viaje pasa de $4t_0$ a t_0. **Cuatro veces más tokens por segundo**.

⚡ La Palanca Nº1 en Local

TOK/S ≈ BW ÷ GB

Sin cambiar de GPU: **FP8, INT4 o NVFP4 acortan el viaje** del token y liberan VRAM para contexto largo. **Cuantizar es ganar velocidad** con la misma sabiduría.

Modelos Densos: Una Petición Enciende las 48 Luces

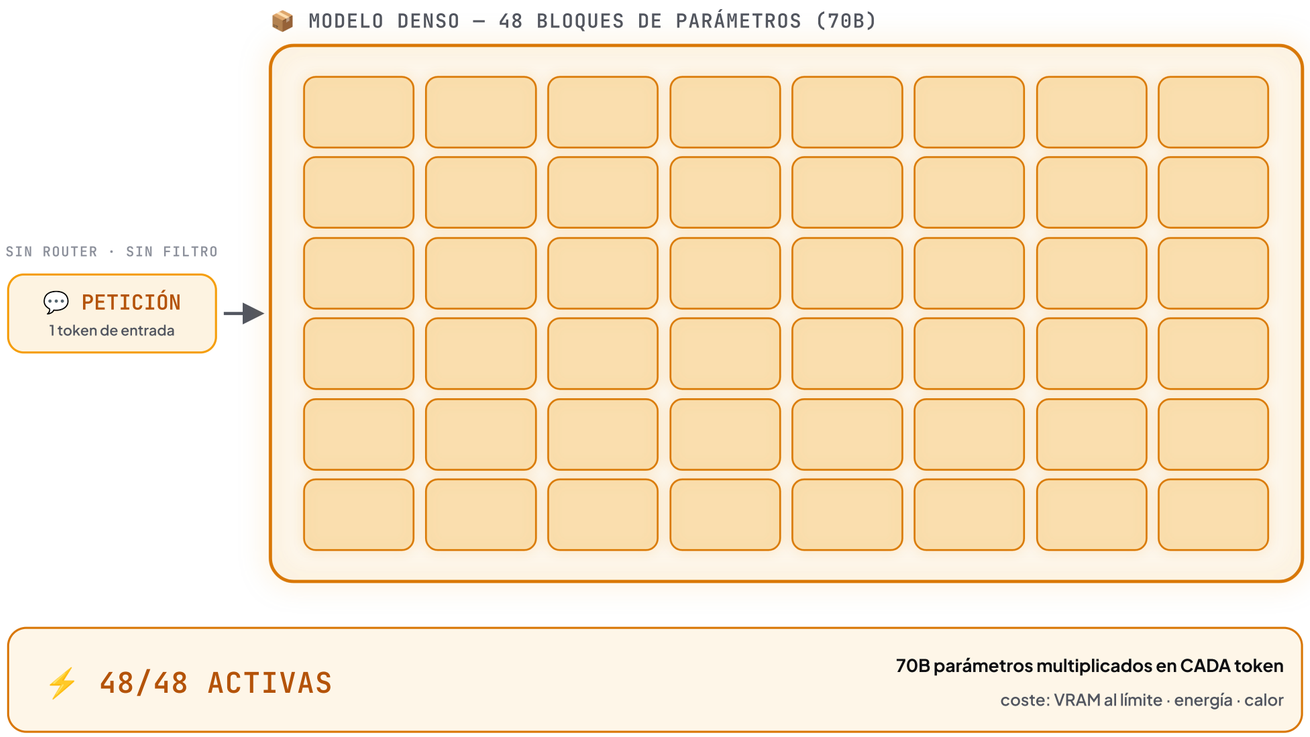

🟠 Sin Gatekeeper: se Encienden Todas

48/48 · 100%

La petición entra y **no existe filtro previo**: los 48 bloques que forman el modelo participan en el cálculo de esa palabra. Es la junta médica completa de la slide siguiente, vista como un panel eléctrico.

⚡ El Peaje: Fuerza Bruta Constante

70B OPS/TOKEN

La GPU **multiplica los 70B parámetros en cada token**, aunque la pregunta sea trivial. VRAM llena, calor y consumo al máximo: el precio de la consistencia total.

🧱 Cuándo Brillan los Densos

8B–32B LOCALES

LLaMA 3 y Qwen densos: predecibles, robustos y perfectos para fine-tuning especializado. En tamaños pequeños y medianos siguen siendo la opción sólida por defecto.

ARQUITECTURA DE MODELOS • DENSOS (100% ACTIVO)

Modelos Densos: La Junta Médica Completa

🏥 Modelo Denso (100% Personal Activo) — Todo el hospital paralizado

🩺 La Analogía Hospitalaria

100% PARÁMETROS

Entras a la consulta por un simple dolor de cabeza y **se convoca a todo el cuadro médico del centro** (neurocirugía, cardiología, traumatología...) para deliberar conjuntamente sobre cada palabra.

⚡ El Peaje en Silicio

FUERZA BRUTA

La GPU no puede discriminar: debe **cargar y multiplicar cada parámetro del modelo** en cada token generado. Si el modelo es de 70B, calcula 70B de operaciones por letra.

📌 Ejemplos en Producción

CLÁSICOS

LLaMA 3 (8B, 70B), Qwen 2.5 (27B, 72B): Extremadamente sólidos y consistentes, pero **devoradores de energía, calor y memoria** en hardware local.

ARQUITECTURA DE MODELOS • MOE — PANEL VISUAL

Modelos MoE: El Router Enciende solo 5 de 48 Luces

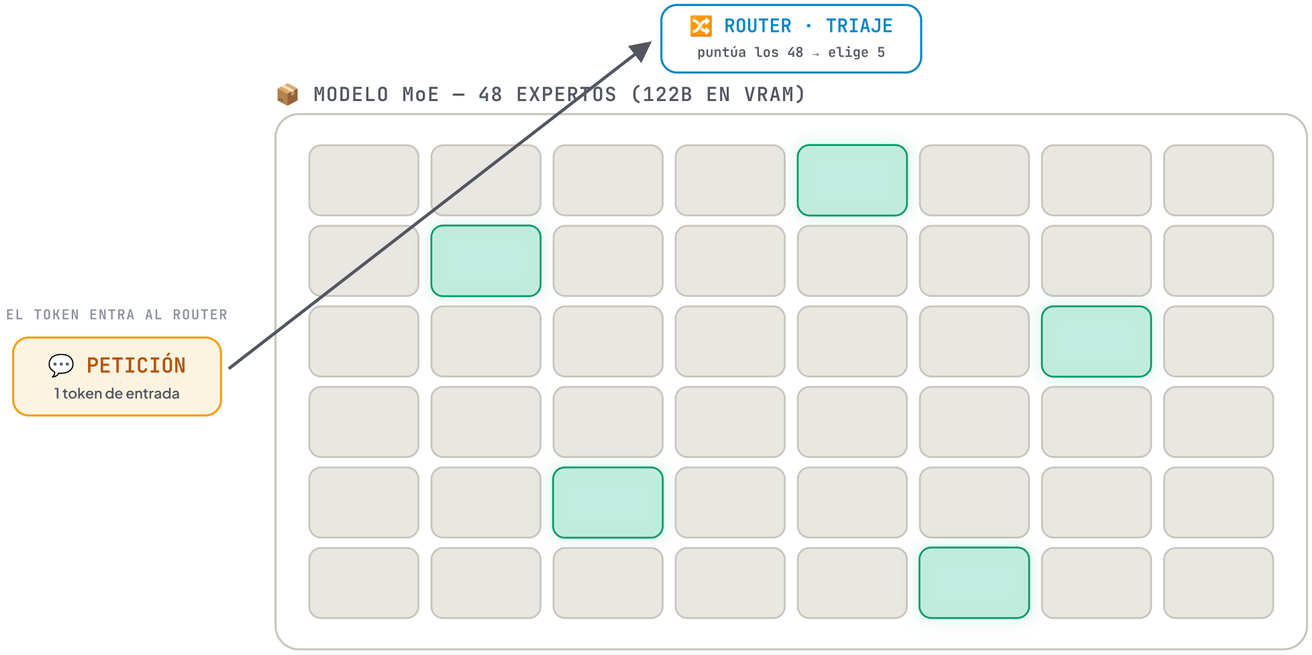

🎯 El Router Hace el Triaje

`TOP-K = 5`

Un **gatekeeper ultrarrápido puntúa a los 48 expertos** en milisegundos y despierta solo a los 5 más afines al token. Los otros 43 ni se inmutan: **su cálculo simplemente no ocurre**.

🚀 VRAM Llena, Cuenta Ligera

`122B / 10B`

En memoria guardas **la enciclopedia completa (122B)**, pero por token solo se mueve **~10B de cómputo**: velocidad relámpago y hueco libre para contexto largo en 128 GB.

🌟 El Estándar de la Nueva Era

`QWEN · DEEPSEEK · MIXTRAL`

Qwen 3.5/3.8 MoE, DeepSeek V3/R1, Mixtral: la frontera corre en estaciones locales. El panel con 5 luces encendidas de 48 es hoy la arquitectura dominante.

ARQUITECTURA DE MODELOS • MIXTURE OF EXPERTS (MOE)

Modelos MoE: El Servicio de Triaje Inteligente

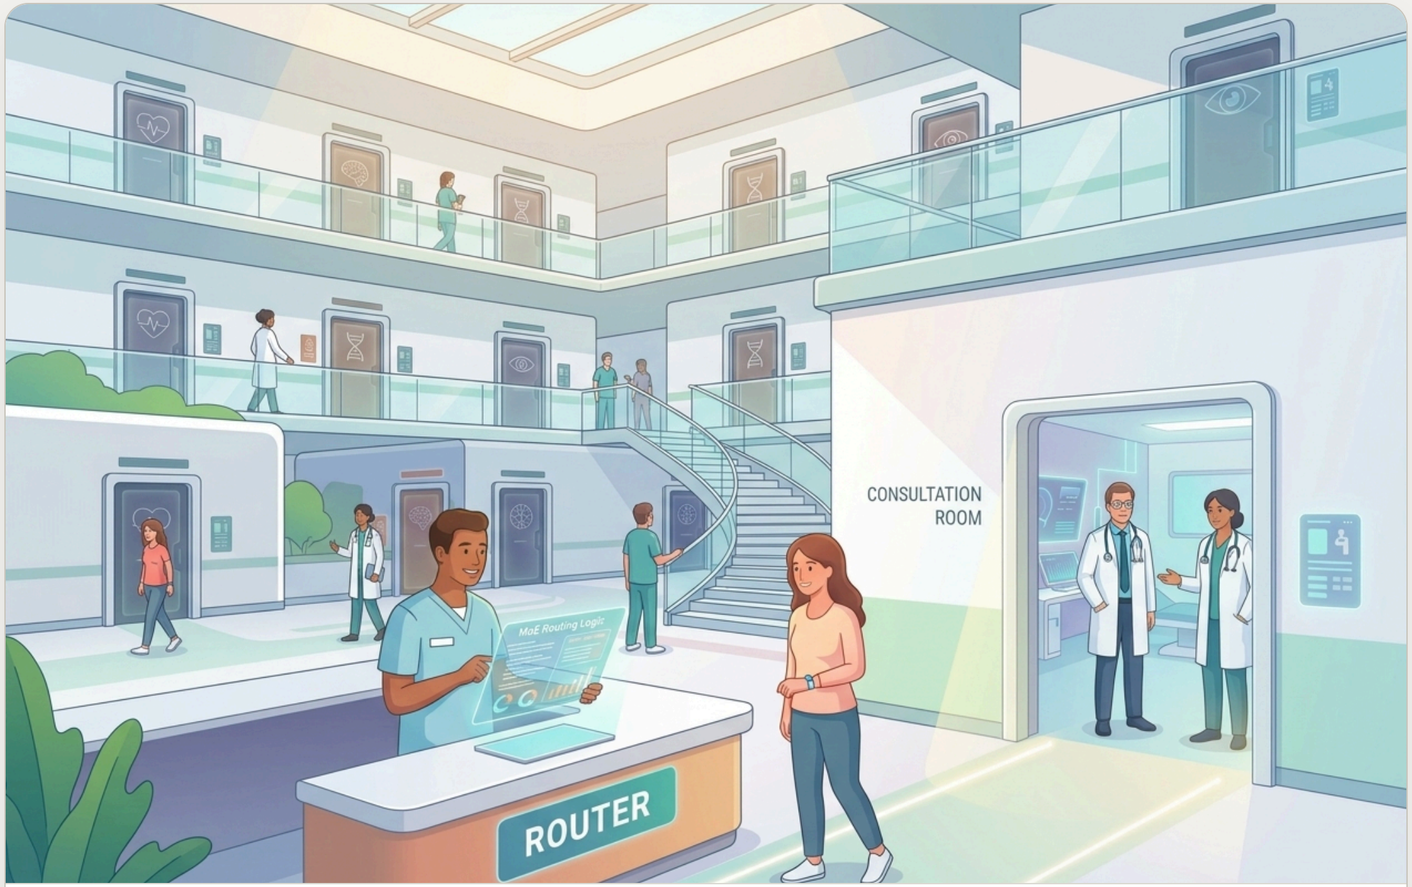

🩺 Modelo MoE (Servicio de Triaje / Router) — Solo 2 Especialistas Activos

🔀 El Servicio de Triaje (*Router*)

SPARSE / EFICIENTE

Un sistema de triaje ultra-rápido clasifica la consulta en un milisegundo y **deriva al paciente exclusivamente a los 2 especialistas necesarios**. El resto del hospital sigue atendiendo en paz.

🚀 La Magia de la Velocidad

122B TOTAL / 10B ACTIVO

En VRAM almacenas la sabiduría de **todo el hospital (122B)**, pero la GPU solo procesa **10B de cálculo activo** por token: velocidad relámpago con máxima inteligencia.

🌟 El Estándar Moderno

NUEVA ERA

Qwen 3.5 (35B / 122B), DeepSeek V3 / R1, Mixtral: Permiten correr modelos de frontera en estaciones de 128 GB dejando espacio holgado para el contexto.

RENDIMIENTO · DOS VELOCIDADES

Prefill vs. Decode: la velocidad tiene dos perfiles

La analogía del corral: el prompt entra como un saco de pienso de golpe; la respuesta sale huevo a huevo.

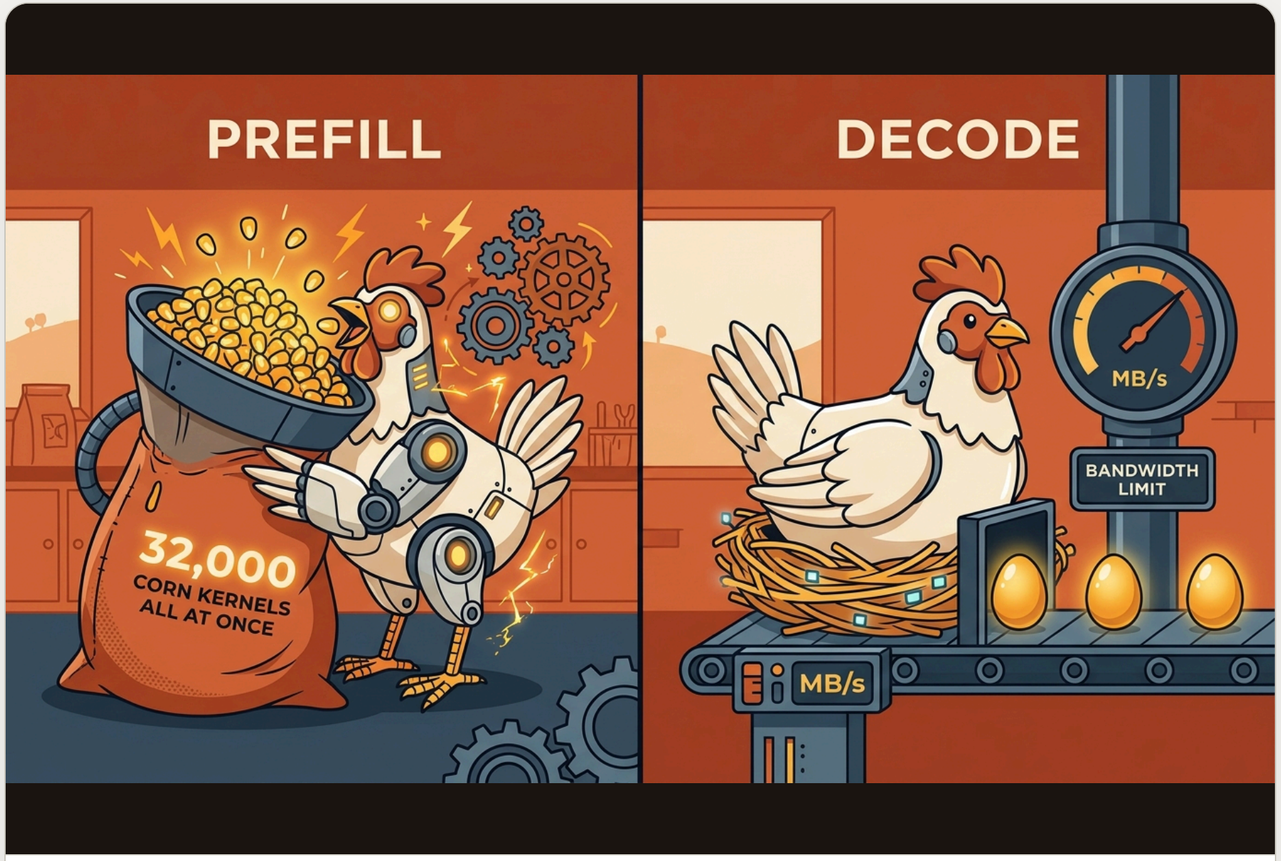

🌾 Prefill: Cómputo (FLOPs) 🥚 Decode: Ancho de banda (GB/s)

🌾 PREFILL

El Saco de Pienso · TTFT

Lee 32.000 tokens **en paralelo** de golpe para construir la atención y la KV Cache.

Cuello de botella: **fuerza bruta de cómputo (FLOPs)** — Tensor Cores FP4/FP8.

👑 NVIDIA Blackwell domina: **~7.600 tok/s en un 8B**

🥚 DECODE

Poner el Huevo · tok/s

Genera **token a token**: cada huevo exige leer los 40 GB enteros de los pesos en memoria.

Cuello de botella: **ancho de banda de memoria (GB/s)**.

👑 Apple Silicon domina: **546 GB/s → 1,2 TB/s**

`Ley del corral: velocidad máx. ≈ GB/s ÷ tamaño (GB)`

Modelo denso 70B en 4-bit (~40 GB): **273 GB/s → ~6,8 tok/s** · 1,2 TB/s → ~30

ECOSISTEMA & INFERENCIA ACELERADA

2026: Timeline de Modelos & Aceleración

Línea temporal de la revolución open-weights: lanzamientos de arquitecturas y evolución del *speculative decoding* (MTP ➔ DSpark ➔ DFlash ➔ DFlash 2).

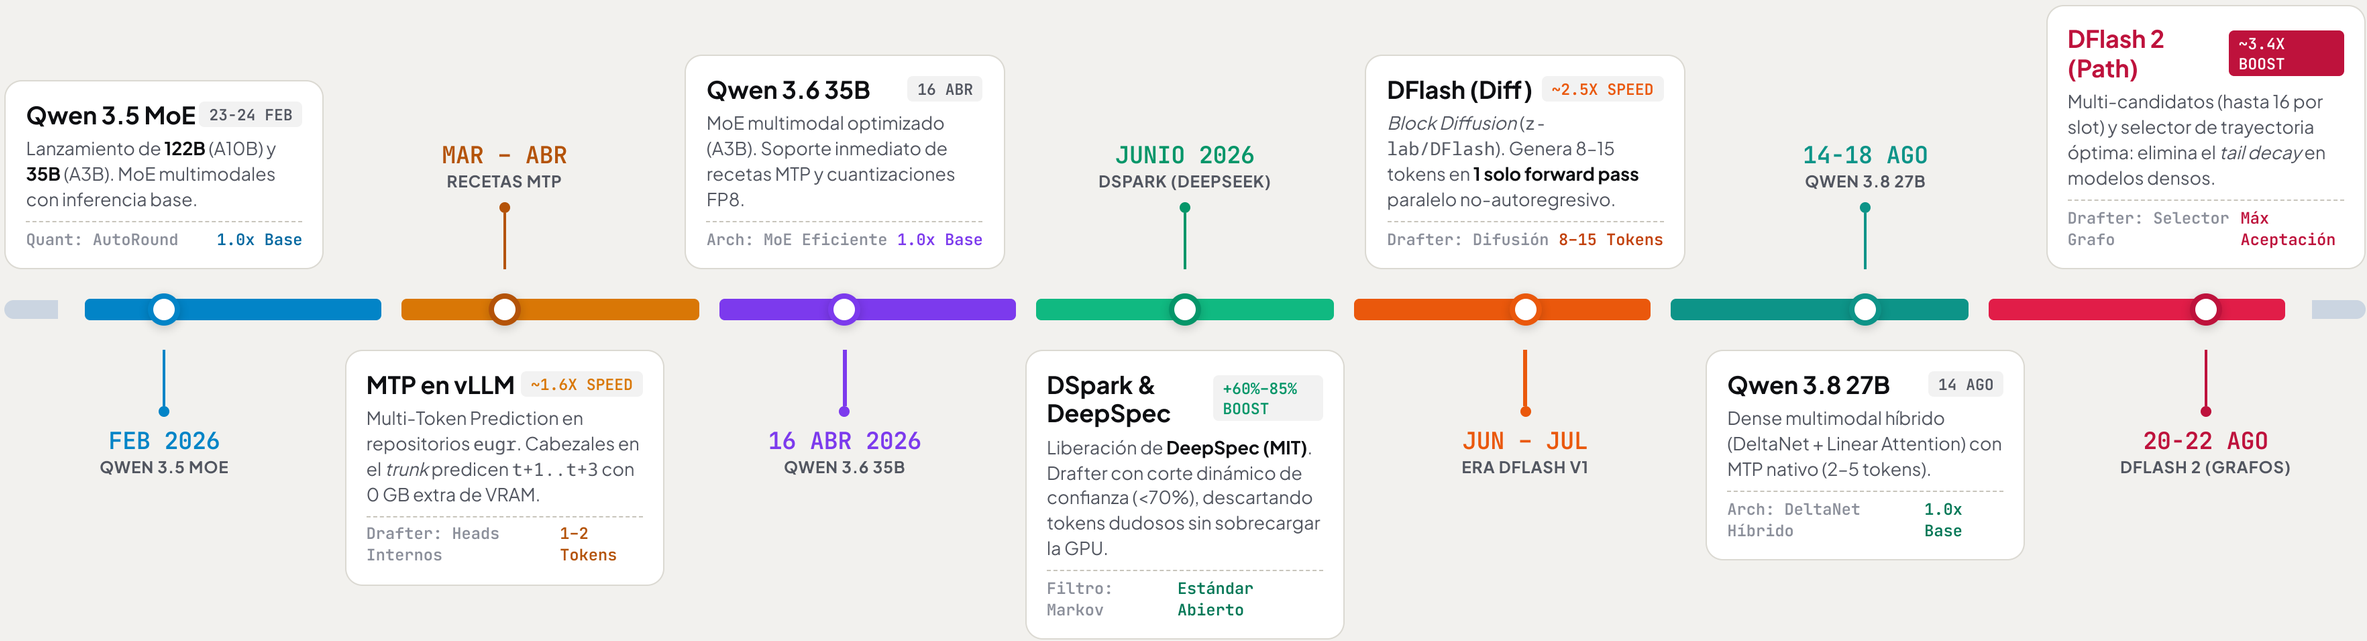

HARDWARE SIZING • FAMILIA QWEN (3.5 – 3.8)

Matriz de Pesos: La Zona Ricitos de Oro

MODELO	PARÁMETROS (TOT. / ACT.)	BF16 / FP16	FP8 / Q8_0	GGUF Q5_K_M	AWQ INT4	INT4 AUTOROUND	NVFP4 (BLACKWELL)	TOK/SEG	CON MTP
Qwen 3.5 – 0.8B	0.8B / 0.8B (Dense)	~1.6 GB	~0.8 GB	~0.55 GB	~0.48 GB	~0.45 GB	*No optimizado*	–	–
Qwen 3.5 – 4B	4B / 4B (Dense)	~8.0 GB	~4.0 GB	~2.8 GB	~2.4 GB	~2.3 GB	*No optimizado*	–	–
Qwen 3.5 – 9B	9B / 9B (Dense)	~18.0 GB	~9.0 GB	~6.2 GB	~5.3 GB	~5.0 GB	*No optimizado*	–	–
Qwen 3.5 – 27B	27B / 27B (Dense)	~54.0 GB	~27.0 GB	~18.5 GB	~15.5 GB	~15.2 GB	~14.5 GB	–	–
Qwen 3.6 – 27B	27B / 27B (Dense)	~54.0 GB	~27.0 GB	~18.5 GB	~15.5 GB	~15.2 GB	~14.5 GB	8	16 (×2)
★ Qwen 3.8 – 27B MTP / DFlash	27B / 27B (Dense)	**~53.0 GB**	**~28.0 GB**	**~19.0 GB**	**~21.0 GB**	**~21.0 GB**	**~22.0 GB**	12	28 (×2.3)
★ Qwen 3.6 – 35B	35B / 3B (MoE)	**~70.0 GB**	**~35.0 GB**	**~24.0 GB**	**~20.2 GB**	**~19.8 GB**	**~18.5 GB**	74	134 (×1.8)
★ Qwen 3.8 Flash Next	125B + 51B / 6B (MoE híbrido)	**~360.0 GB**	**~185.5 GB**	**~158.0 GB**	**~168.0 GB**	**~178.0 GB**	**~105.0 GB**	24	38 (×1.6)
Qwen 3.5 – 122B	122B / 10B (MoE)	**~244.0 GB**	**~122.0 GB**	**~84.0 GB**	**~71.5 GB**	**~69.0 GB**	**~65.0 GB**	28	54 (×1.9)
Qwen 3.5 – 397B	397B / 17B (MoE)	~794.0 GB	~397.0 GB	~273.0 GB	~231.0 GB	~223.0 GB	~210.0 GB	–	–

La "Zona Ricitos de Oro" (Goldilocks Zone)
Ni demasiado pequeños (falta de razonamiento) ni inasumibles (>200 GB en GPU): **Qwen 3.8 27B, 35B MoE, 122B MoE y el híbrido Flash Next** (125B+51B: cabe entero en 128 GB) ofrecen la máxima velocidad e inteligencia dejando margen holgado para KV Cache en hardware de 128 GB.

Target: DGX Spark / GB10 (128 GB)

“

El hardware puede encarecerse.

Los pesos, no.